Universidad Nacional Abierta y a Distancia

Vicerrectoría Académica y de Investigación

Unidad gestora: *Escuela*

Programa: *Ingeniería de Sistemas*

Curso: Big Data

Código: 202016911

INSTRUCTIVO DE INSTALACIÓN CLUSTER HADOOP

LINK DE REFERENCIA:

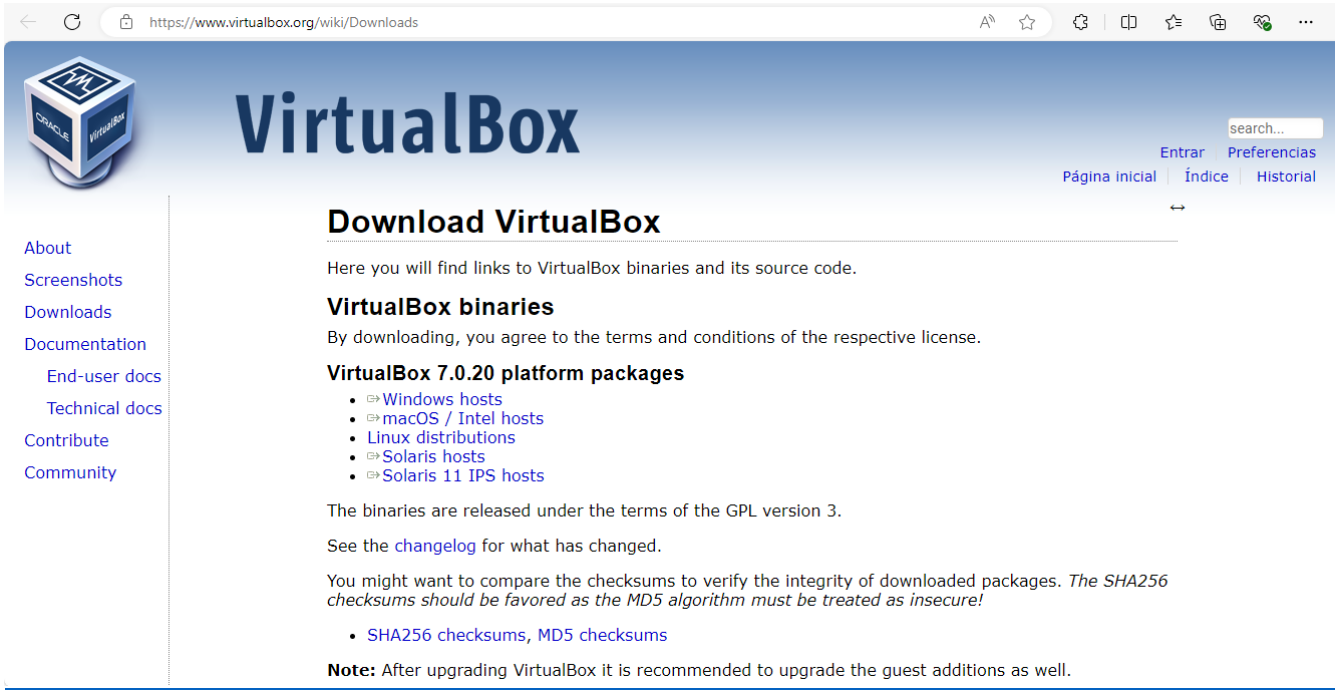
https://www.solvetic.com/tutoriales/article/10983-instalar-ubuntu-server-22-04-en-virtualbox/

VIRTUALBOX

Iniciamos con la instalación de VirtualBox, software que permite crear maquinas virtuales dentro de tu sistema operativo.

Figura 1.

Página principal de virtualbox para descargas.



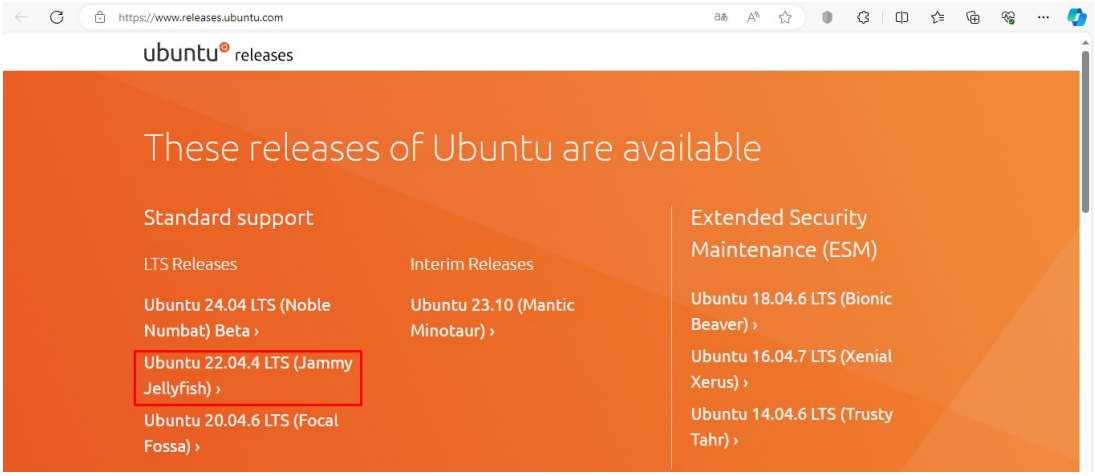
Nota: Página principal de VirtualBox para descargas. Tomado de https://www.virtualbox.org/wiki/Downloads

Se comparte el enlace directo para la descarga de VirtualBox para sistema operativo Windows.
https://download.virtualbox.org/virtualbox/7.0.10/VirtualBox-7.0.10-163906-Win.exe

El archivo se debe descargar y ejecutar como administrador.

Figura 2.

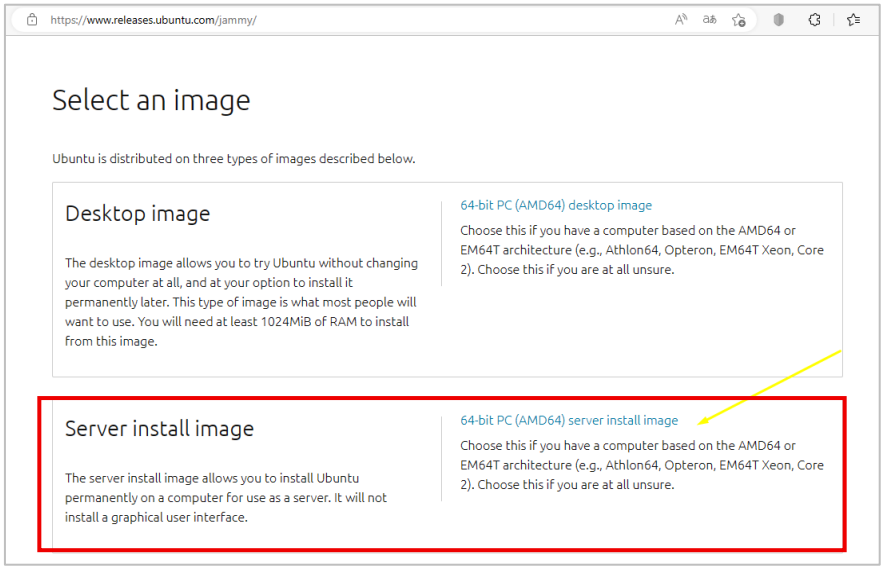
Página principal de Linux Ubuntu



Nota: Página principal de Linux Ubuntu donde se resalta descargar la versión Ubuntu 22.04.4 LTS (Jammy Jellyfish). Tomado de https://www.releases.ubuntu.com/

Figura 3.

Linux Ubunto versión "Server install image"



Nota: Se debe seleccionar la versión “Server install image”.

Ahora, en VirtualBox Añadir nueva máquina virtual

Figura 4.

Software VirtualBox



Iniciamos el proceso de instalación de Linux Ubuntu versión “server” en el software VirtualBox. Damos nombre a la máquina virtual (**BIGDATA**) y buscamos el archivo .iso que descargamos anteriormente en la página oficial de Ubuntu.

Figura 5.

Configuración inicial de la máquina virtual en VirtualBox

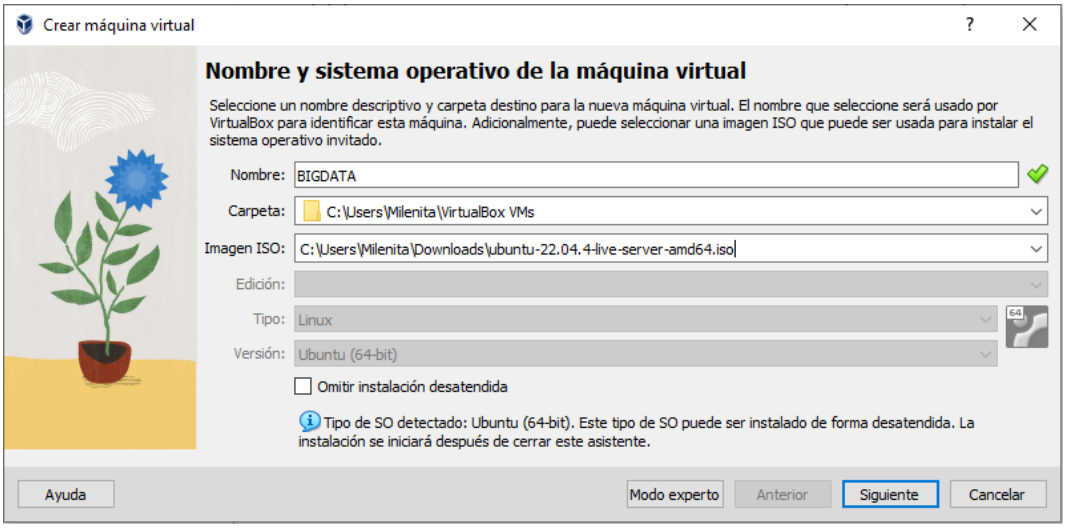
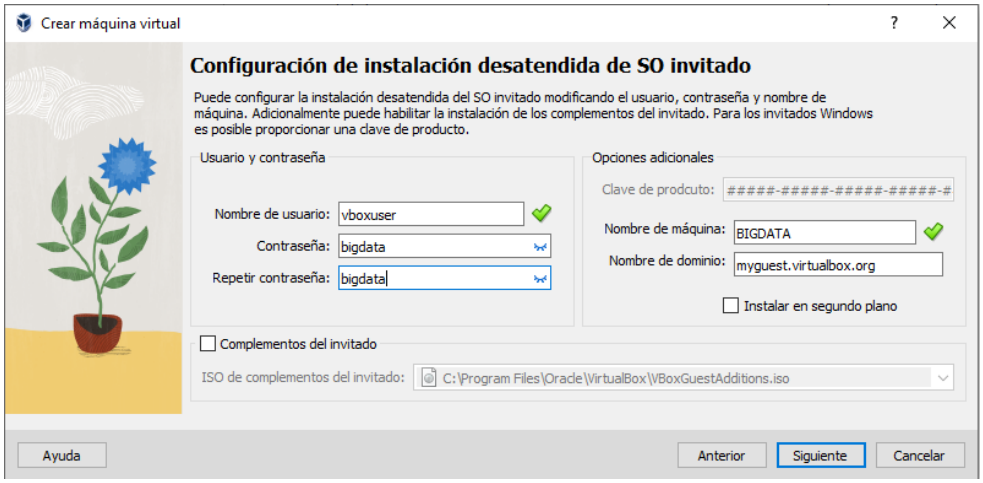


Figura 6.

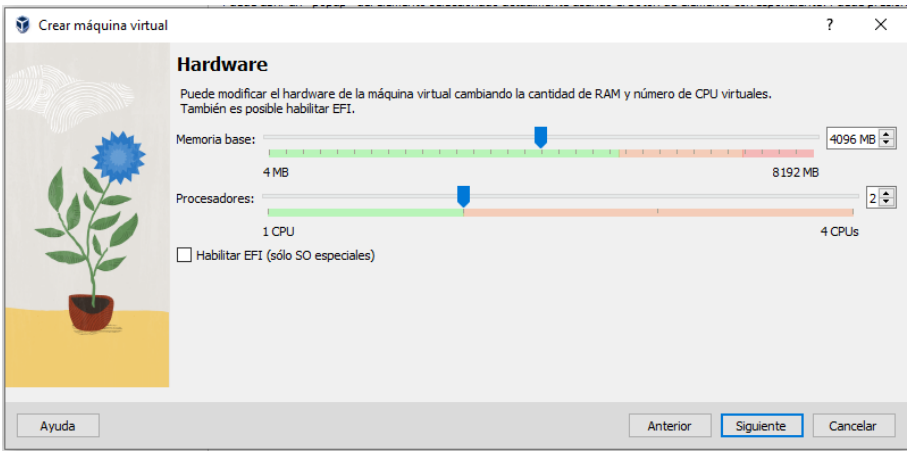
Configuración de usuario y contraseña en VirtualBox



Nota: Se asigna el usuario “vboxuser” y la contraseña “bigdata” a la máquina virtual en VirtualBox.

Figura 7.

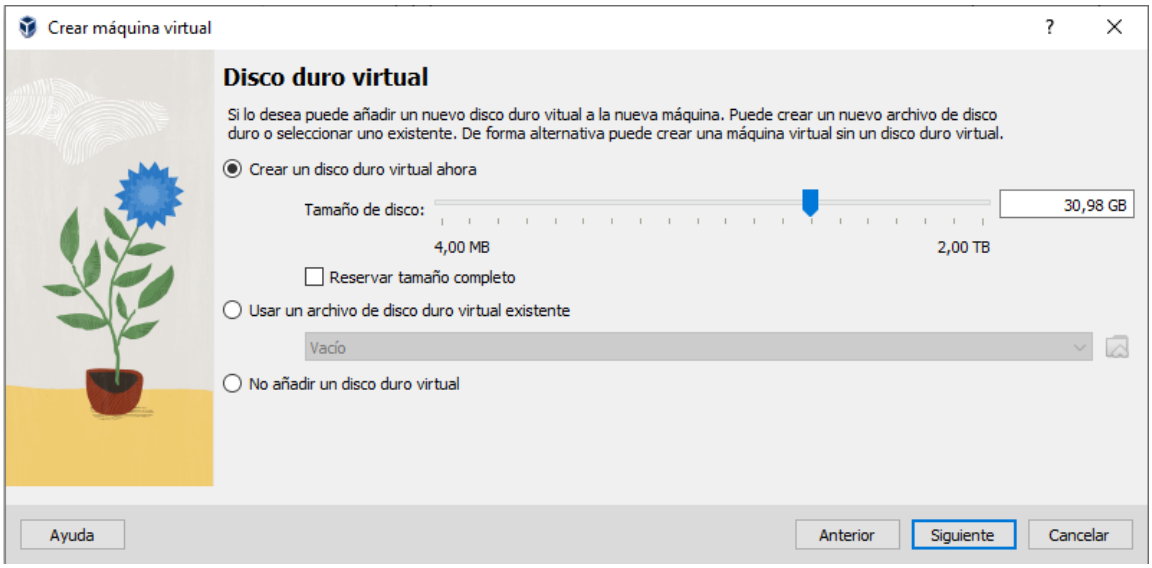
Configuración de hardware en VirtualBox



Nota: Configuración de los recursos de hardware para asignar a la máquina virtual. No pasarse de lo verde (depende de cada máquina) entre más recursos se asignen más rápida será la máquina virtual.

Figura 8.

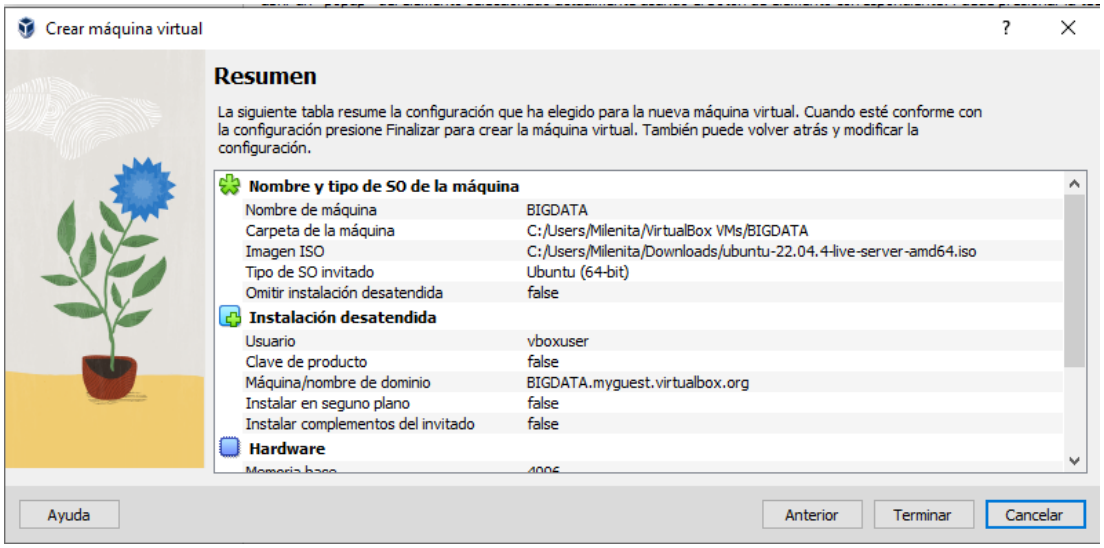
Configuración de disco duro en VirtualBox



Nota: Definimos el tamaño de disco duro para la máquina virtual (se recomienda 30 GB)

Figura 9.

Resumen de la configuración de la máquina virtual



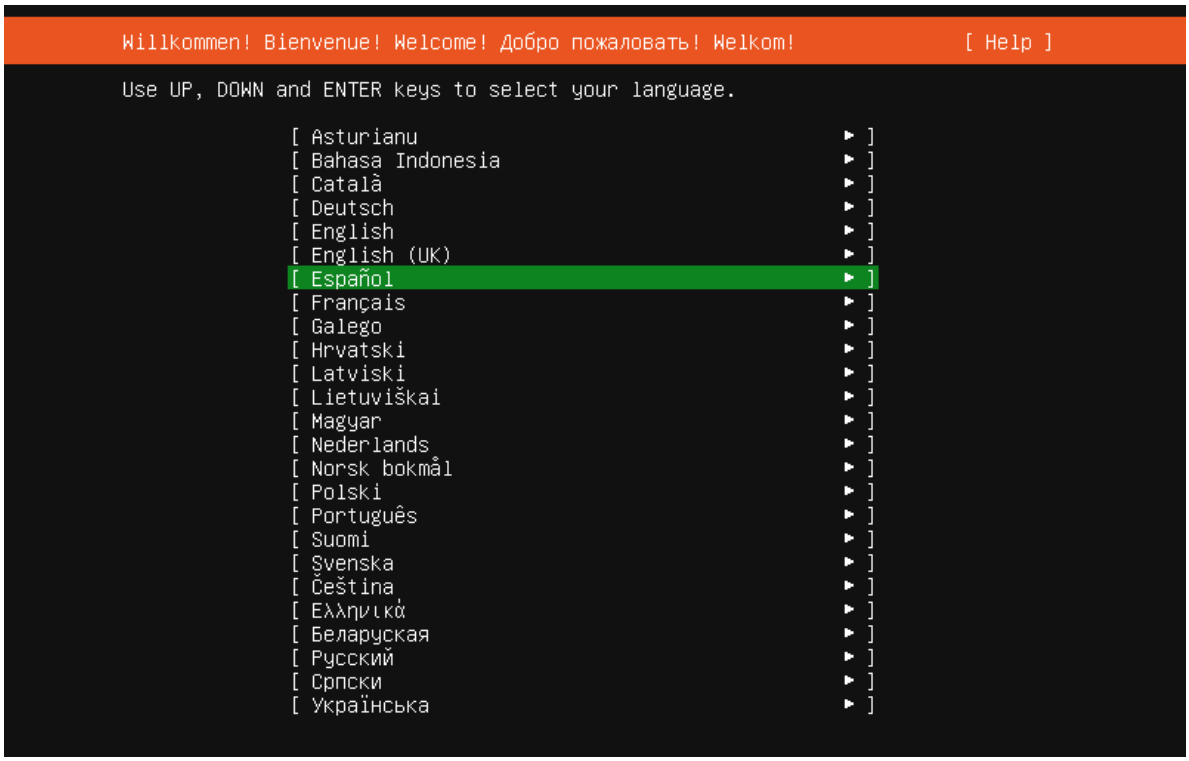
Nota: Resumen con la configuración asignada a la máquina virtual.

Linux Ubuntu

En VirtualBox, debemos iniciar la máquina virtual creada anteriormente. Una vez se inicie la maquina virtual iniciamos con el proceso de configurando el sistema operativo “Linux Ubuntu” o simplemente “Ubuntu”.

Figura 10.

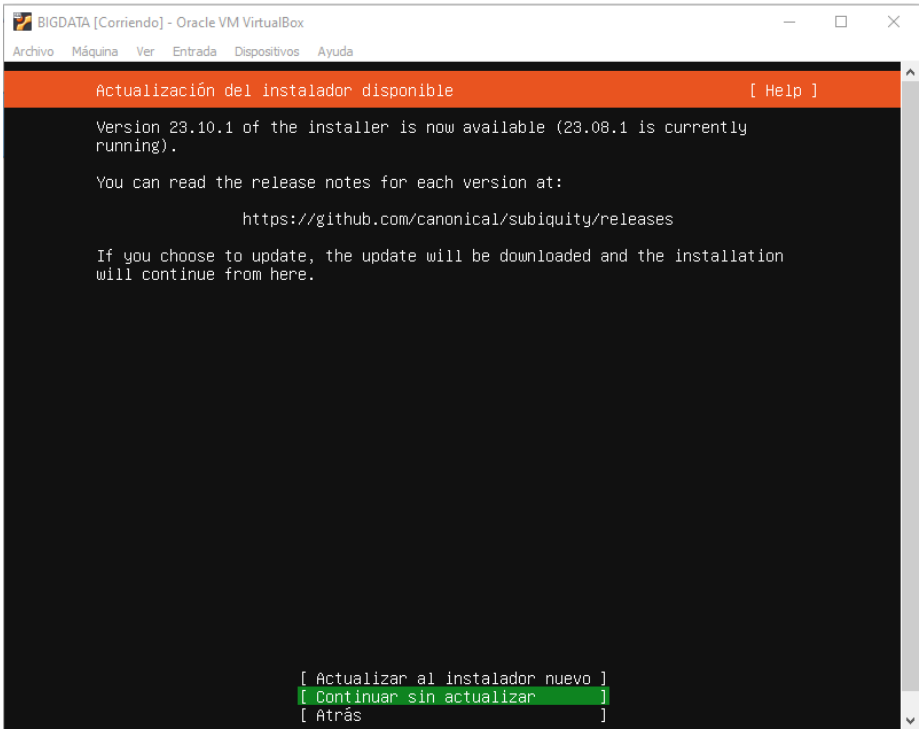
Configuración del idioma en el sistema operativo Ubuntu



Nota: Seleccionar el idioma de su preferencia (recomendado español).

Figura 11.

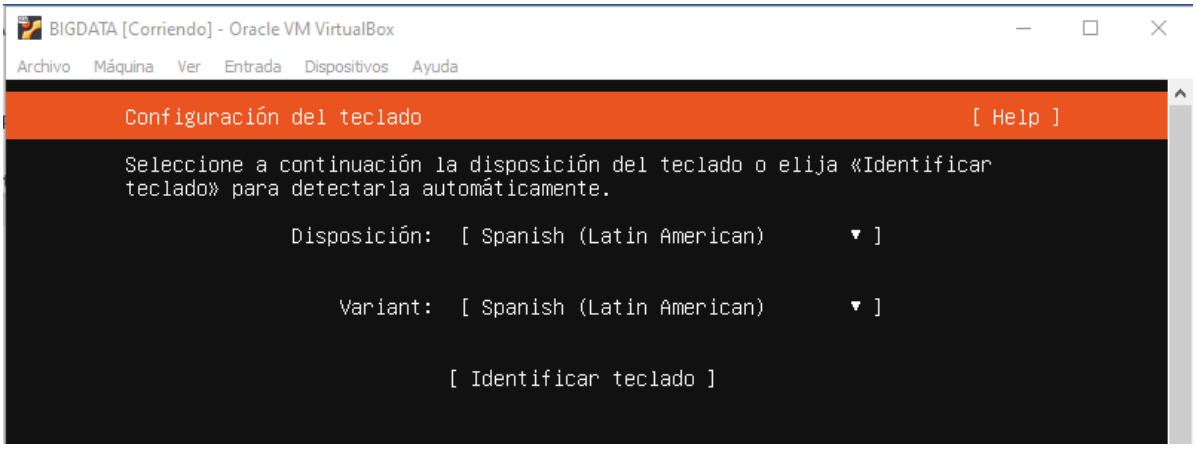
Actualización del instalador de Ubuntu



Nota: Si en la instalación nos pide actualizar el instalador, seleccionamos la opción “Actualizar al instalador nuevo”.

Figura 12.

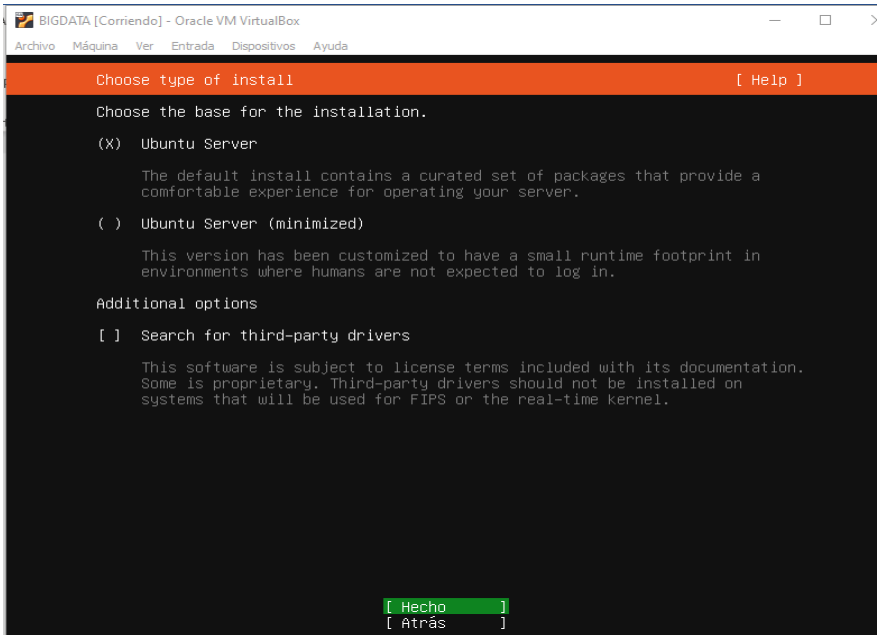
Configuración del teclado



Nota: Se recomienda dejar la configuración del teclado que estan por defecto.

Figura 13.

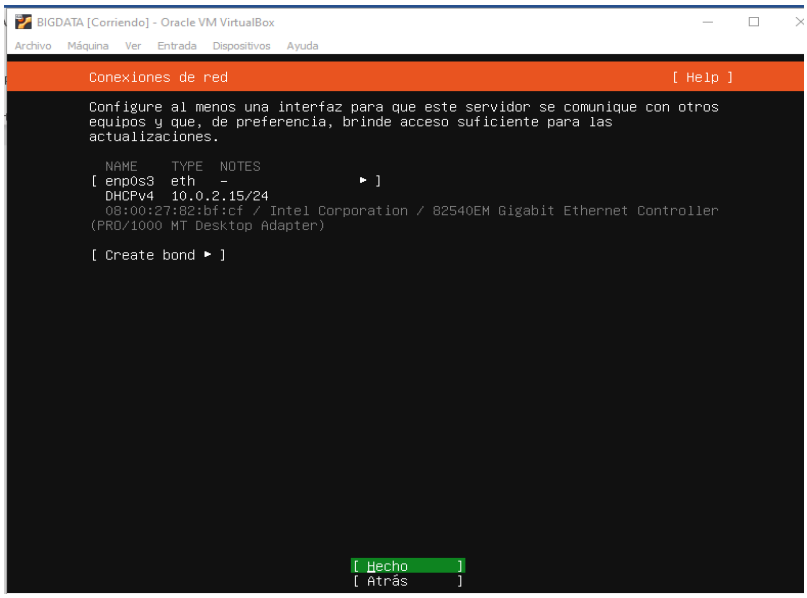
Configuración del Ubuntu Server



Nota: Seleccionar el tipo de instalación “Ubuntu Server” que están por defecto.

Figura 14.

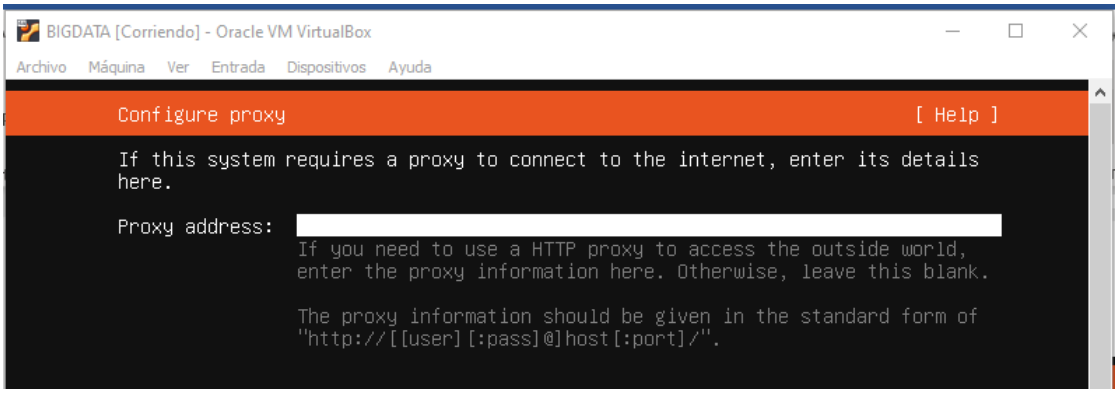
Configuración de red de Ubuntu



Nota: Para la configuración de red, dejamos los valores que nos brinda por defecto el instalador

Figura 15.

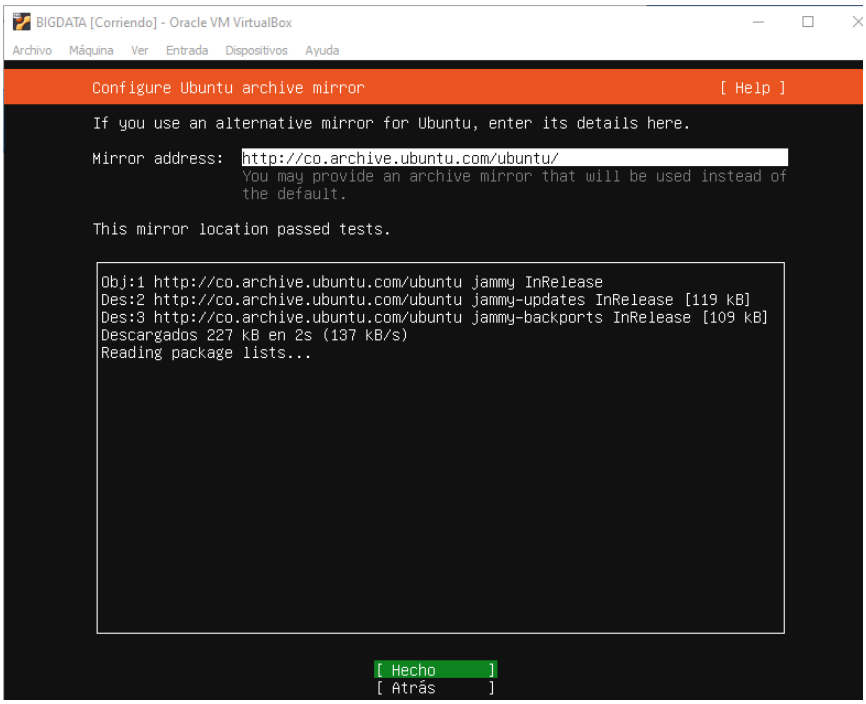
Configuración del proxy del Ubuntu



Nota: En la configuración del proxy Address no configuramos nada. Se dejan los valores por defecto.

Figura 16.

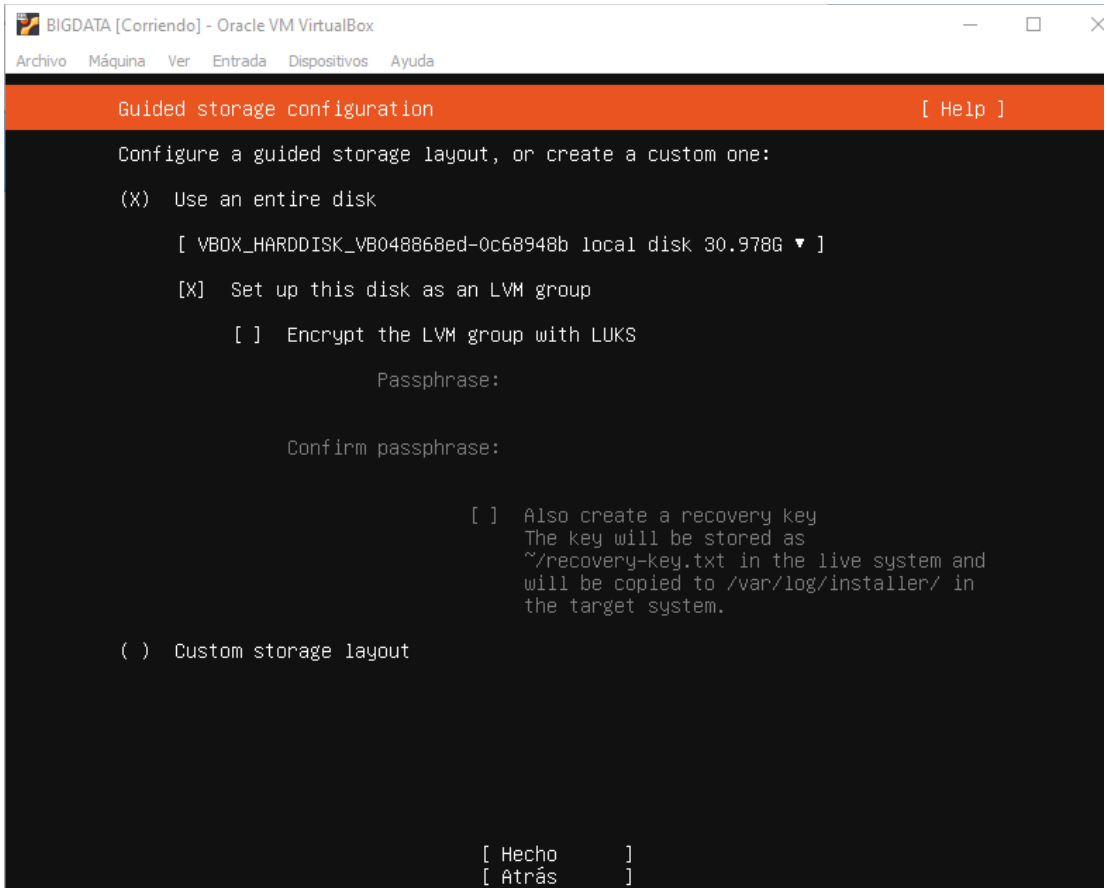
Configuración del mirror de Ubuntu



Nota: En la configuración del mirror address dejamos el valor por defecto

Figura 17.

Configuración del almacenamiento del Ubuntu



Nota: En la configuración de almacenamiento “storage” dejamos los valores que nos aparecen por defecto.

Verificamos el resumen del sistema de archivos, el sistema particiona automáticamente: 1 Mb para grub (gestor de arranque), 2Gb (/boot) archivos del kernel, 28Gb resto del sistema. Lo anterior ya que se seleccionó al inicio en la configuración de la máquina de VirtualBox un espacio de disco de 30Gb

Figura 18.

Resumen de la configuración del Ubuntu

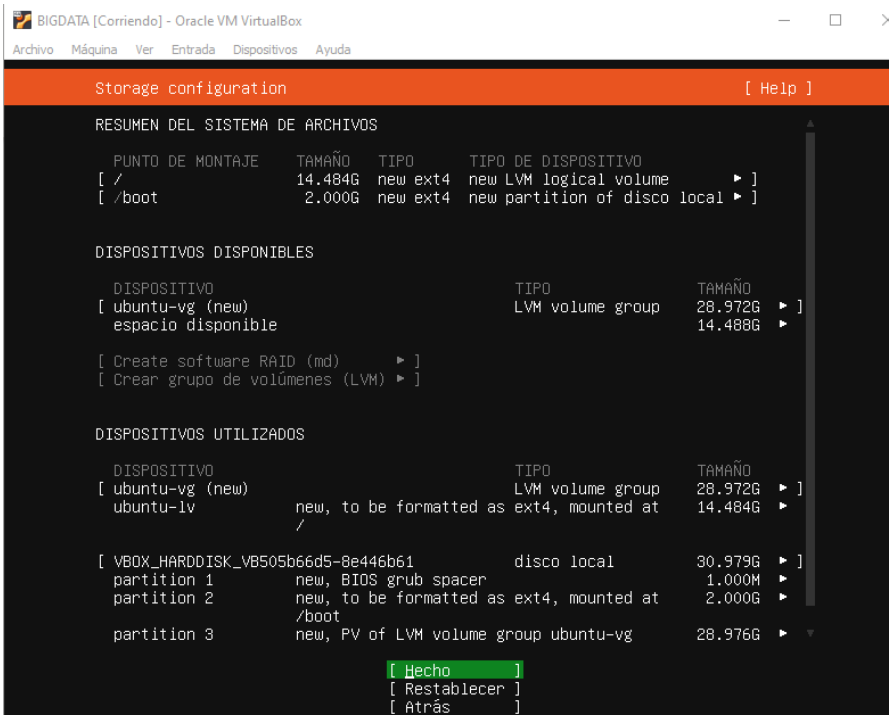
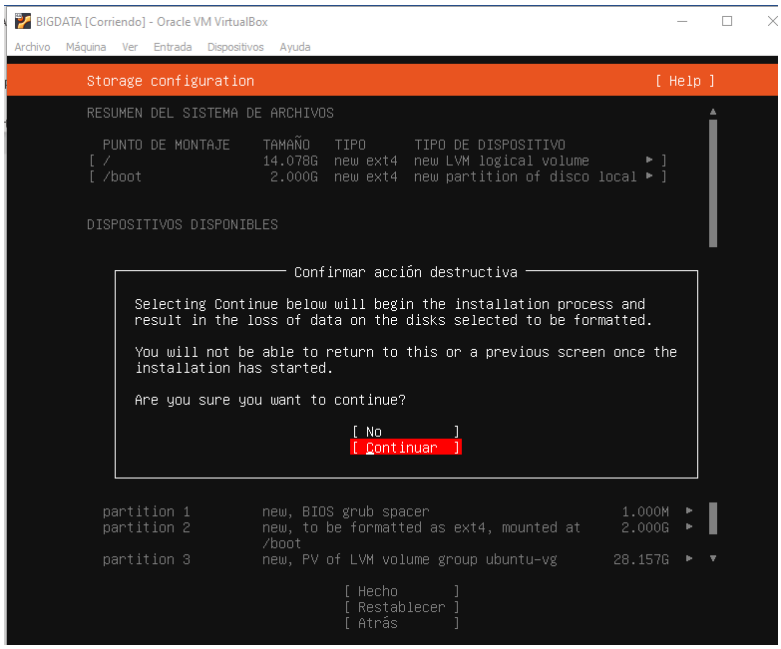


Figura 19.

Confirmación de la configuración establecida en Ubuntu



Se procede con la configuramos el perfil de usuario del sistema operativo Ubuntu.

Su nombre: Digite su nombre y apellido
Your servers name: bigdata
Elija un nombre de usuario: vboxuser
Contraseña y confirme la contraseña: bigdata

Figura 20.

Configuración del perfil de usuario en Ubuntu

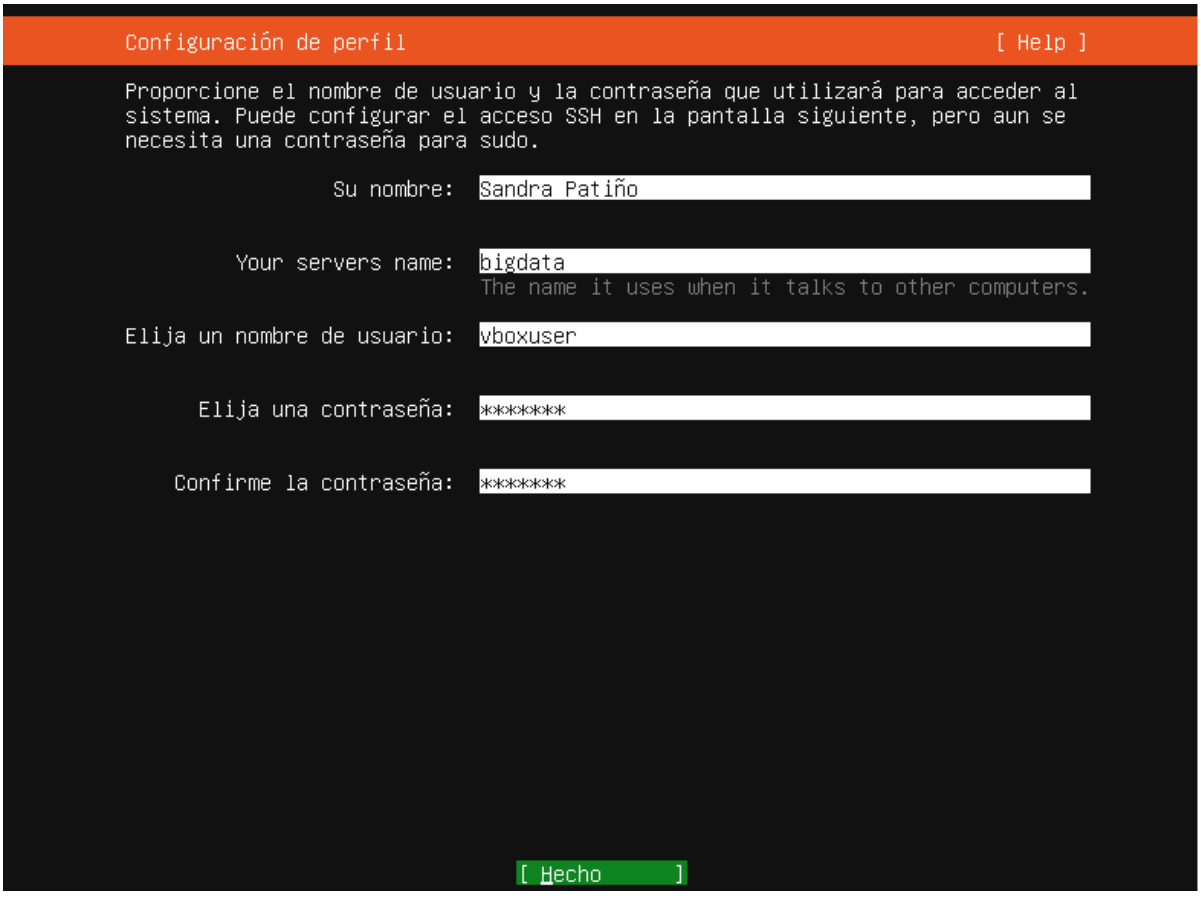
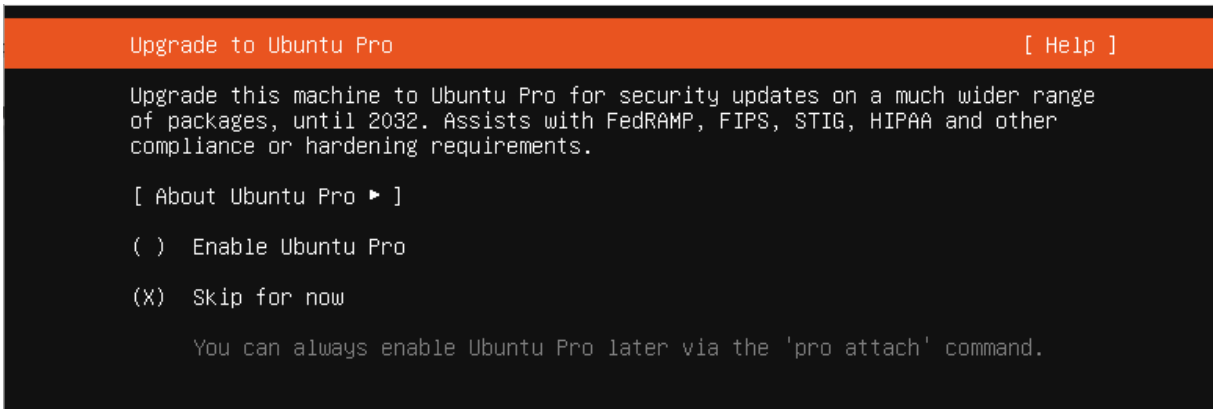


Figura 21.

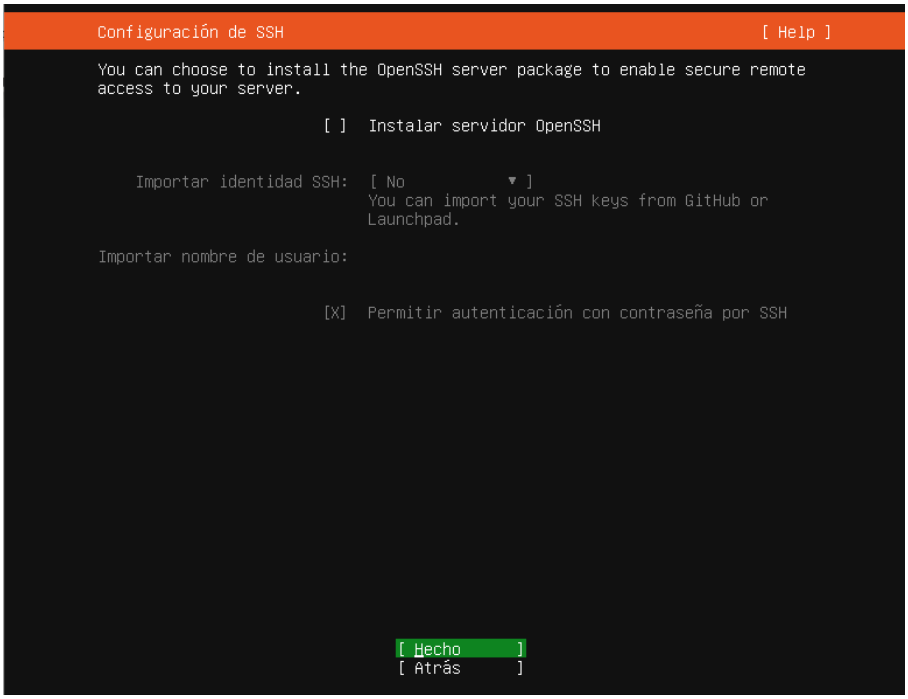
Configuración del Ubuntu Pro



Nota: Para Ubuntu Pro, dejamos los valores por defecto y seleccionamos “Skip for now”

Figura 22.

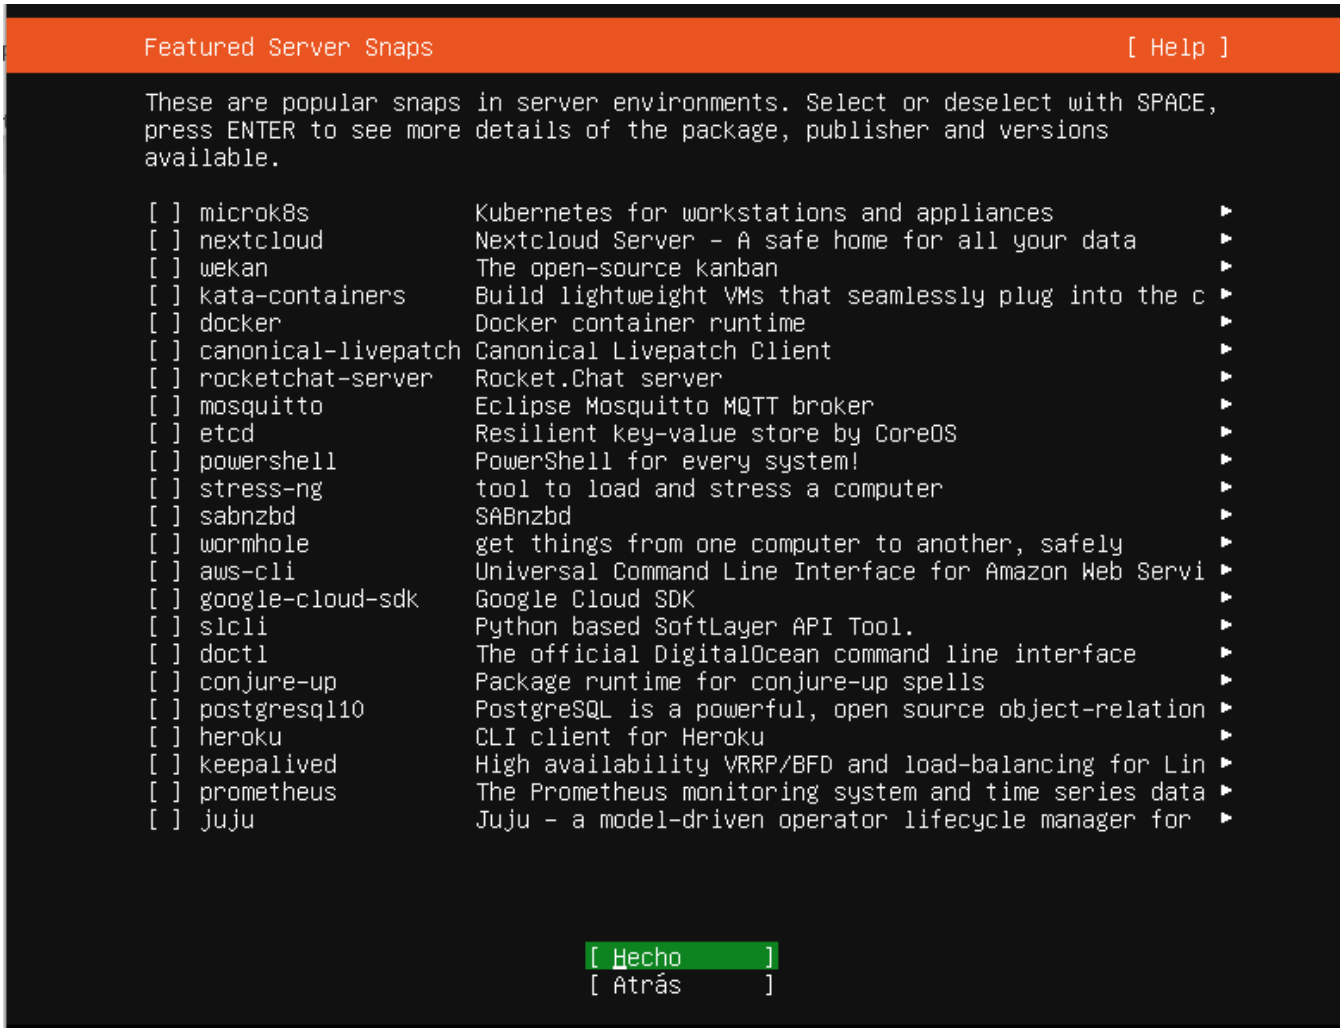
Configuración del SSH en Ubuntu



Nota: Por ahora, no instalamos el servidor OpenSSH (OpenSSH es una herramienta de conectividad para el inicio de sesión remoto que usa el protocolo SSH)

Figura 23.

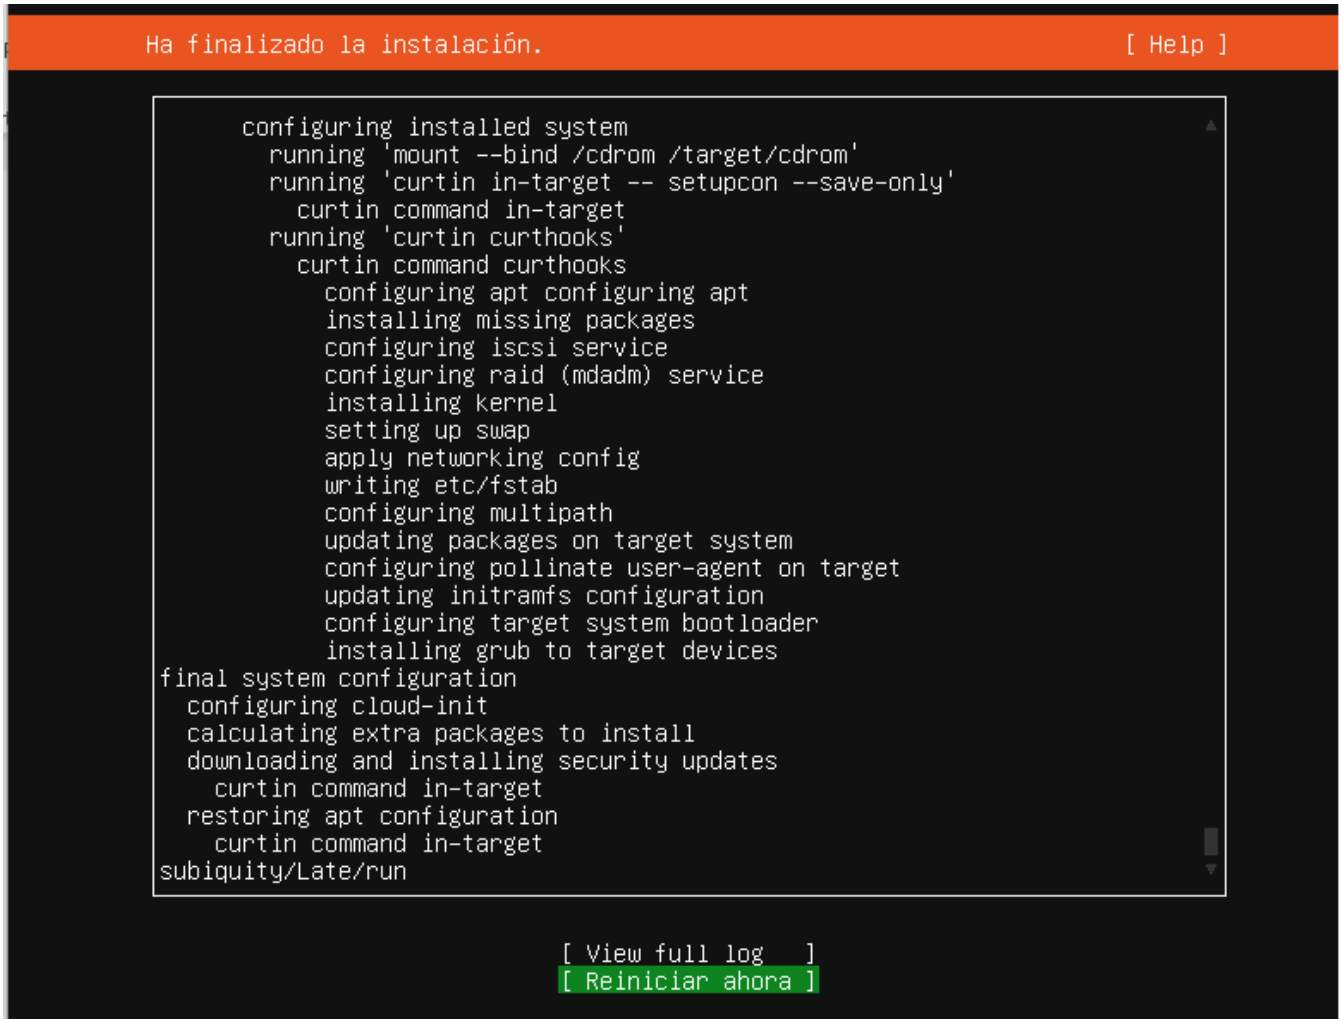
Configuración de paquetes adicionales



Nota: No seleccionamos ningún paquete adicional

Figura 24.

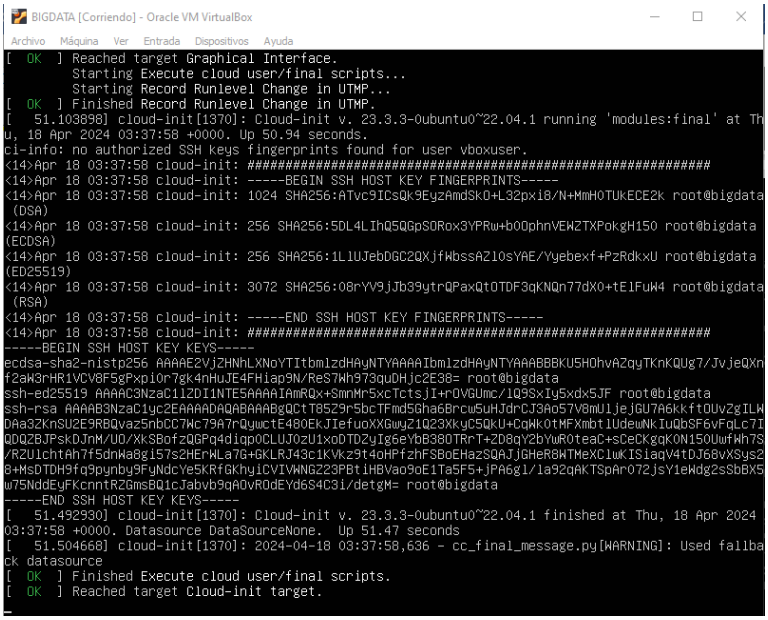
Proceso de instalación del sistema operativo Ubuntu



Nota: Inicia el proceso de instalación del sistema operativo Ubuntu, este proceso puede demorar unos minutos, al finalizar damos enter en Reiniciar ahora

Figura 25.

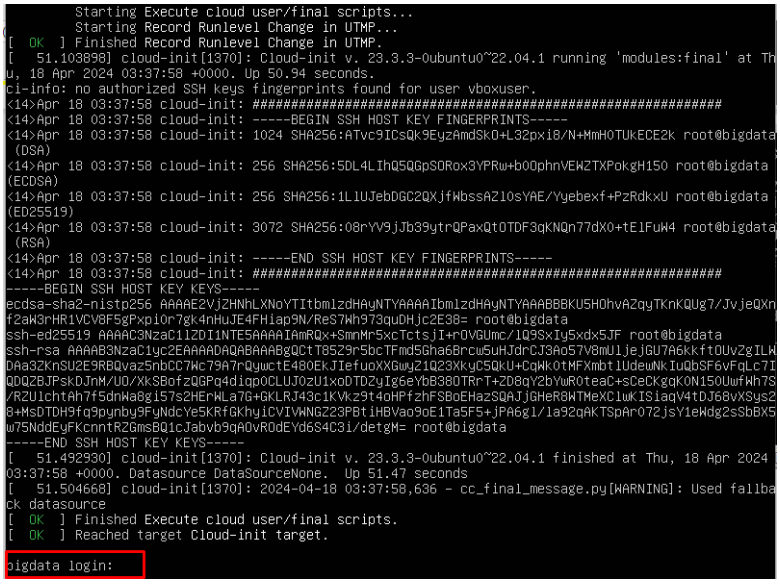
Finalización del proceso de instalación de Ubuntu



Nota: Una vez finalizado el proceso de instalación de Ubuntu, procedemos a dar enter para que aparezca el login

Figura 26.

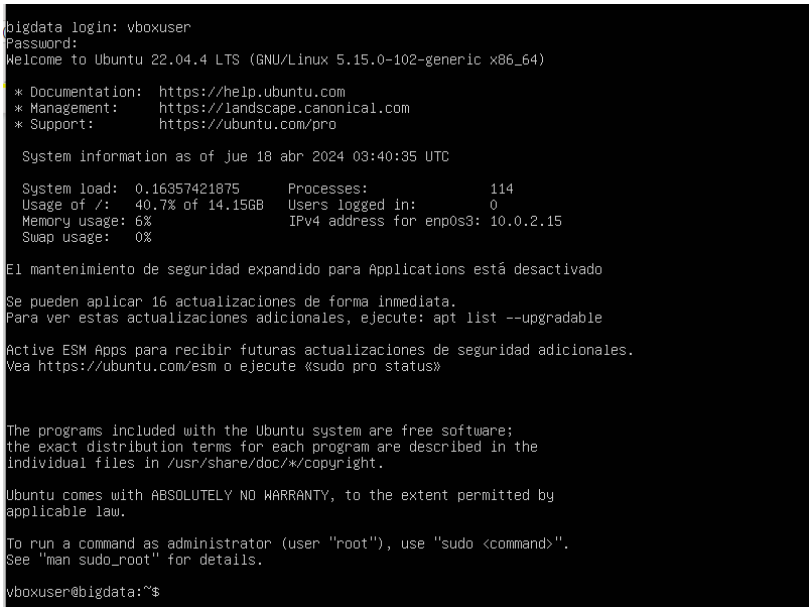
Inicio de sesión en Ubuntu



Nota: iniciamos sesión con el usuario definido en el proceso de instalación y configuración del Ubuntu. Usuario “vboxuser” y contraseña “bigdata”

Figura 27.

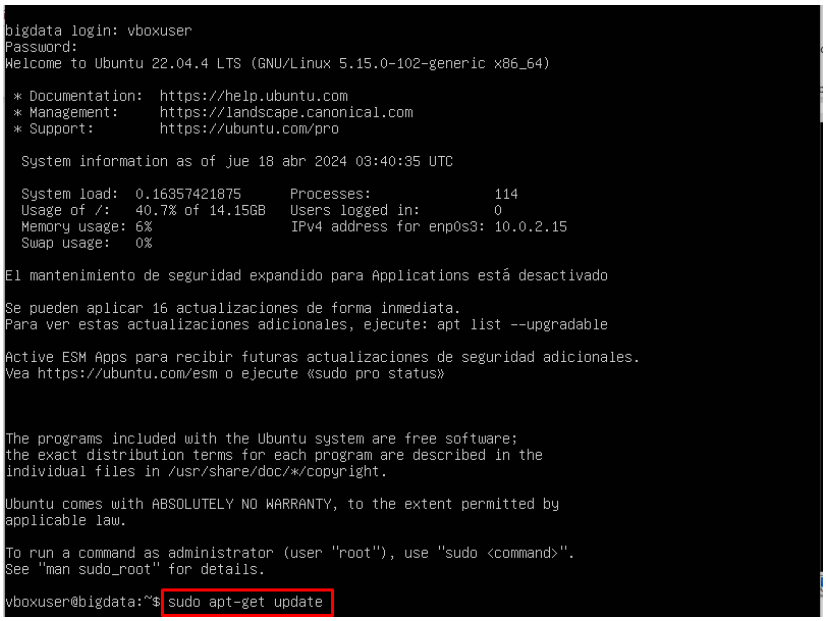
Inicio de sesión con el usuario vboxuser



Una vez iniciado la sesión con el usuario “vboxuser” procedemos a realizar una actualización del sistema operativo Ubuntu ya instalado.

Figura 28.

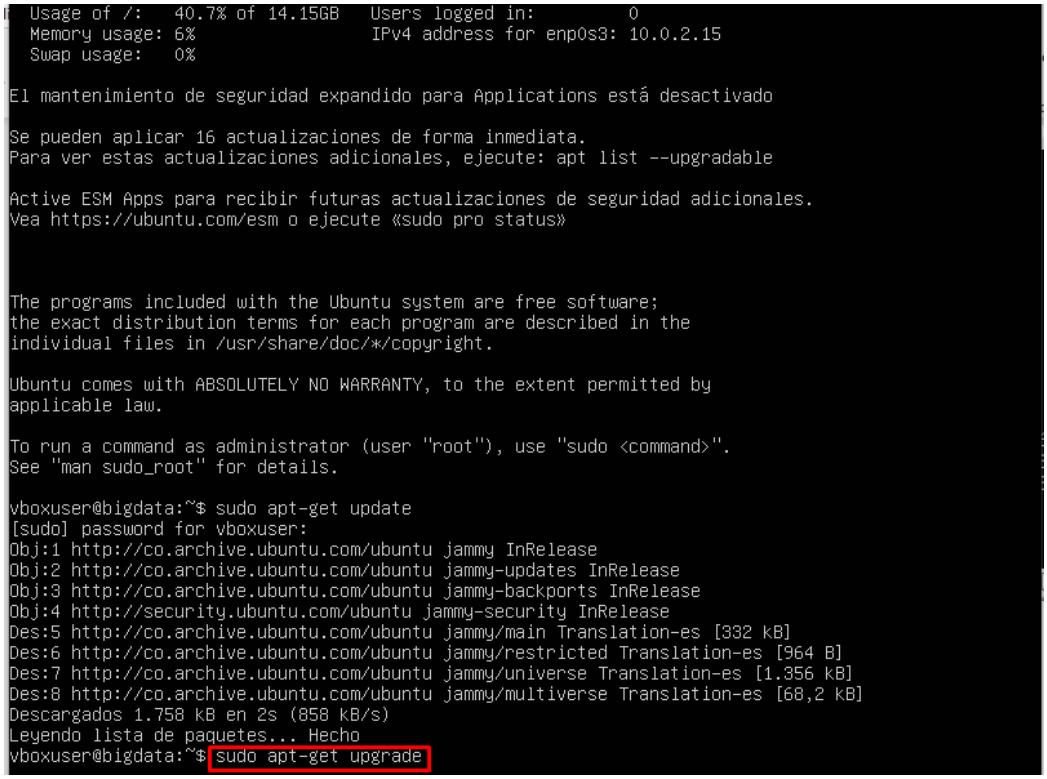
Actualización del Ubuntu mediante el comando update



Nota: Proceso de actualización mediante el comando “sudo apt-get update”. Si el sistema operativo solicita contraseña se debe diligenciar “bigdata”

Figura 29.

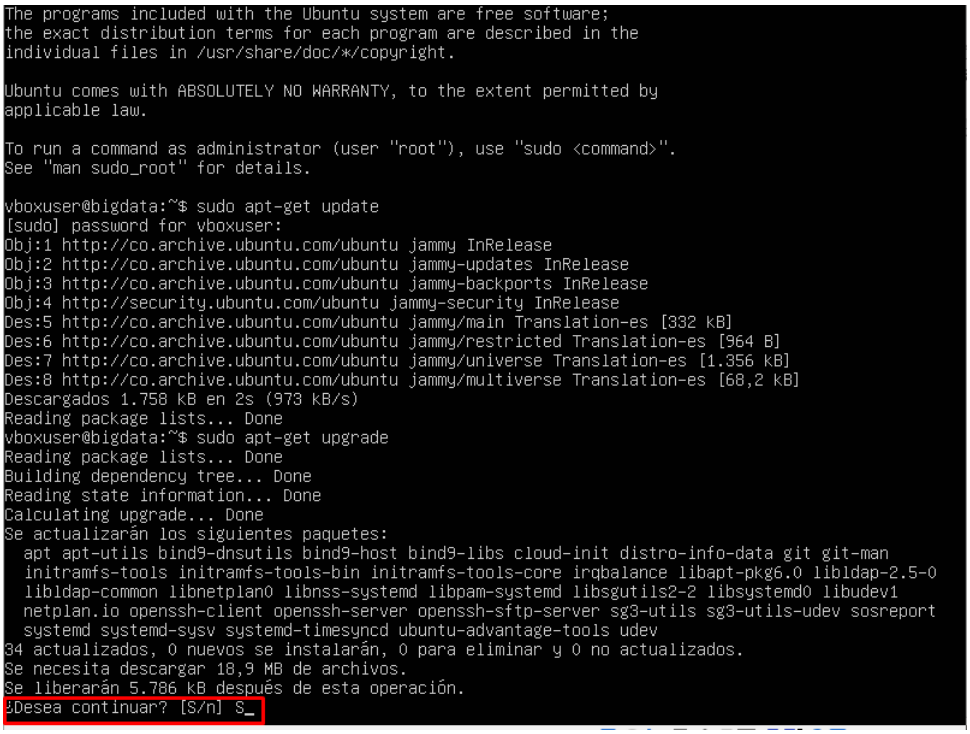
Actualización del Ubuntu mediante el comando upgrade



Nota: Proceso de actualización mediante el comando “sudo apt-get upgrade”. Si el sistema operativo solicita contraseña se debe diligenciar “bigdata”

Figura 30.

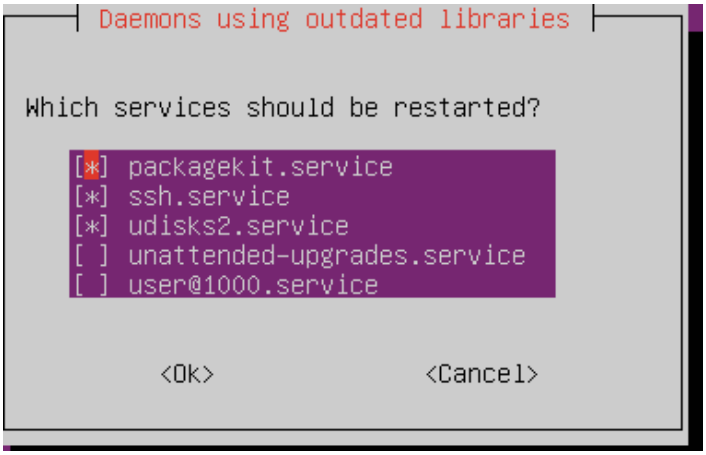
Proceso de confirmación de Ubuntu para continuar



Nota: Si el sistema operativo Ubuntu nos pide confirmación para continuar. Escribimos S y damos enter

Figura 31.

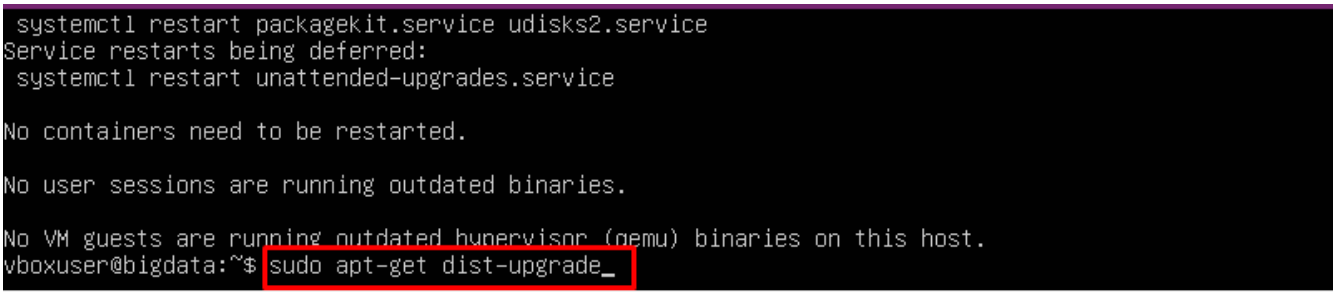
Confirmación de reinicio de servicios de Ubuntu



Nota: Seleccionamos OK y Enter

Figura 32.

Actualización de Ubuntu mediante el comando dist-upgrade



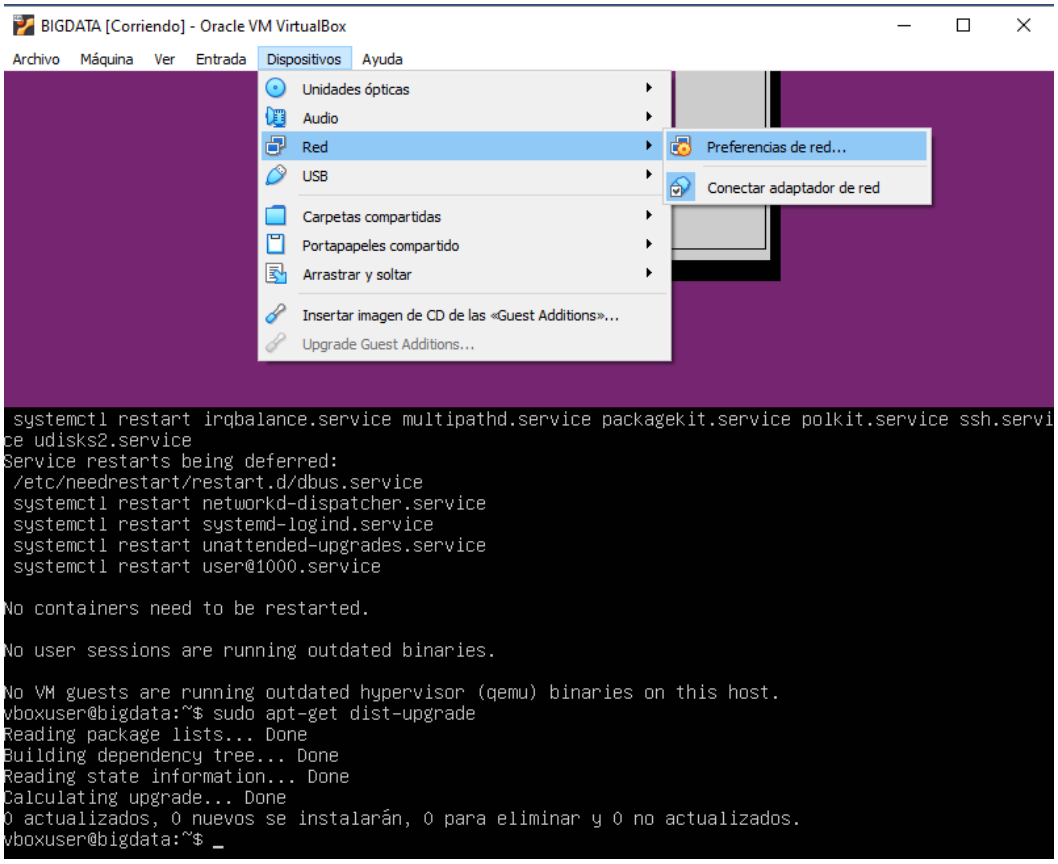
Nota: Validar si existen actualizaciones pendientes de realizar en el sistema operativo Ubuntu mediante el comando “sudo apt-get dist-upgrade”. Si hay paquetes a actualizar se debe teclear S y luego enter.

Conexión por SSH (putty) al servidor Ubuntu

Iniciamos el proceso de configuración para lograr la conexión a la máquina virtual de Ubuntu desde el software Putty.

Figura 33.

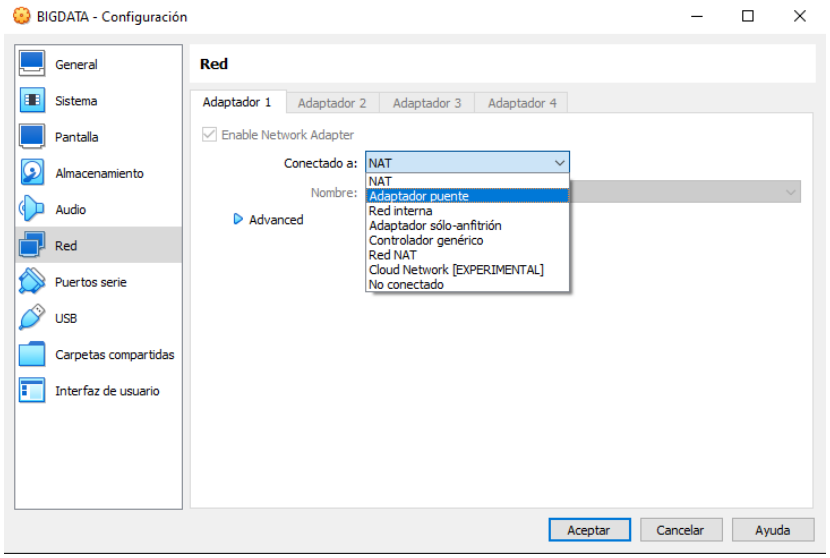
Configuración de red del VirtualBox



Nota: En VirtualBox ingresamos en Dispositivos – Red - Preferencias de red.

Figura 34.

Configuración de adaptador de red de VirtualBox



Nota: Cambiar “NAT” por “Adaptador puente” y aceptar. Se debe seleccionar la tarjeta de red que tenga conectada a internet

Figura 35.

Reinicio del sistema operativo Ubuntu

```
 systemctl restart irqbalance.service multipathd.service packagekit.service polkit.service ssh.servi
ce udisks2.service
Service restarts being deferred:
 /etc/needrestart/restart.d/dbus.service
 systemctl restart networkd-dispatcher.service
 systemctl restart systemd-logind.service
 systemctl restart unattended-upgrades.service
 systemctl restart user@1000.service

No containers need to be restarted.

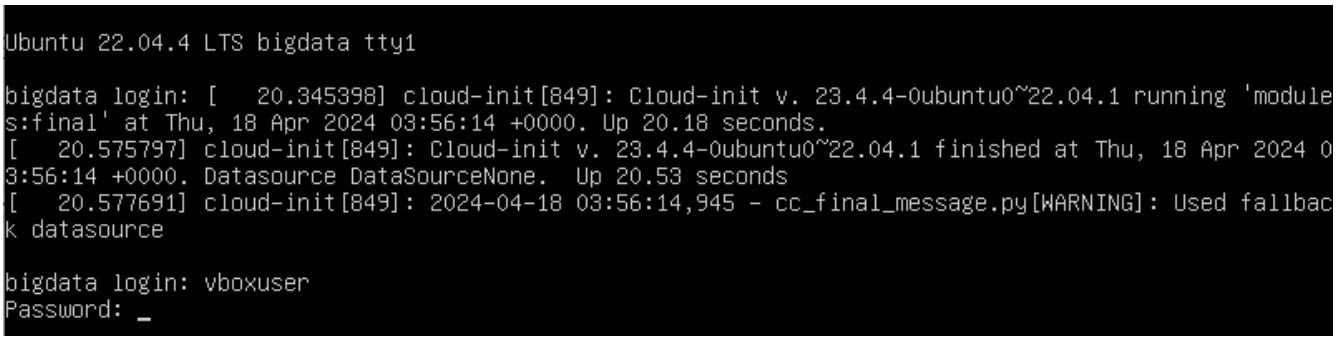
No user sessions are running outdated binaries.

No VM guests are running outdated hypervisor (qemu) binaries on this host.
vboxuser@bigdata:~$ sudo apt-get dist-upgrade
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
Calculating upgrade... Done
0 actualizados, 0 nuevos se instalarán, 0 para eliminar y 0 no actualizados.
vboxuser@bigdata:~$ reboot
```

Nota: Reiniciar la máquina virtual por medio del comando “reboot” y luego enter para que cambie la dirección IP asignada,

Figura 36.

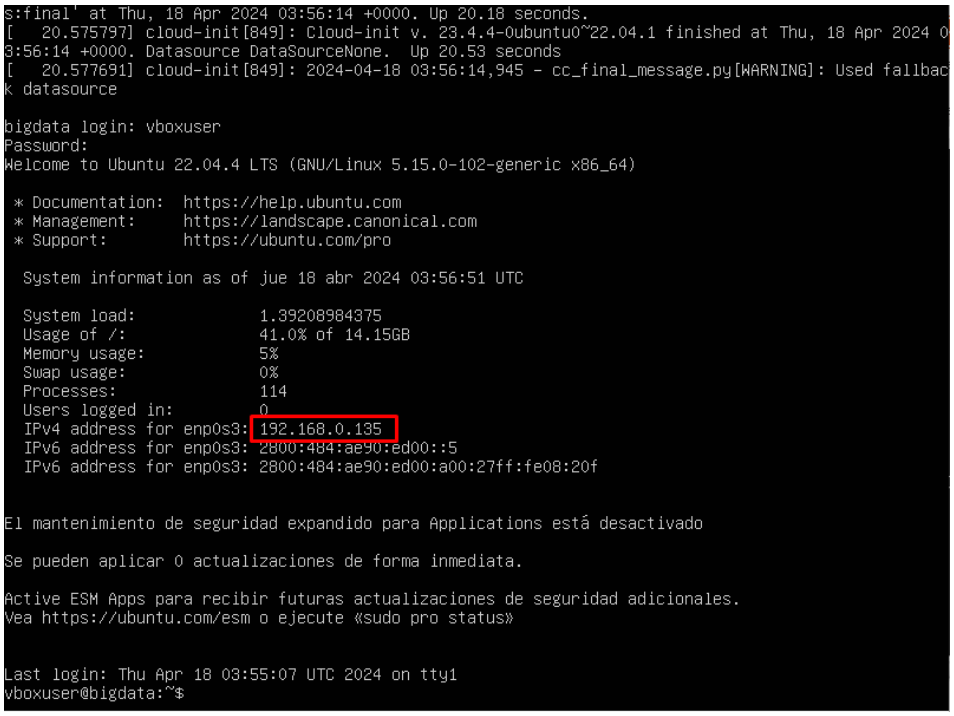
Inicio de sesión en Ubuntu



Nota: Luego de reiniciar la maquina virtual con el sistema operativo Ubuntu instalado, procedemos a iniciar sesión con el usuario “vboxuser” y la contraseña “bigdata”.

Figura 37.

Asignación de IP de la máquina virtual



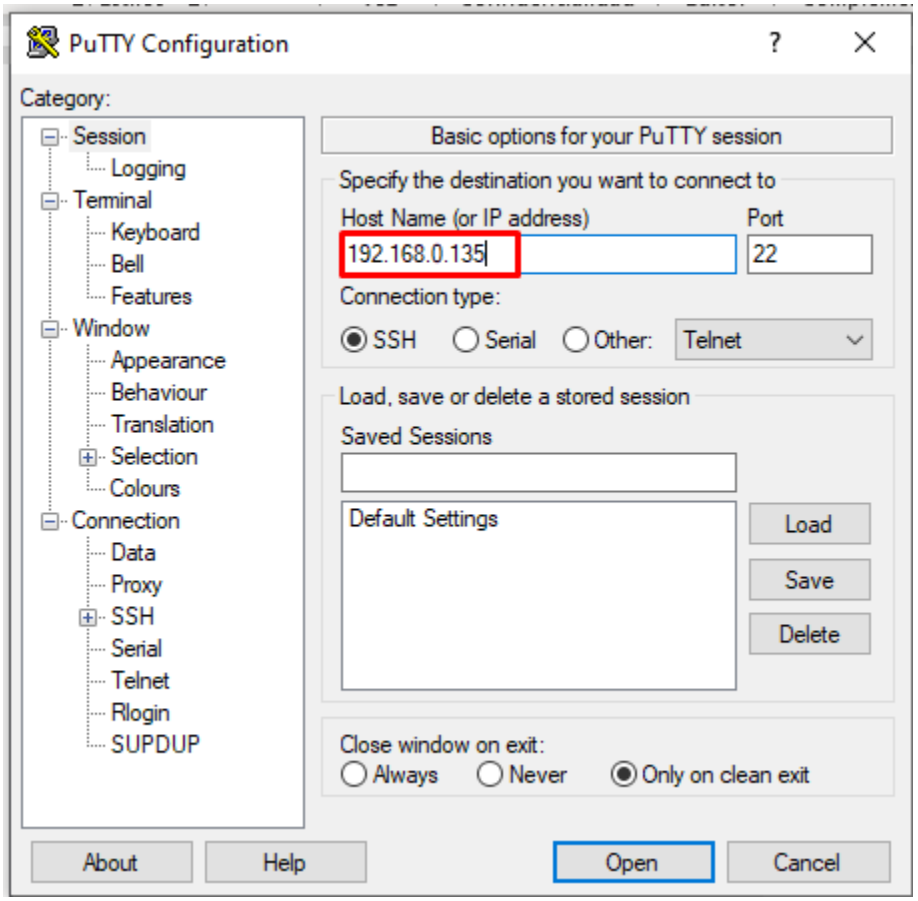
Nota: Tomar nota de la IP asignada a la máquina virtual, ya que con esta IP nos conectaremos de forma remota a la máquina virtual. Tener presente que cada vez que se reinicie la máquina virtual la IP puede cambiar.

Putty

Descagar el software Putty por medio del link https://the.earth.li/~sgtatham/putty/latest/w64/putty.exe, luego, ejecutamos el archivo descargado con el nombre “putty.exe”

Figura 38.

Configuración del Putty



Nota: Colocar la IP que nos asignó la máquina virtual Ubuntu y damos click en el botón “Open” y luego dar click en “Accept”

Si al reiniciar la máquina virtual donde instalamos el sistema operativo Ubuntu no logras obtener una dirección IP para hacer la conexión por el Putty, debes ejecutar el siguiente comandos y volver a reiniciar la máquina virtual

- sudo apt update
- sudo apt install openssh-server

Para validar que el servicio se esté ejecutando correctamente

- sudo systemctl status ssh

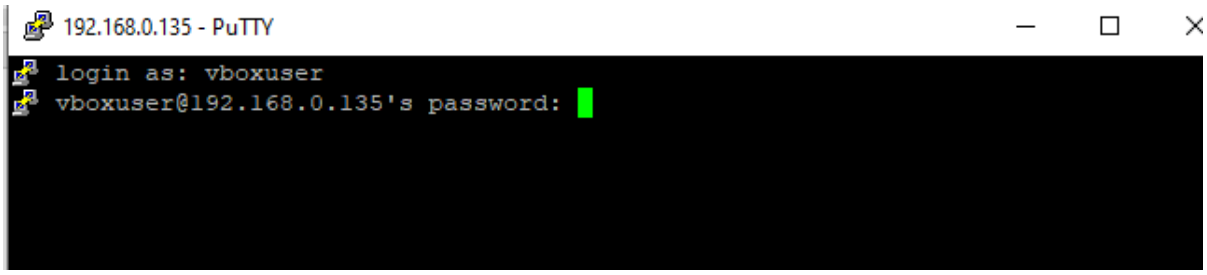
Deberías ver un estado que diga Active: active (running)

luego

- reboot

Figura 39.

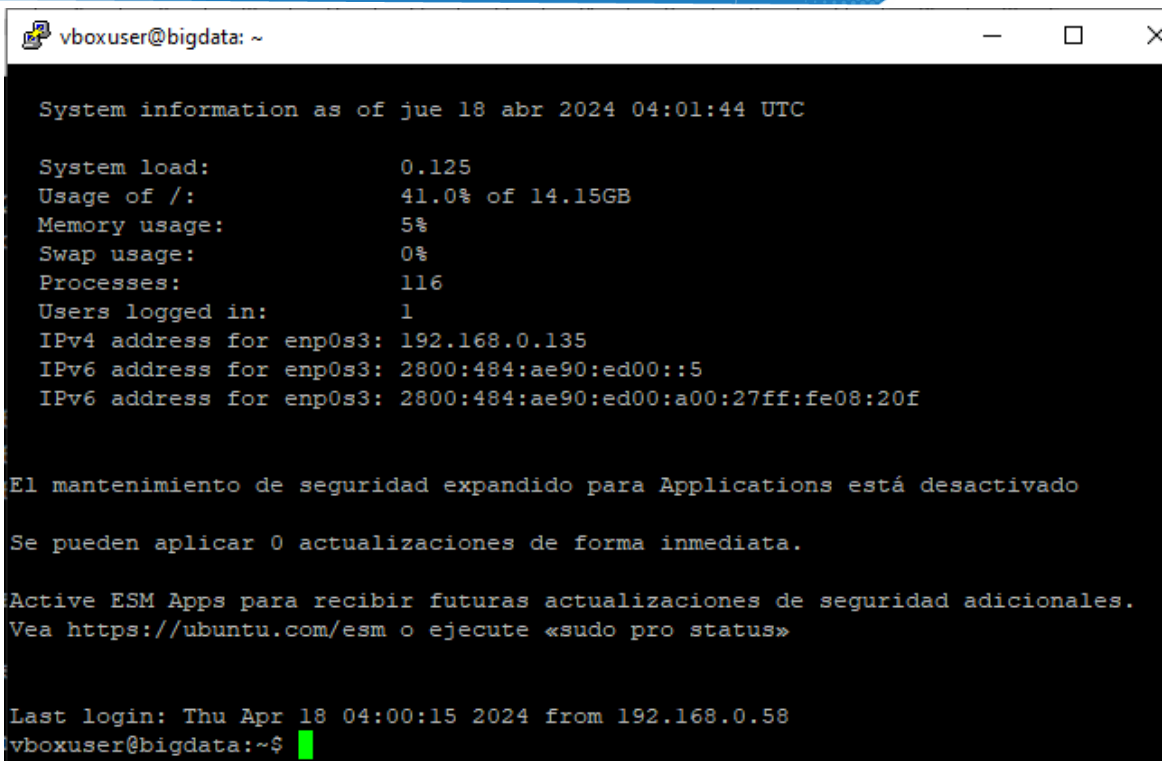
Inicio de sesión por Puttty



Nota: Si logramos la conexión exista entre el Putty y la máquina virtual donde tenemos instalado el sistema operativo Ubuntu procedemos a iniciar sesión con usuario “vboxuser” y contraseña “bigdata”

Figura 40.

Inicio de sesión exitosa en Ubuntu



Nota: De esta forma tenemos conexión remota por SSH a la consola de nuestra máquina virtual Ubuntu, para copiar y pegar a la consola debemos seleccionar el texto a copiar en el documento o página de origen dar CRTL+C o click derecho y copiar y luego en la consola de putty dar click derecho donde queremos pegar el texto seleccionado.

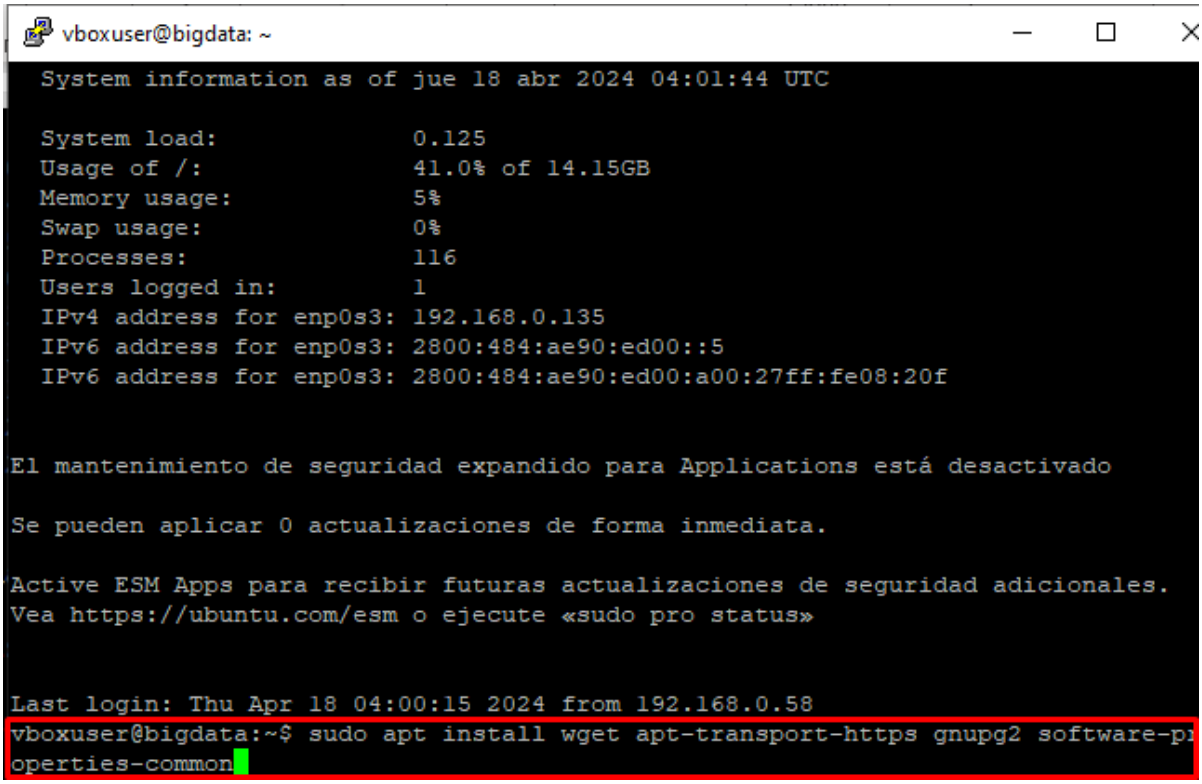
INSTALAR HADOOP

Link de referencia

https://tecadmin.net/how-to-install-apache-hadoop-on-ubuntu-22-04/

Figura 41.

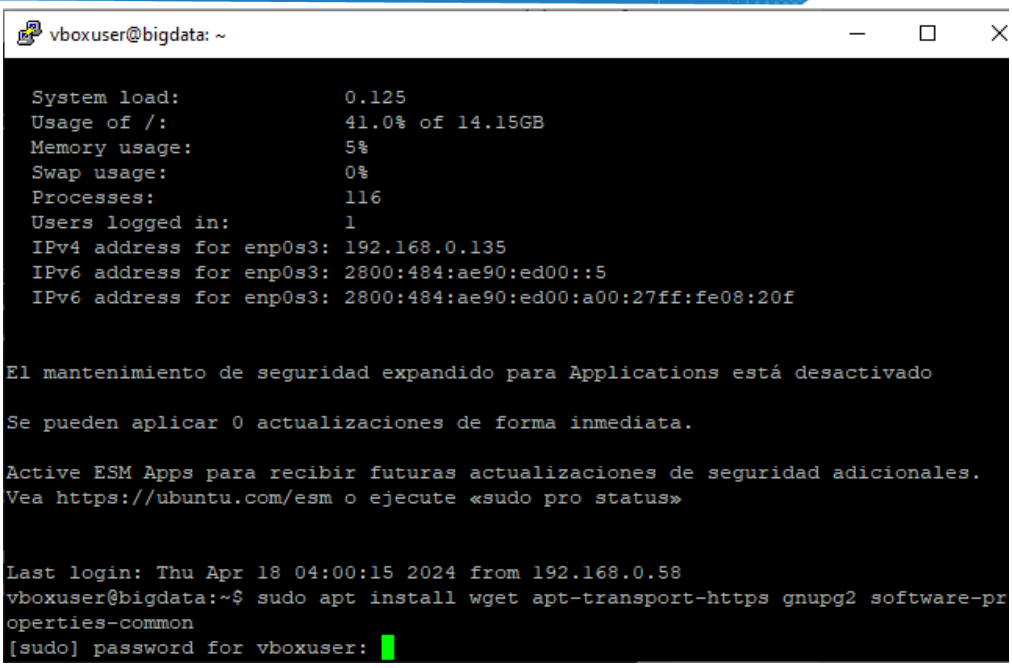
Instalación de dependencias en Ubuntu



Nota: Instalación de dependencias en Ubuntu por medio del comando “sudo apt install wget apt-transport-https gnupg2 software-properties-common”.

Figura 42.

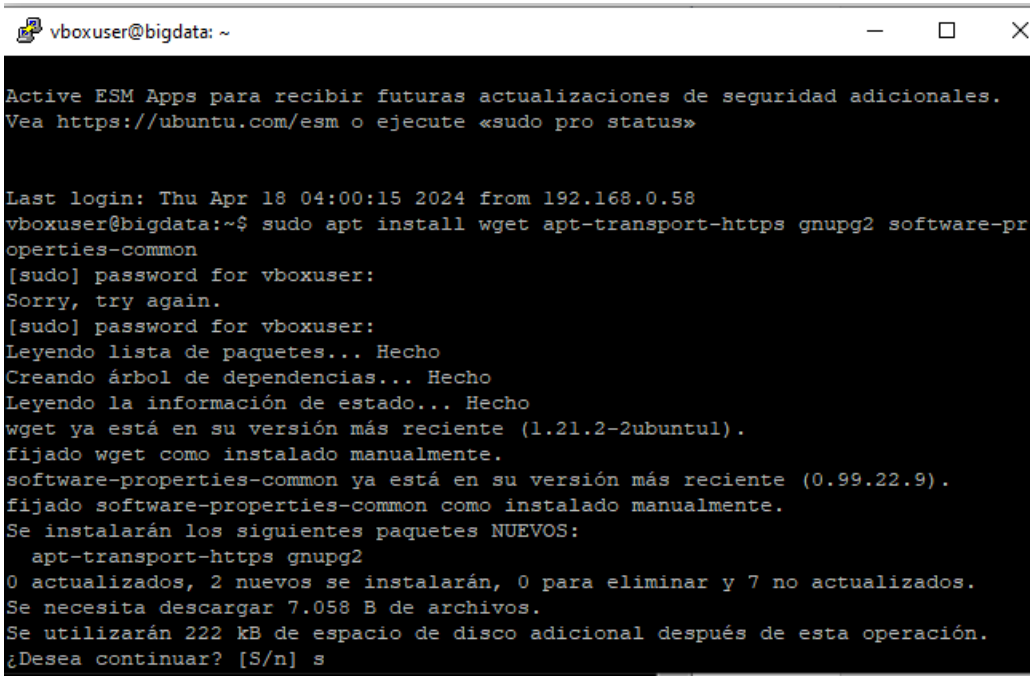
Solicitud de contraseña en Ubuntu



Nota: Si solicita contraseña “bigdata”

Figura 43.

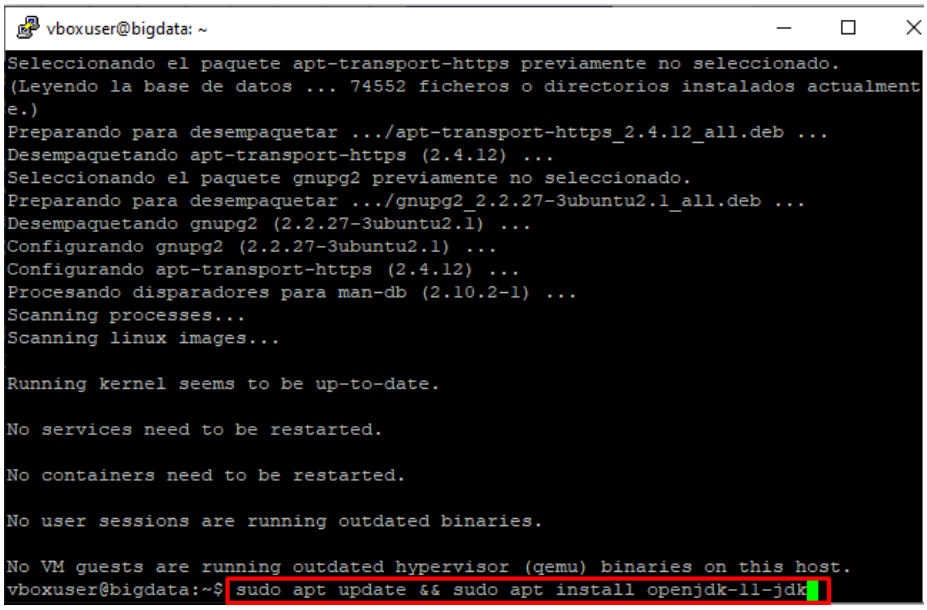
Confirmación de instalación en Ubuntu



Nota: Si solicita confirmación para la instalación, damos S y enter

Figura 44.

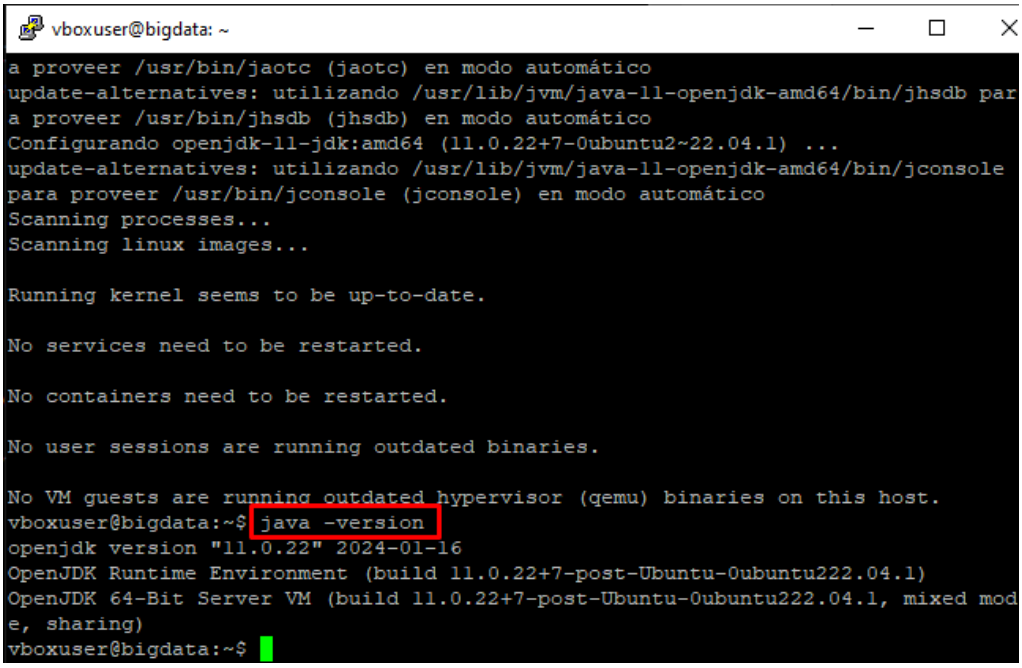
Instalación de Java Development Kit



Nota: Instalación de Java Development Kit por medio del comando “sudo apt update && sudo apt install openjdk-11-jdk”. Si solicita confirmación si desea continuar, damos S y enter.

Figura 45.

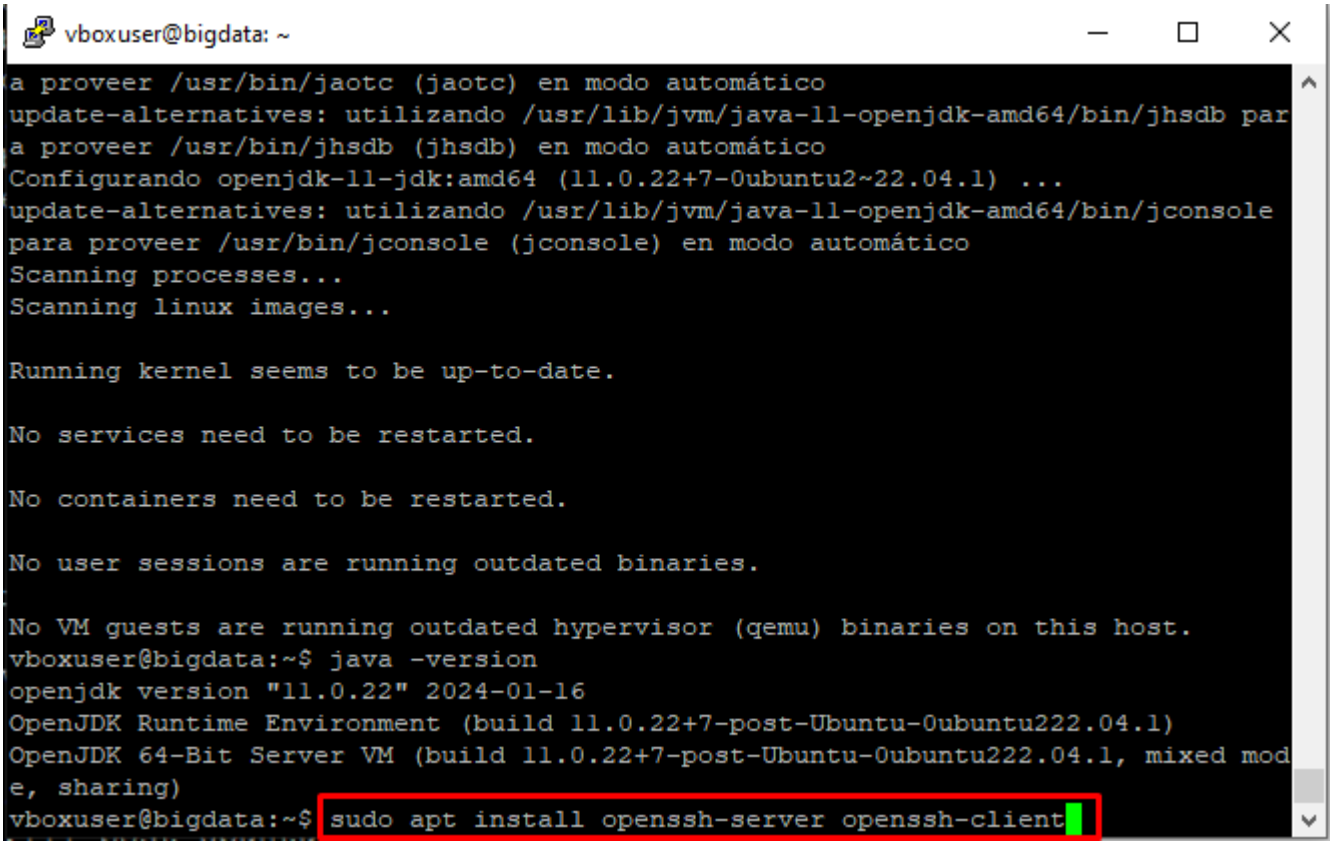
Verificación de la versión de Java instalada



Nota: Para validar que Java se instaló de manera correcta y verificar la versión instalada, usamos el comando “java -version”.

Figura 46.

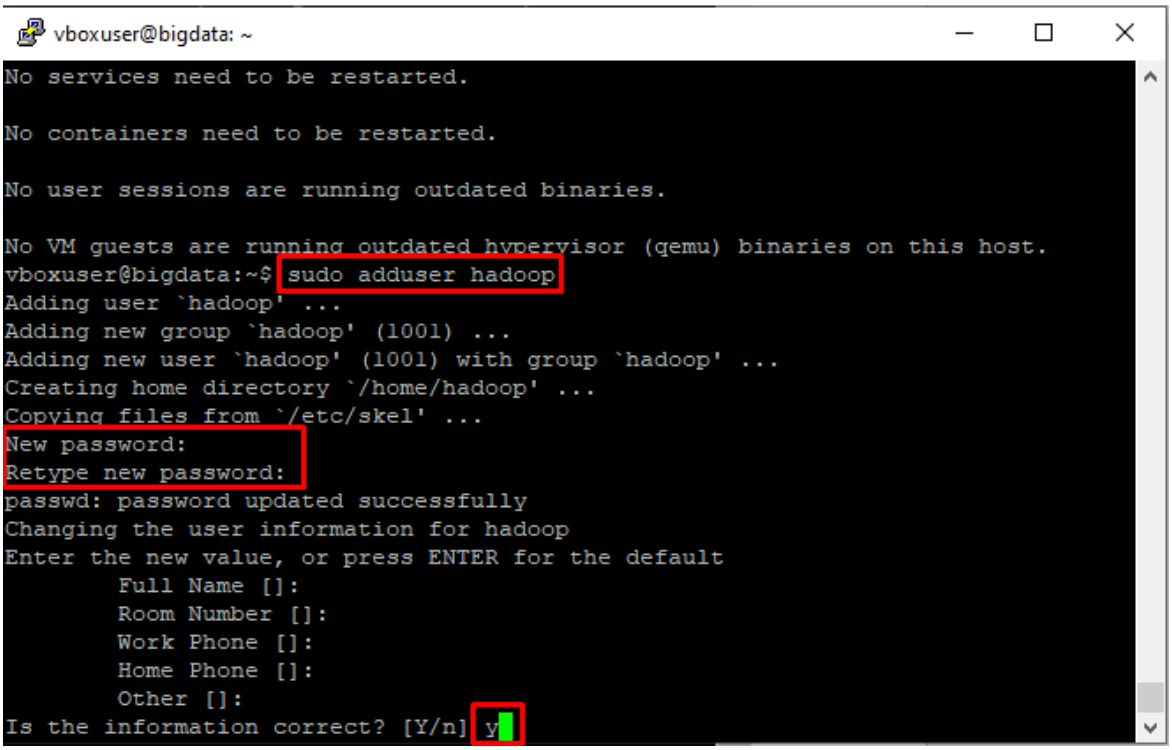
Instalación del openssh



Nota: Se realiza el proceso de instalación del openssh mediante el comando “sudo apt install openssh-server openssh-client”.

Figura 47.

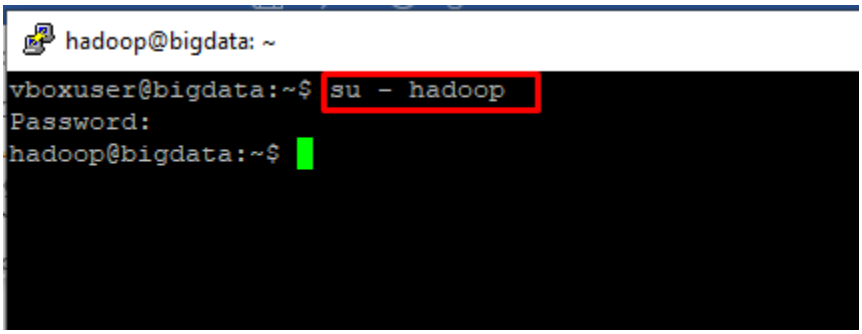
Creación de nuevo usuario "hadoop"



Nota: Creación de nuevo usuario “hadoop” en la máquina virtual de Ubuntu mediante el comando “sudo adduser hadoop” y asignación de contraseña “hadoop”. En los siguientes campos no digitamos nada, damos enter (Full Name []:, Room Number []:, Work Phone []:, Home Phone []:, Other []:) y para finalizar y confirmar digitamos Y

Figura 48.

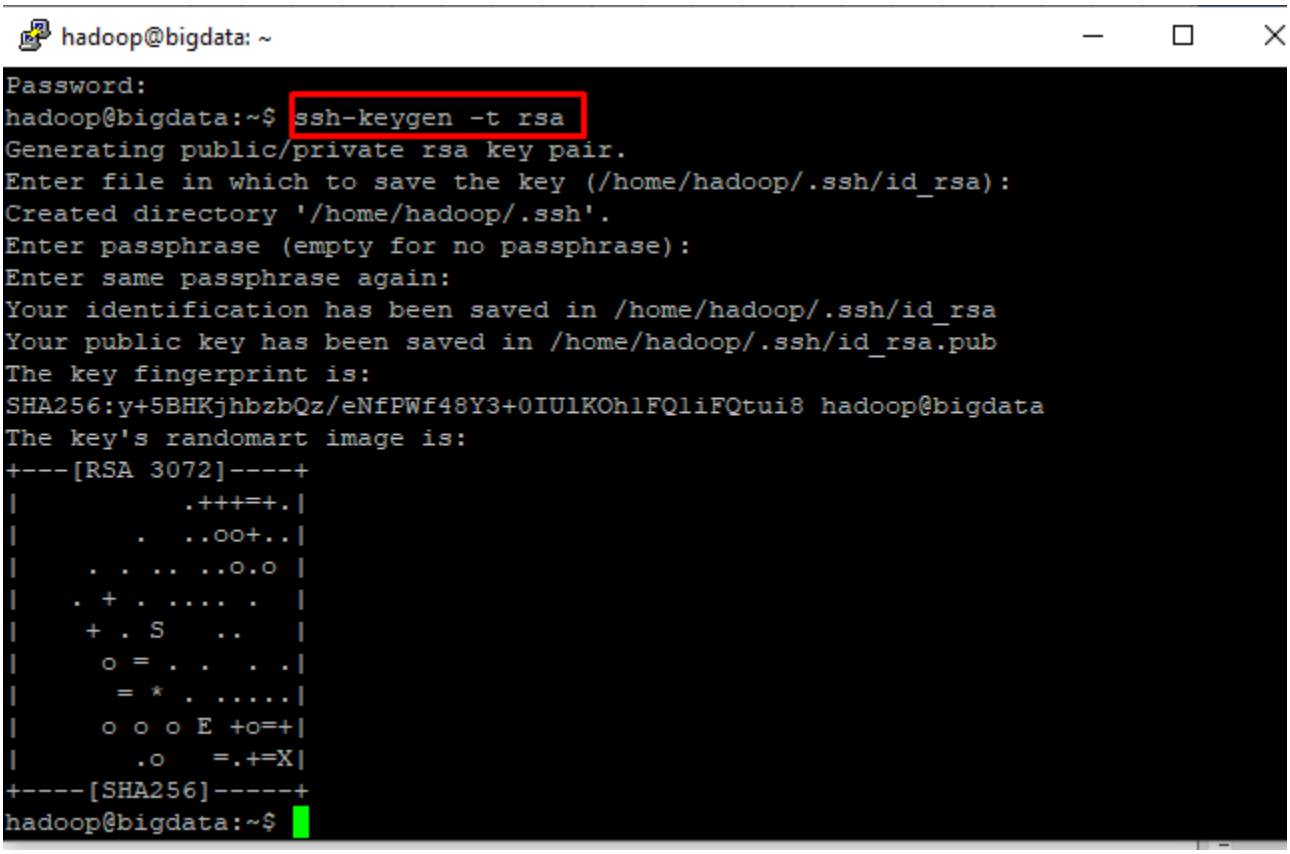
Cambio de inicio de sesión a usuario hadoop



Nota: Cambiamos al usuario recién creado anteriormente en la máquina virtual por medio del comando “su - hadoop” y confirmamos con la contraseña asignada “hadoop”.

Figura 49.

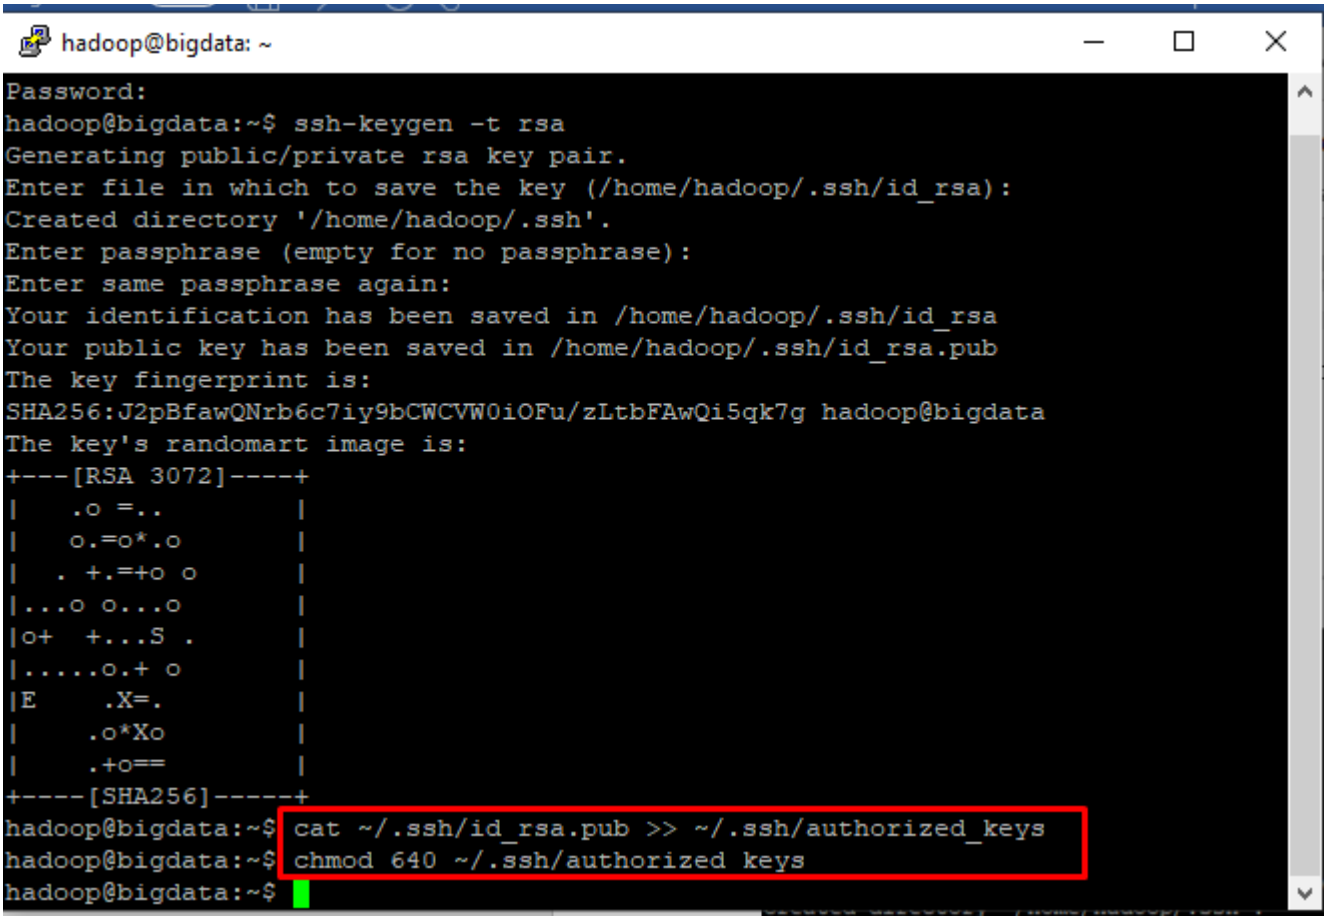
Generación de llaves SSH



Nota: Ahora configuramos el acceso SSH sin contraseña para el usuario “hadoop”. Genere primero un par de claves SSH mediante el comando “ssh-keygen -t rsa” y a las preguntas damos solo enter.

Figura 50.

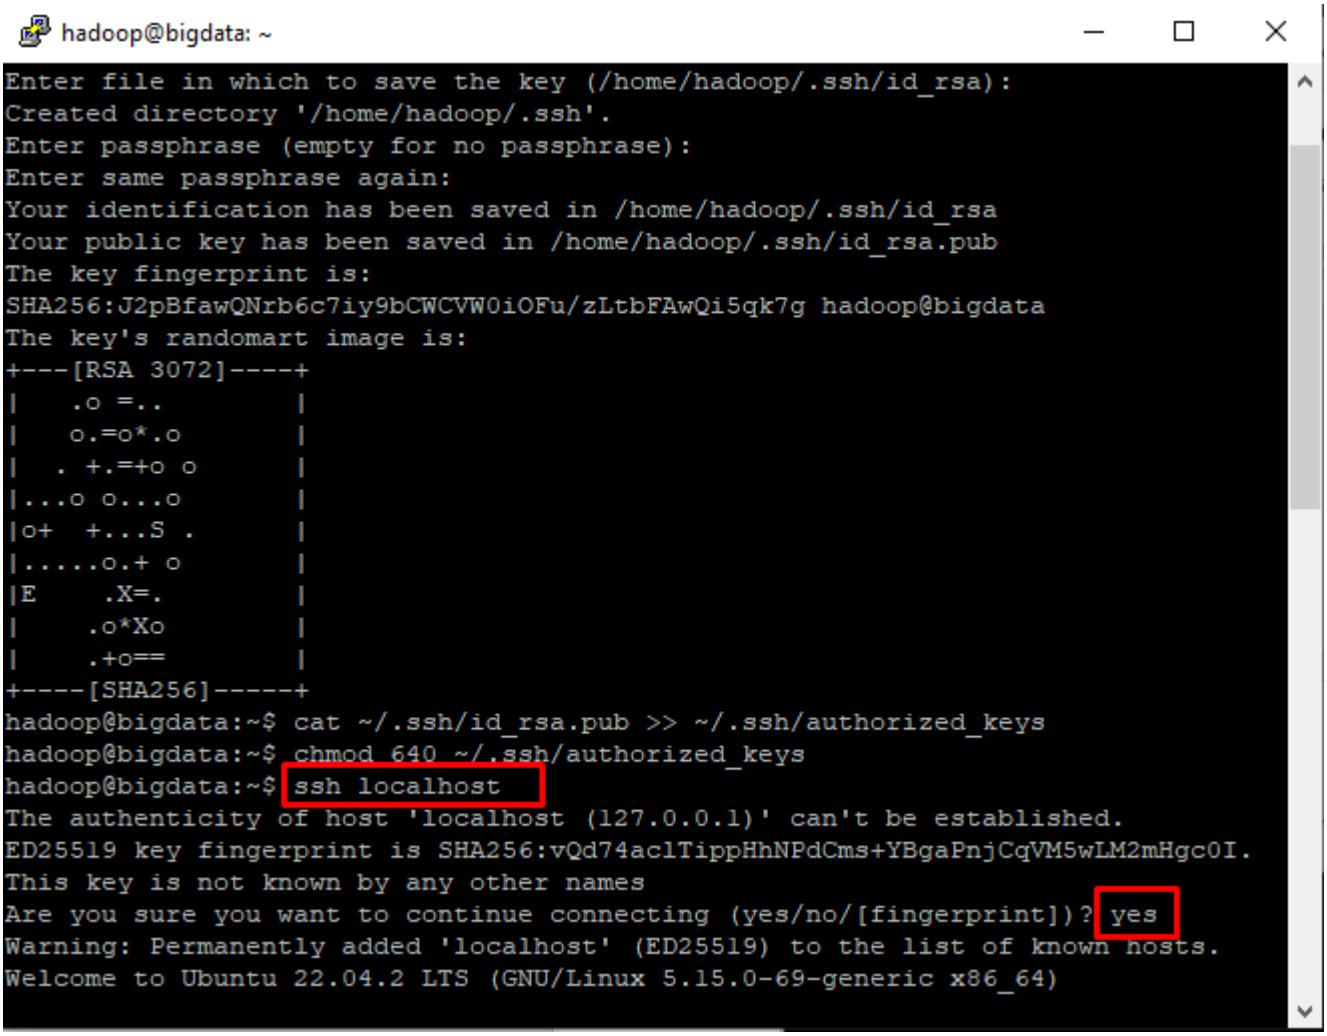
Copia de llaves públicas generadas



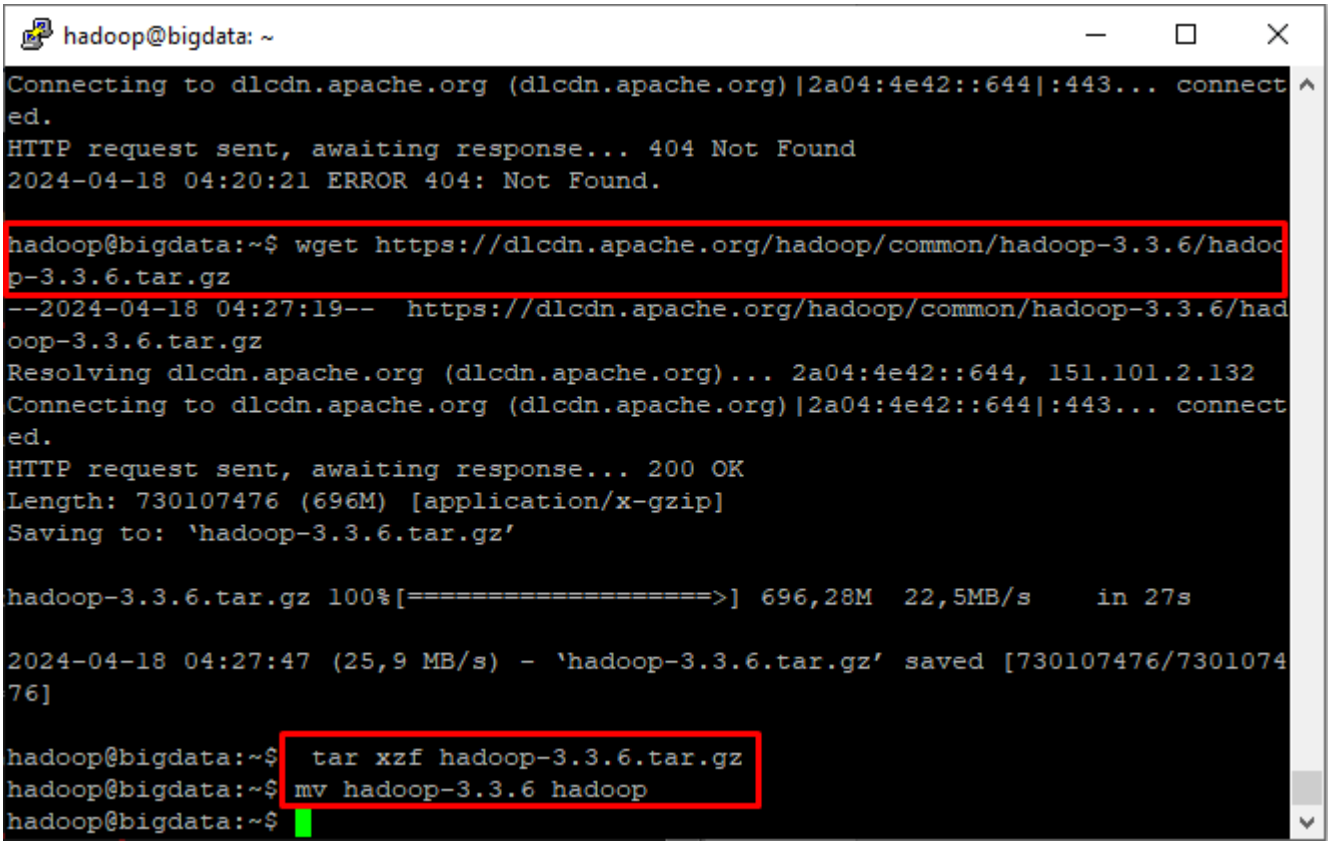
Nota: Copiamos la clave pública generada en el archivo de clave autorizada y establezca los permisos adecuados mediante el comando “cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys” y luego con el commando “chmod 640 ~/.ssh/authorized_keys”.

Figura 51.

Asignación de SSH en el localhost



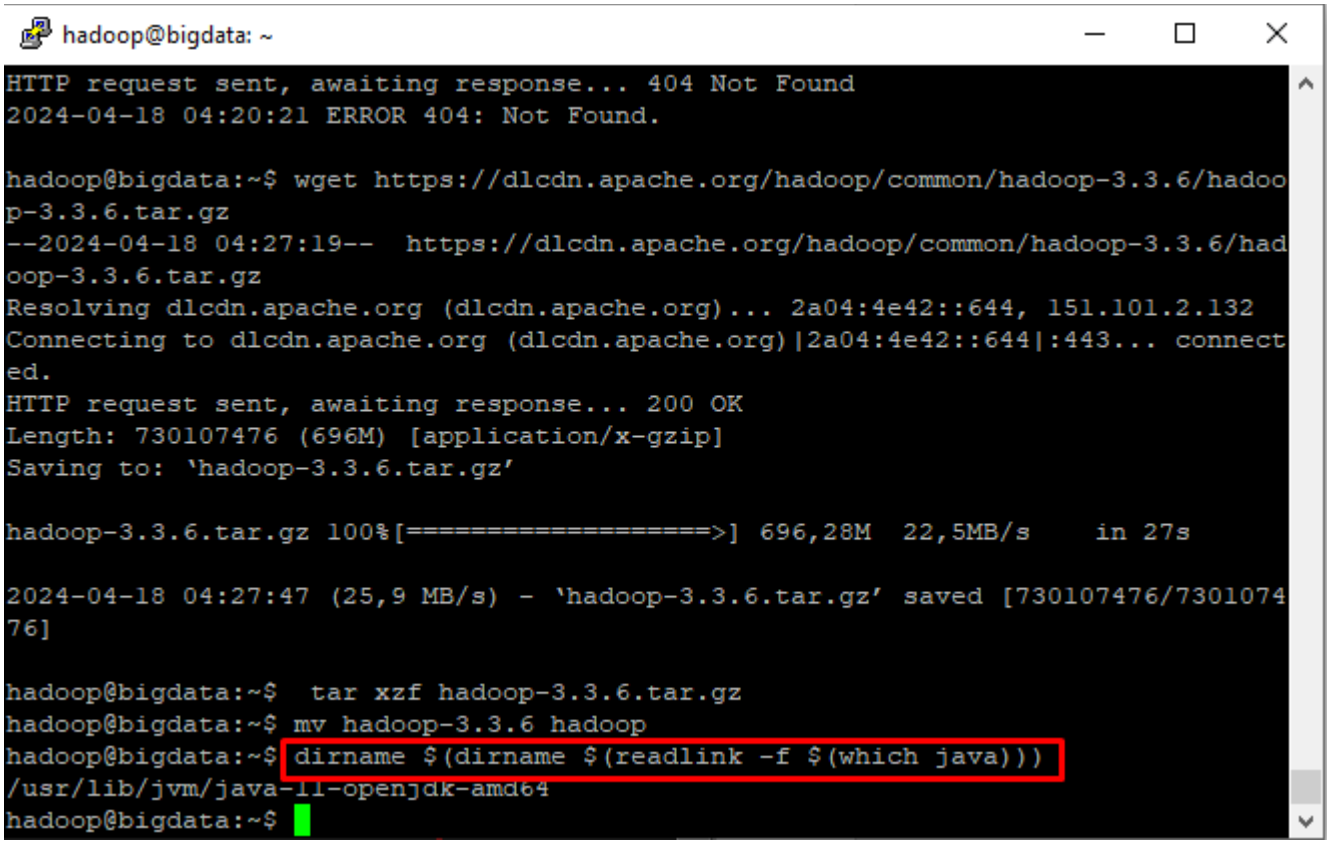
Nota: Ahora se le pedirá que autentique los hosts agregando claves RSA a hosts conocidos mediante el comando “ssh localhost” y luego escriba “yes” para confirmar y presione Enter para autenticar el localhost



Nota: Iniciamos la descarga de hadoop usando el comando “wget https://dlcdn.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz”, luego usamos el comando para descomprimir la carpeta descargada “tar xzf hadoop-3.3.6.tar.gz” y por último usamos el comando “mv hadoop-3.3.6 hadoop” para cambiarle el nombre a la carpeta. Se debe validar que la versión 3.3.6 de hadoop siga disponible en la pagina web consultando la url de descarga.

Figura 52.

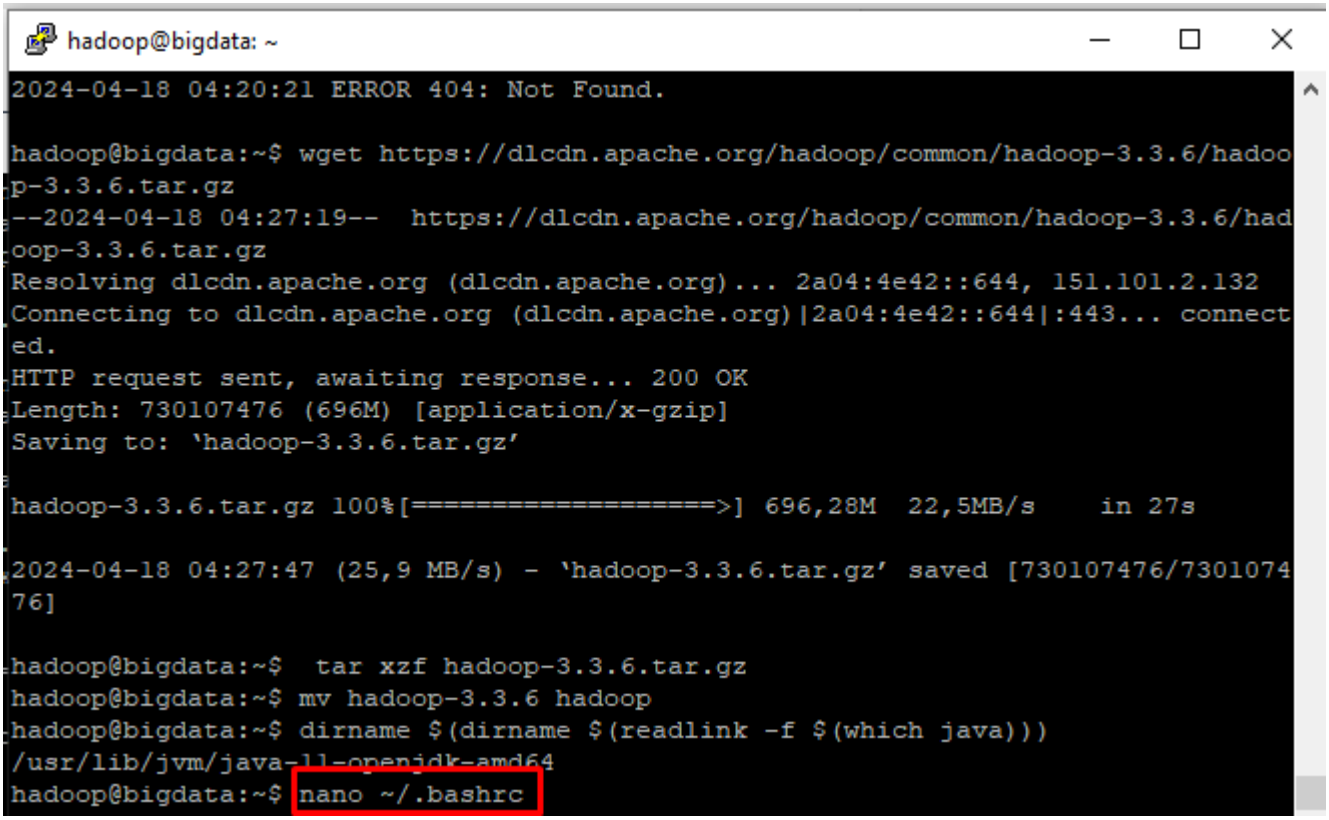
Configuración de variables JAVA en Hadoop



Nota: Configurar Hadoop y Java Environment variables en su sistema. Puede encontrar la ubicación de JAVA_HOME ejecutando el comando “dirname $(dirname $(readlink -f $(which java)))”

Figura 53.

Configuración de archivo .bashrc



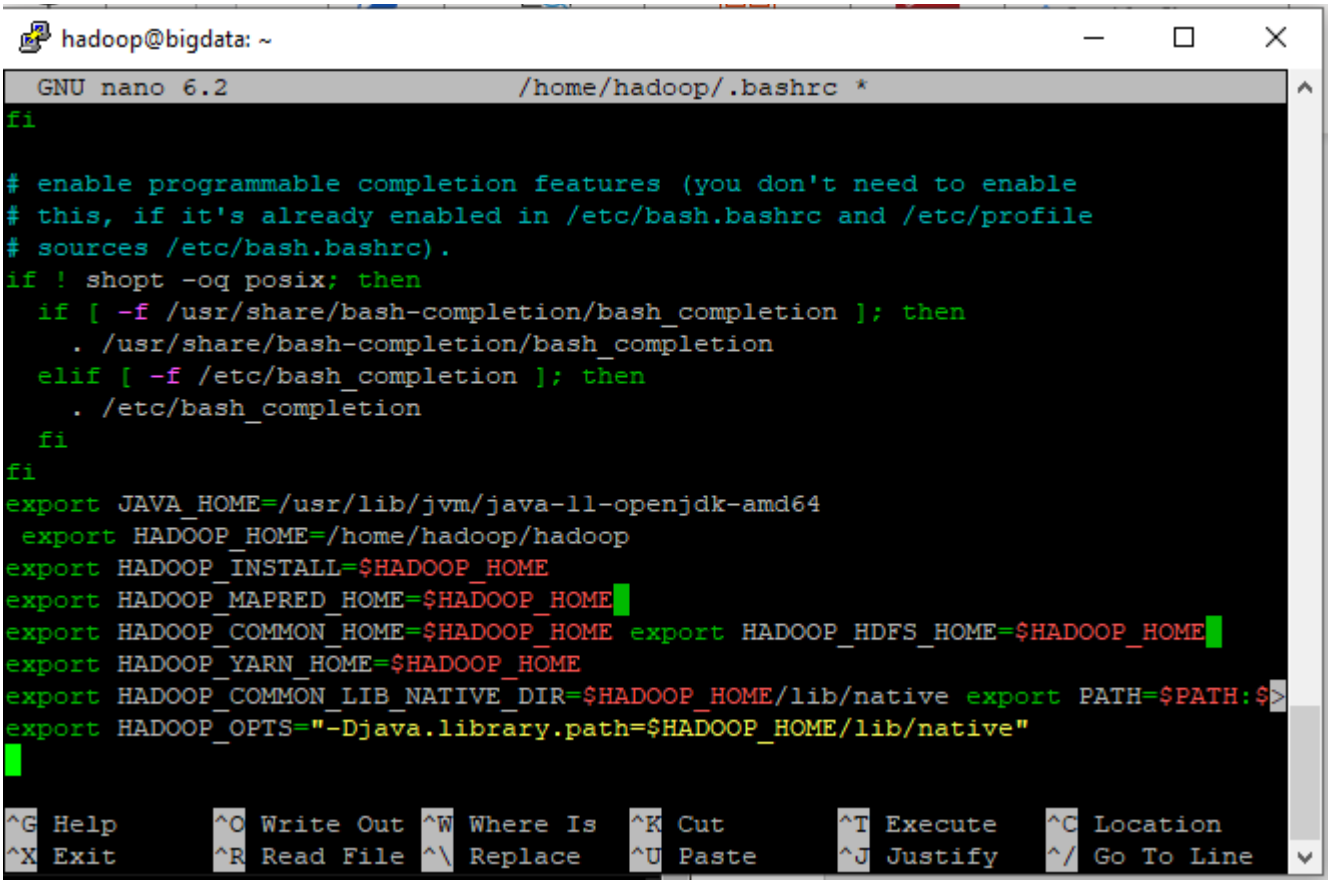
Nota: Abra el archivo ~/.bashrc en su editor de texto usando el comando “nano ~/.bashrc”.

Anexe las líneas siguientes al final del archivo.

export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export HADOOP_HOME=/home/hadoop/hadoop
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export HADOOP_YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/nativeexport
PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"

Figura 54.

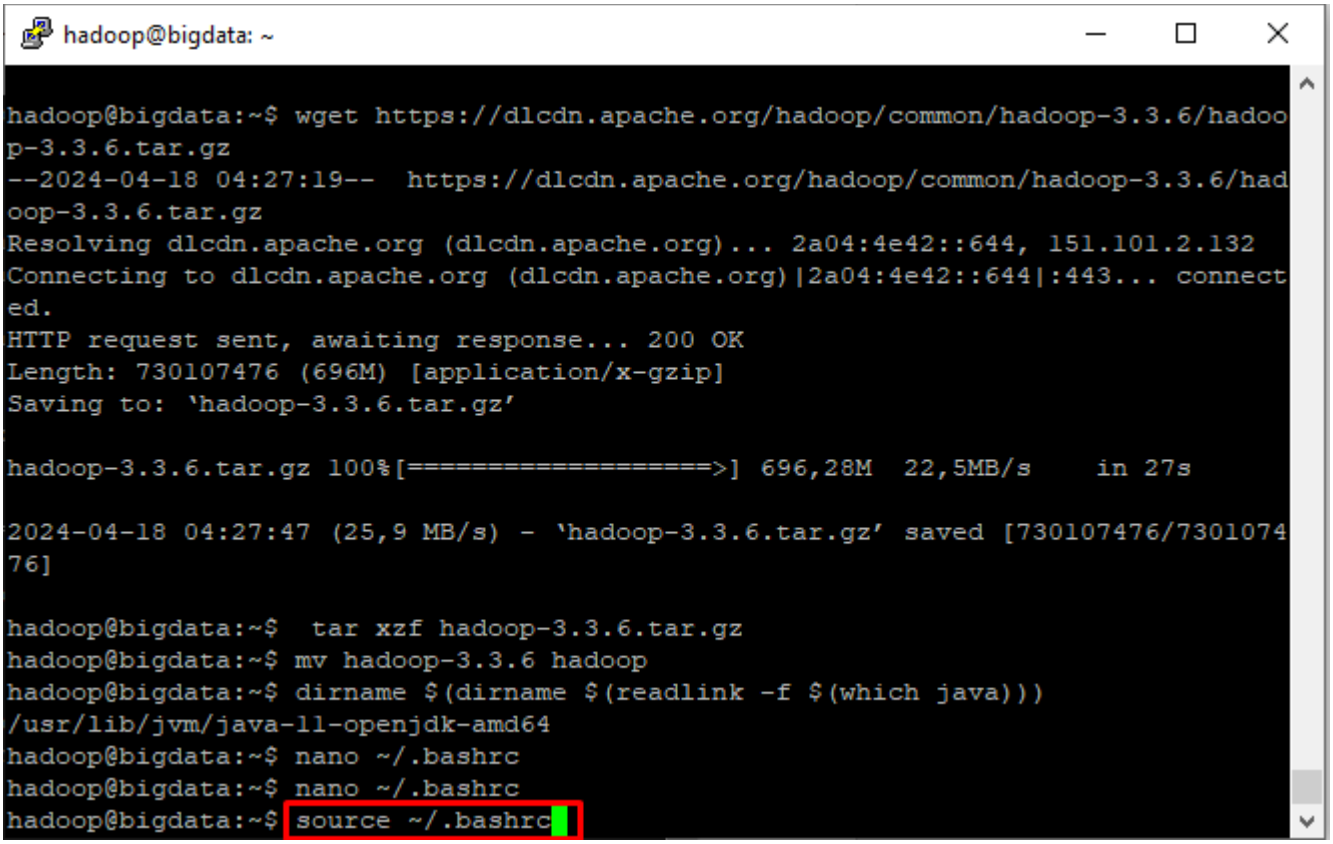
Configuración de variables en el archivo .bashrc



Nota: copiar las líneas y dar Crtl+O enter y luego Crtl+X para salir

Figura 55.

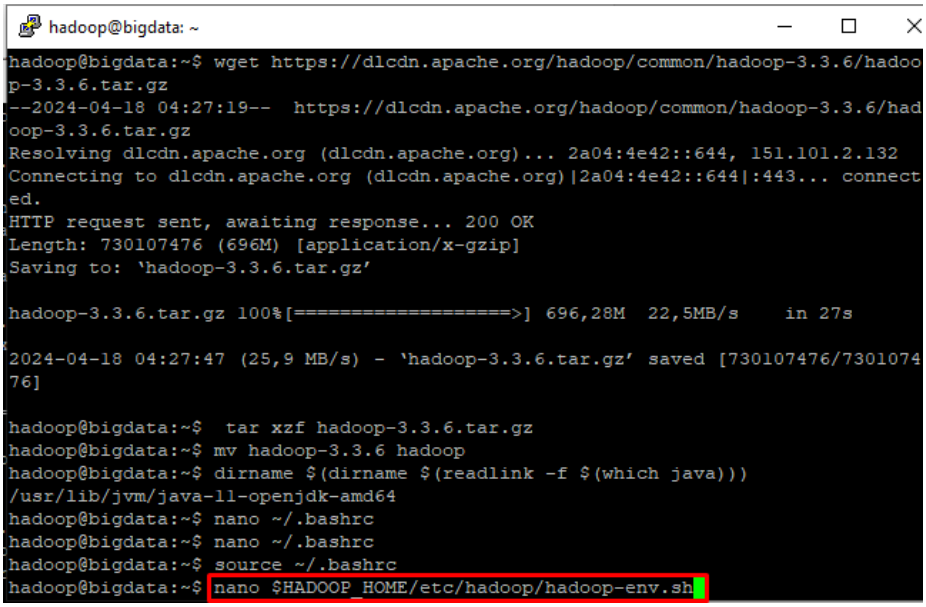
Cargue de configuración de archivo .bashrc



Nota: Cargue la configuración anterior del archivo .bashrc en el entorno actual usando el comando “source ~/.bashrc”

Figura 56.

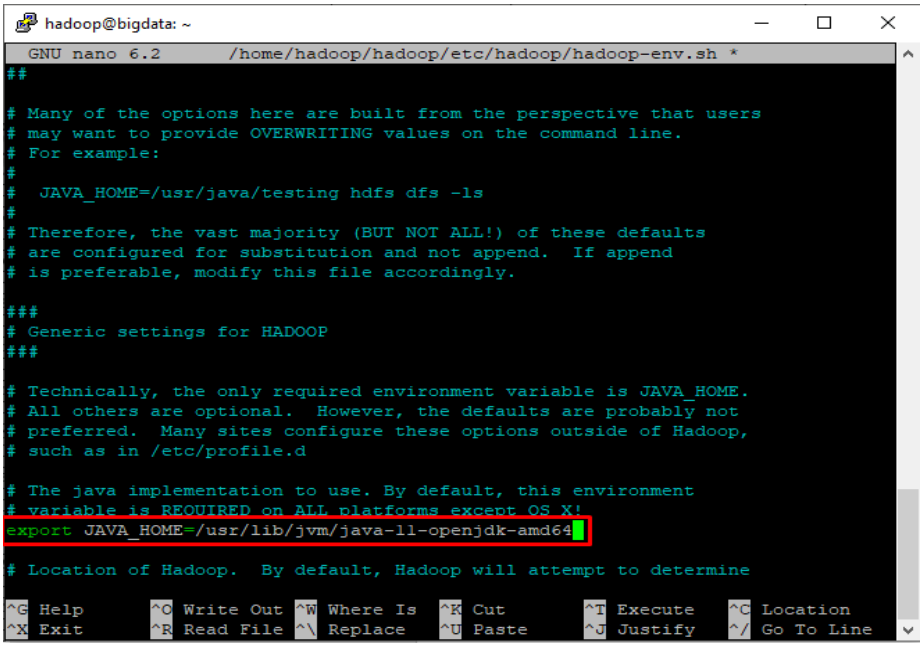
Configuración de archivo hadoop-env.sh



Nota: Abrir el archivo hadoop-env.sh usando el comando “nano $HADOOP_HOME/etc/hadoop/hadoop-env.sh”.

Figura 57.

Configuración de la variable JAVA_HOME del archivo hadoop-env.sh

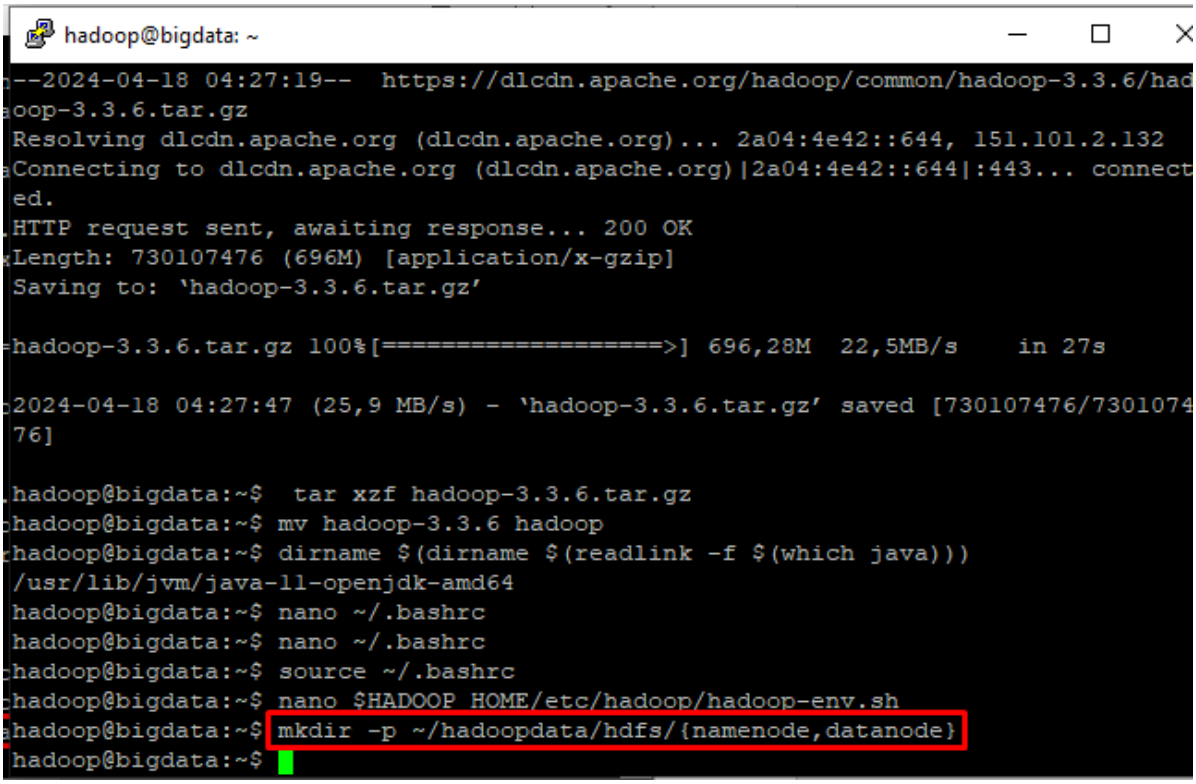


Nota: Configurar la variable JAVA_HOME en el archivo hadoop-env.sh. Buscar “export JAVA_HOME” y quitar el # del inicio, debe quedar export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64

dar Crtl+O enter y luego Crtl+X para salir

Figura 58.

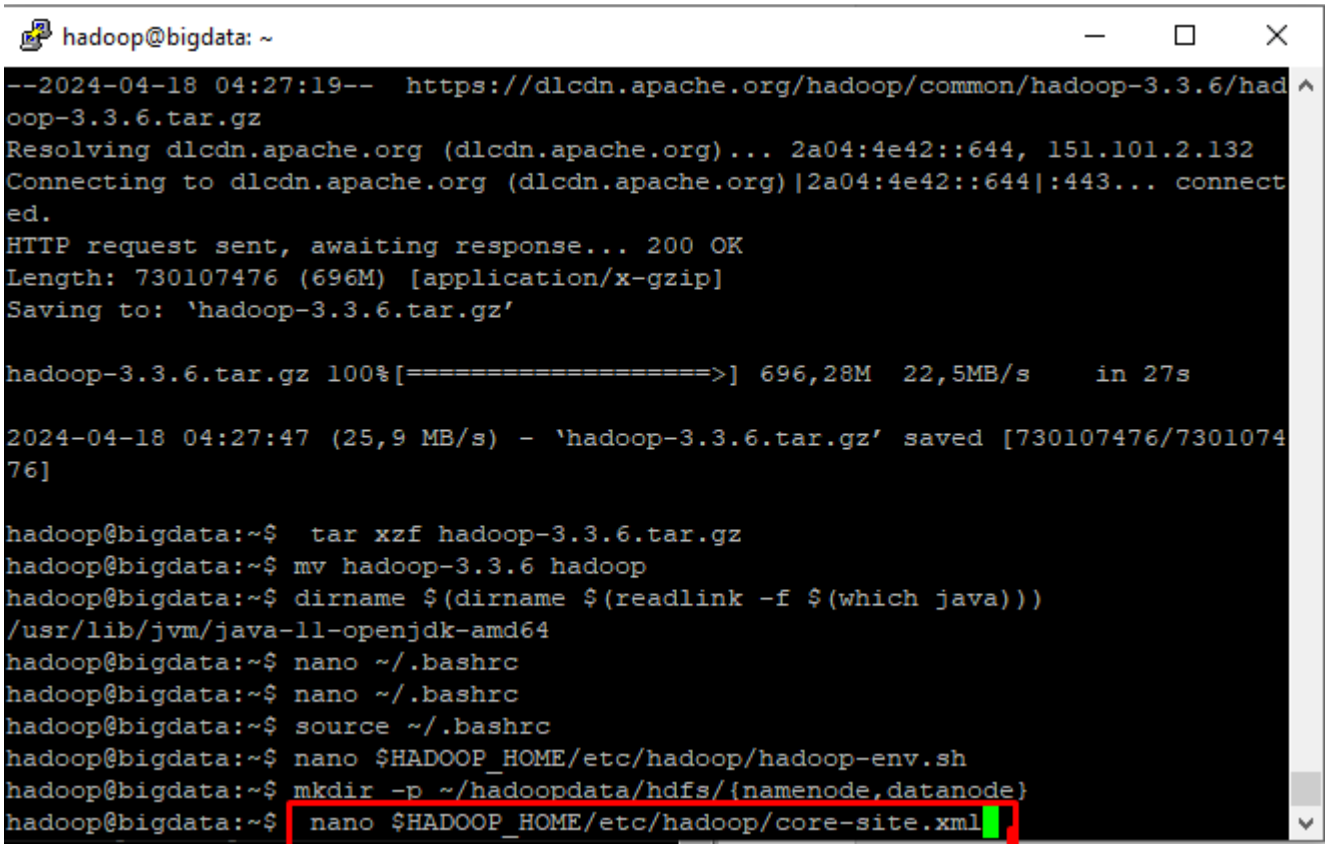
Creación de directorios namenode y datanode



Nota: Se debe crear los directorios namenode y datanode dentro del directorio de inicio de usuario hadoop. Ejecute el siguiente comando para crear ambos directorios “mkdir -p ~/hadoopdata/hdfs/{namenode,datanode}”

Figura 59.

Configuración del archivo core-site.xml



Nota: Edite el archivo core-site.xml y actualice con el nombre de host de su sistema usando el comando “nano $HADOOP_HOME/etc/hadoop/core-site.xml”

Y agregamos al final del archivo:

<configuration>

<property>

<name>fs.defaultFS</name>

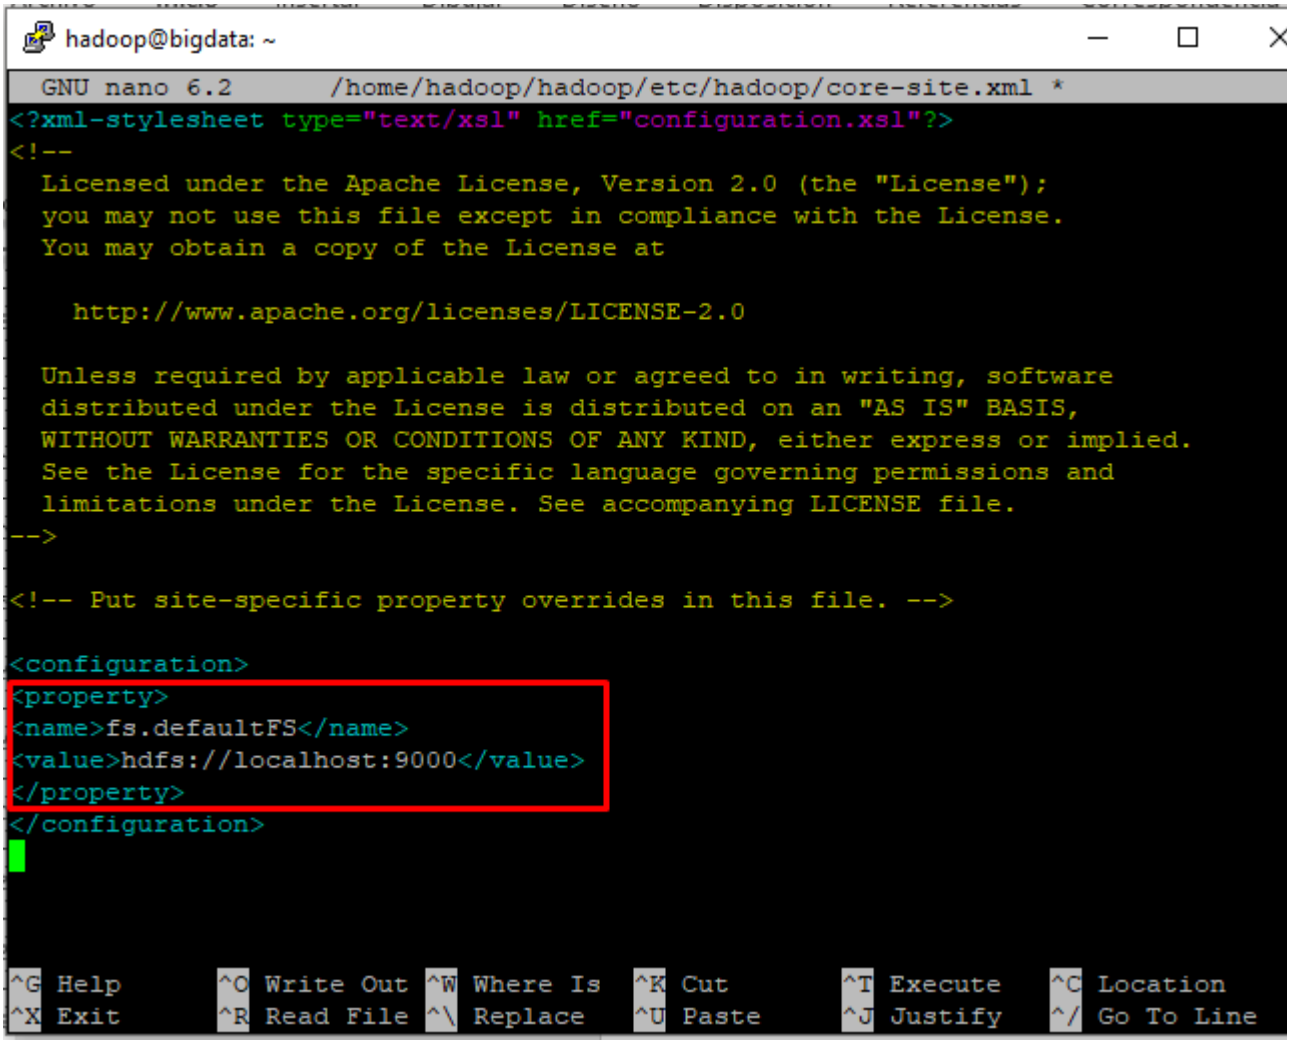
<value>hdfs://localhost:9000</value>

</property>

</configuration>

Figura 60.

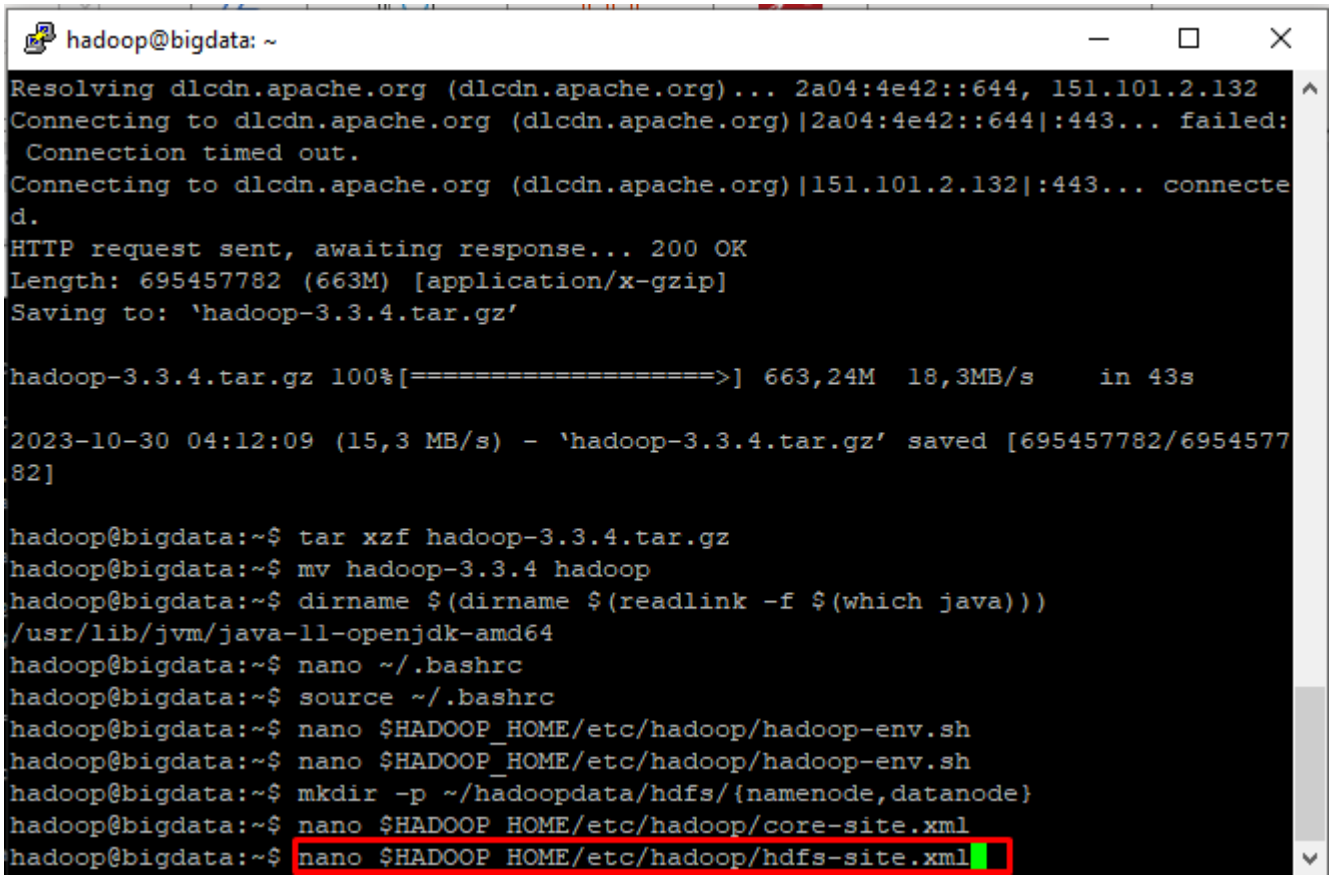
Configuración de variables en el archivo core-site.xml



Nota: Dar Crtl+O enter y luego Crtl+X para salir

Figura 61.

Configuración del archivo hdfs-site.xml



Nota: Edite el archivo hdfs-site.xml con el comando “nano $HADOOP_HOME/etc/hadoop/hdfs-site.xml”

Y agregamos:

<configuration>
<property>

<name>dfs.replication</name>

<value>1</value>

</property>

<property>

<name>dfs.name.dir</name>

<value>file:///home/hadoop/hadoopdata/hdfs/namenode</value>

</property>

<property>

<name>dfs.data.dir</name>

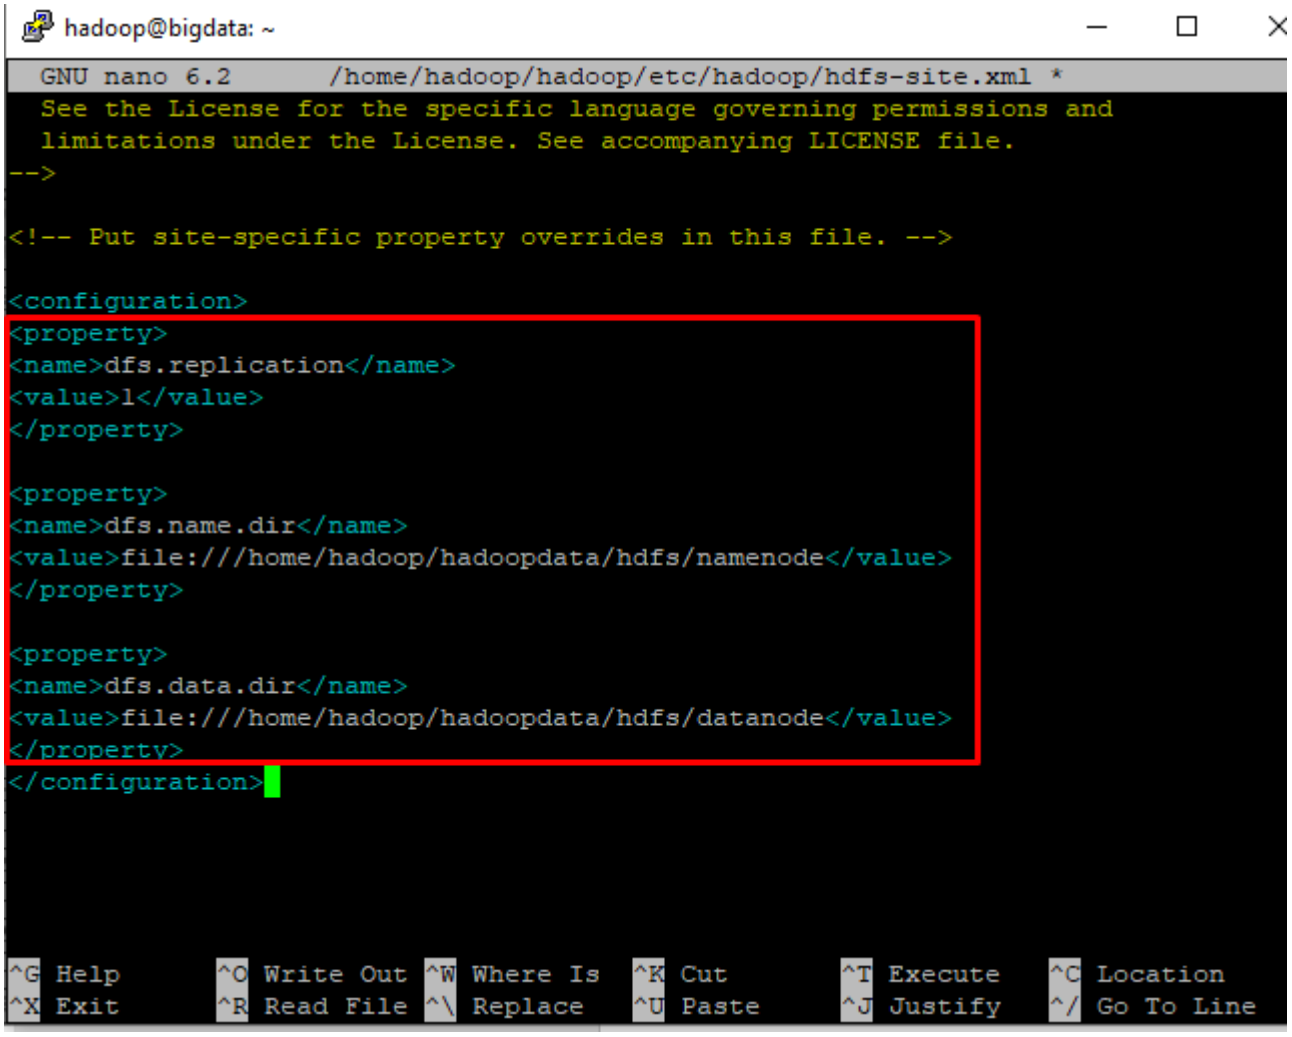
<value>file:///home/hadoop/hadoopdata/hdfs/datanode</value>

</property>

</configuration>

Figura 62.

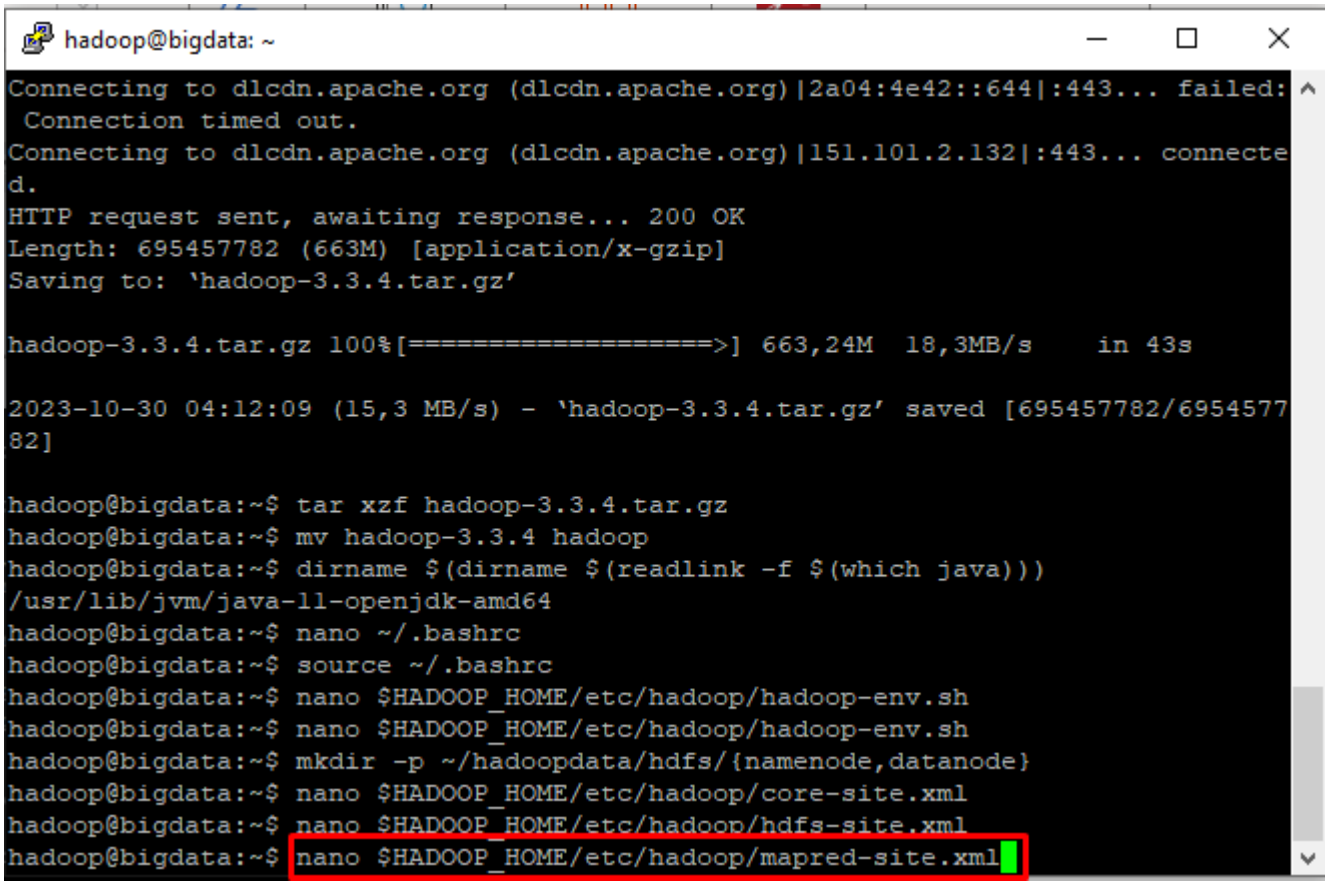
Configuración de variables del archivo hdfs-site.xml



Nota: Dar Crtl+O enter y luego Crtl+X para salir

Figura 63.

Configuración de archivo mapred-site.xml



Nota: Edite el archivo mapred-site.xml mediante el comando “nano $HADOOP_HOME/etc/hadoop/mapred-site.xml”

Y agregamos:

<configuration>

<property>

<name>mapreduce.framework.name</name>

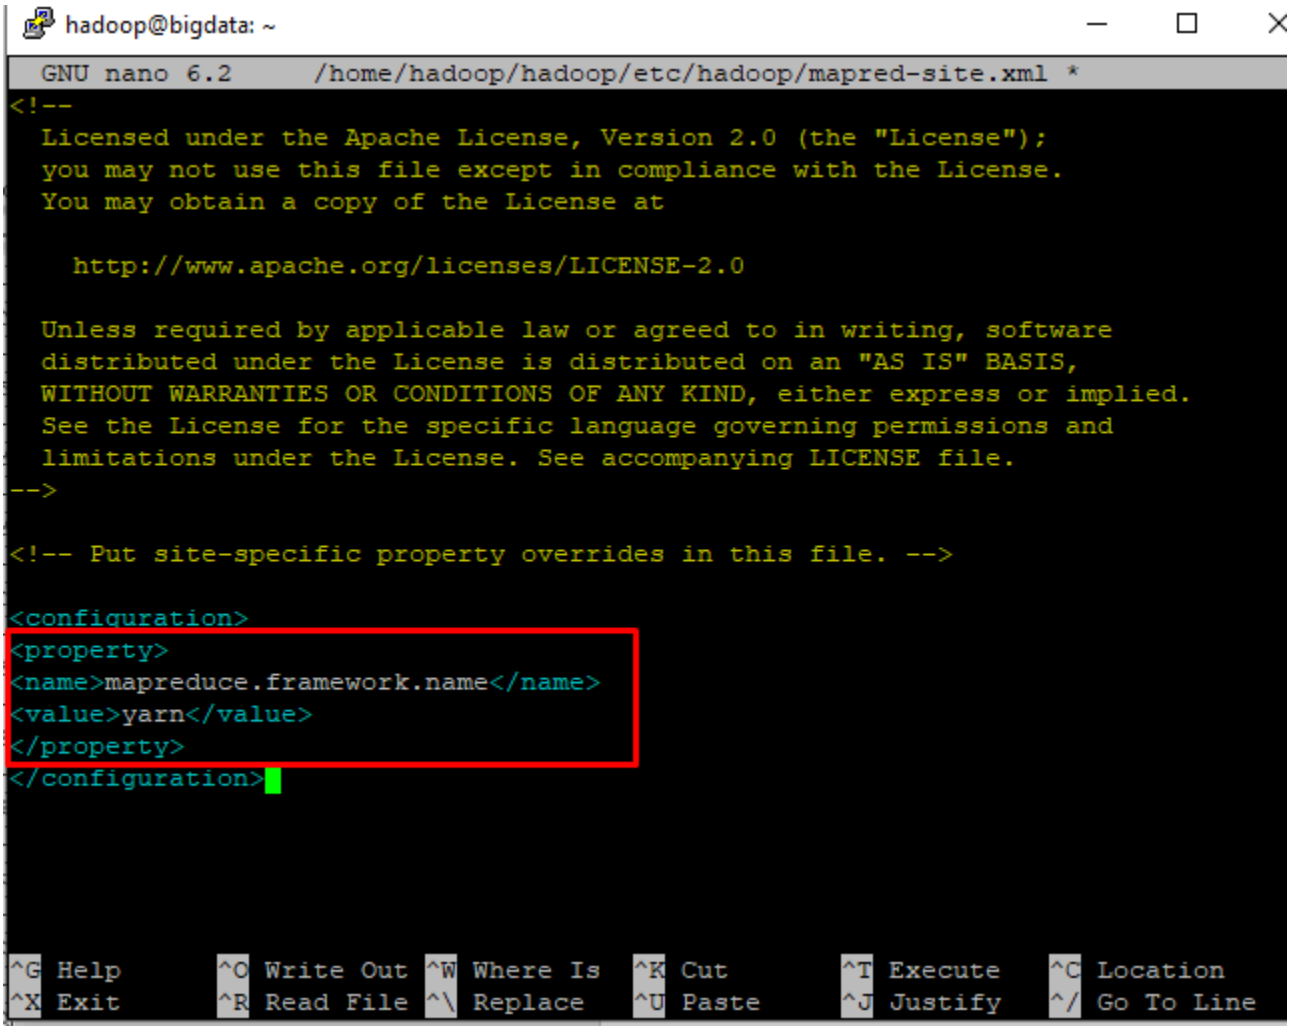
<value>yarn</value>

</property>

</configuration>

Figura 64.

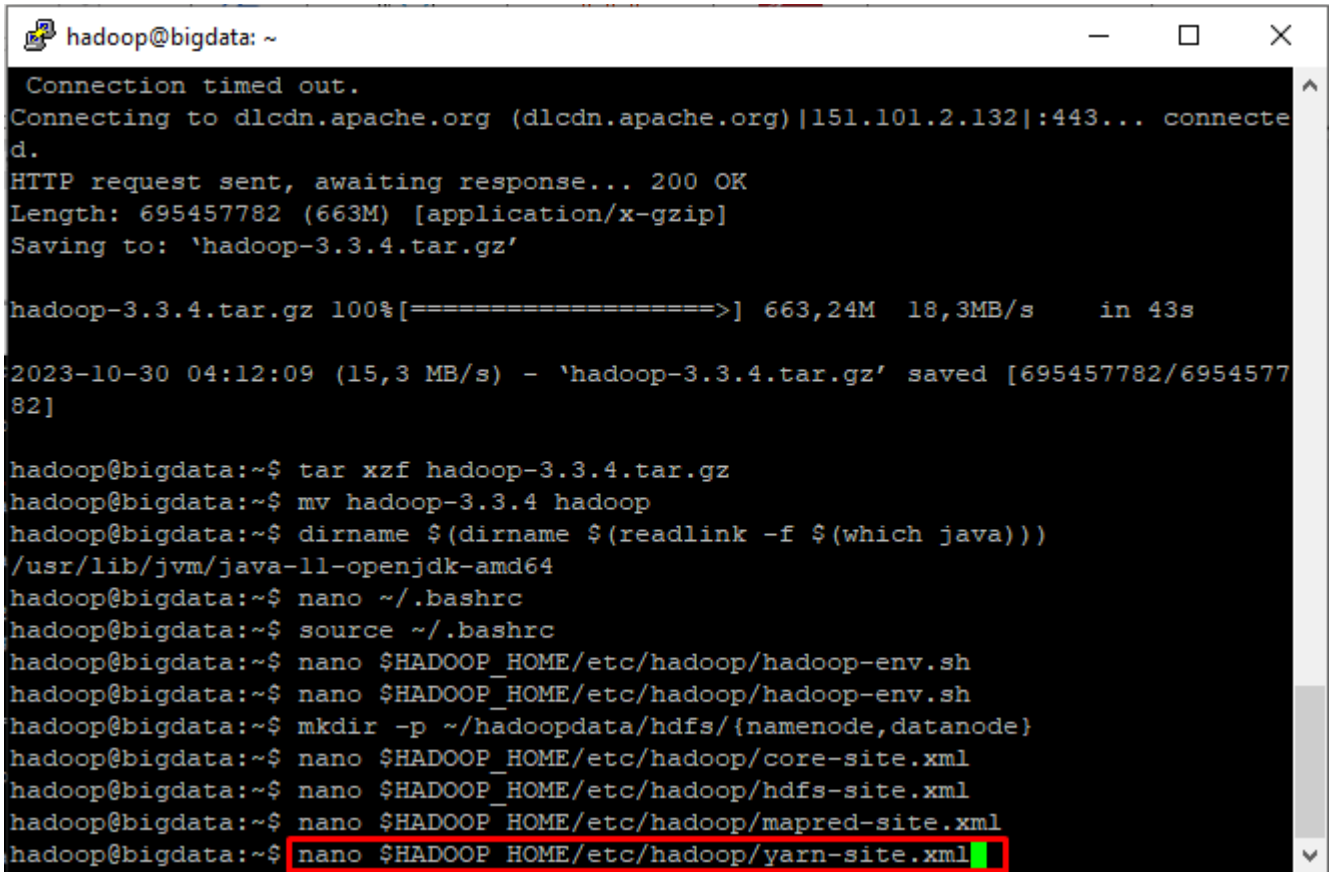
Configuración de variables de archivo mapred-site.xml



Nota: Dar Crtl+O enter y luego Crtl+X para salir

Figura 65.

Configuración de archivo yarn-site.xml



Nota: Edite el archivo yarn-site.xml mediante el comando “nano $HADOOP_HOME/etc/hadoop/yarn-site.xml”

Y agregamos:

<configuration>

<property>

<name>yarn.nodemanager.aux-services</name>

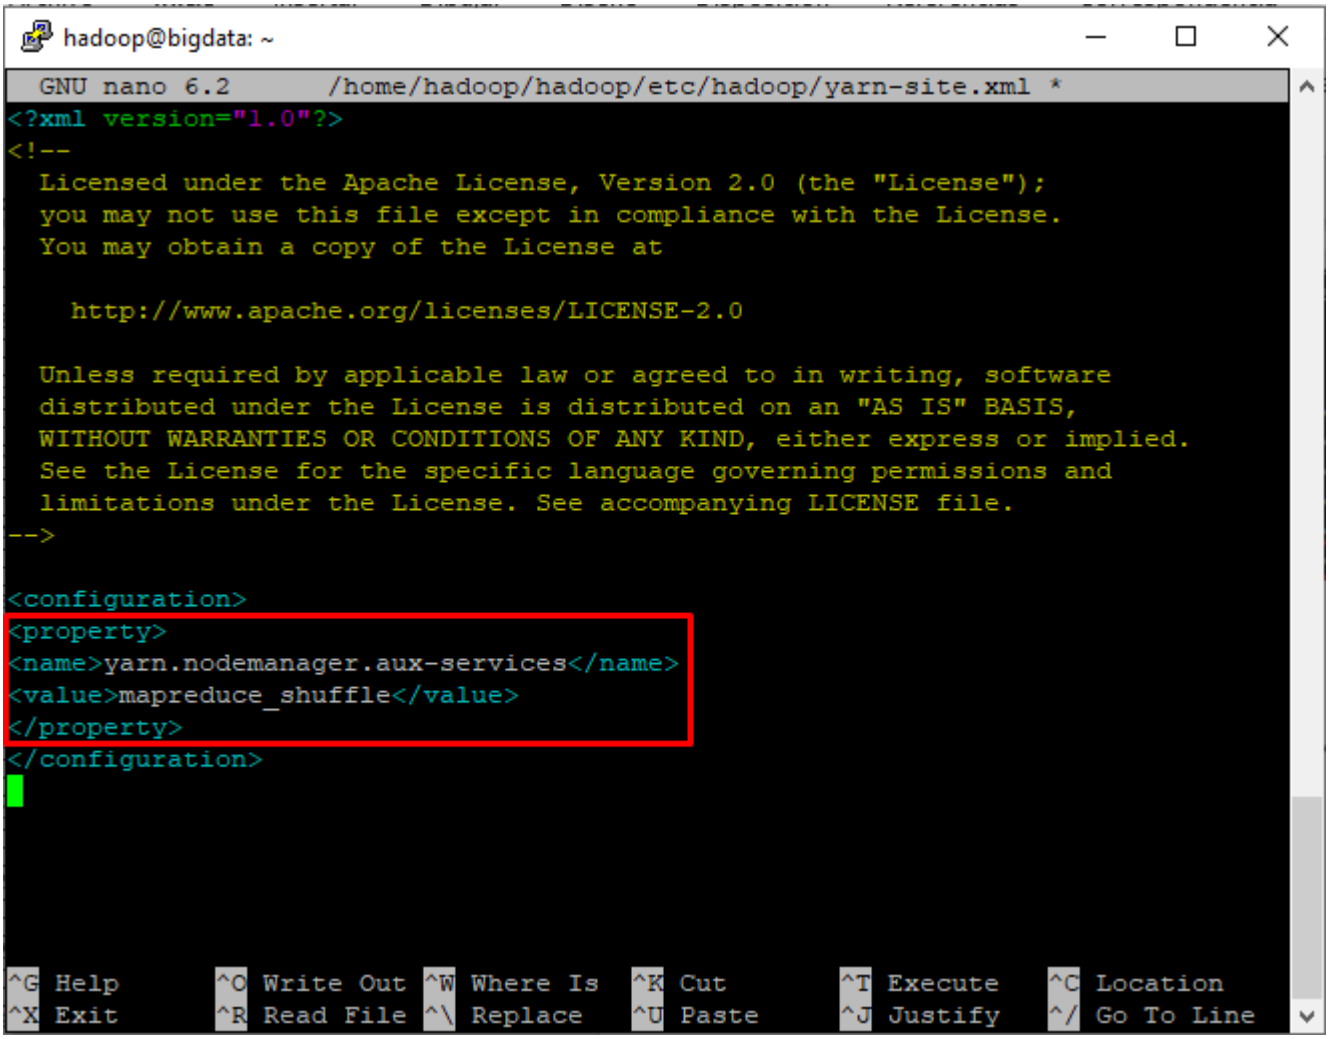
<value>mapreduce_shuffle</value>

</property>

</configuration>

Figura 66.

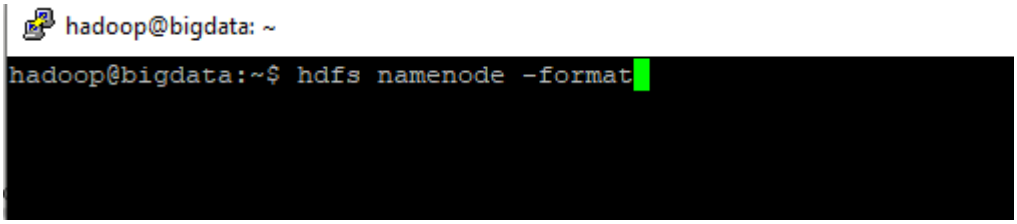
Configuración de variables de archivo yarn-site.xml



Nota: Dar Crtl+O enter y luego Crtl+X para salir

Figura 67.

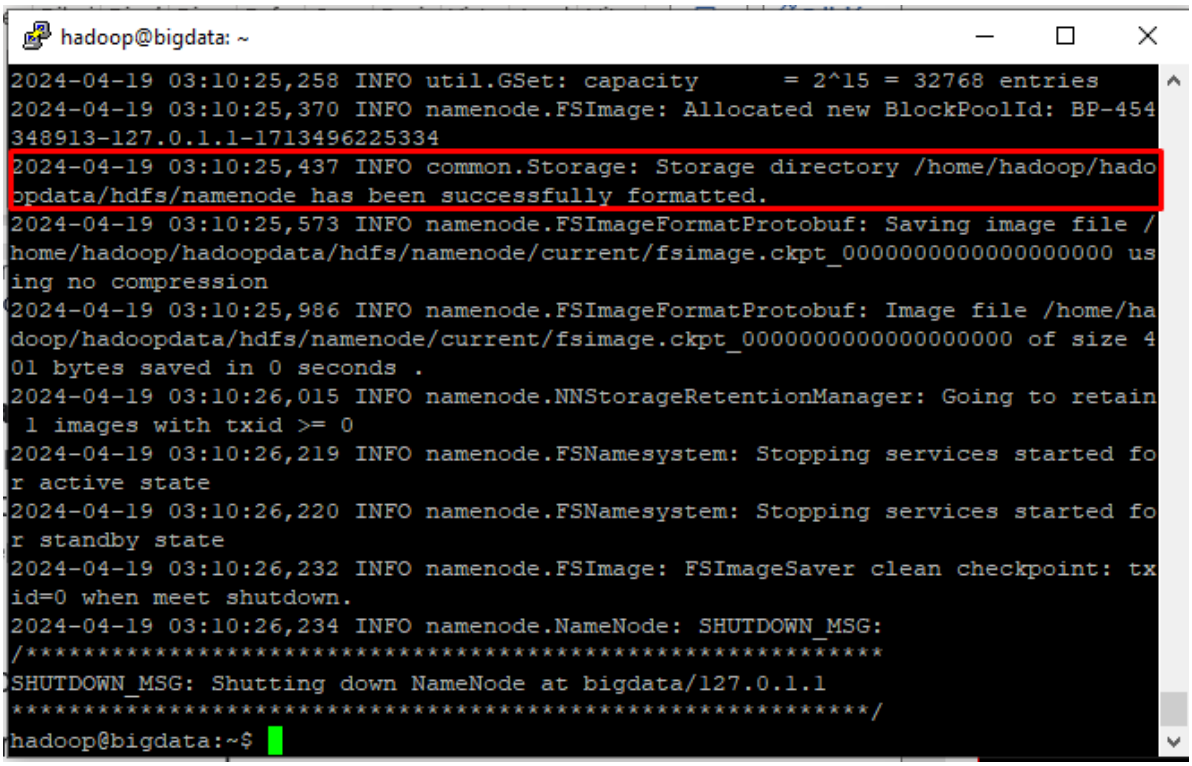
Formateo del nodo namenode



Nota: Antes de iniciar el clúster de Hadoop. Debemos formatear el Namenode como usuario de hadoop. Ejecute el siguiente comando “hdfs namenode -format” para dar formato al nodo.

Figura 68.

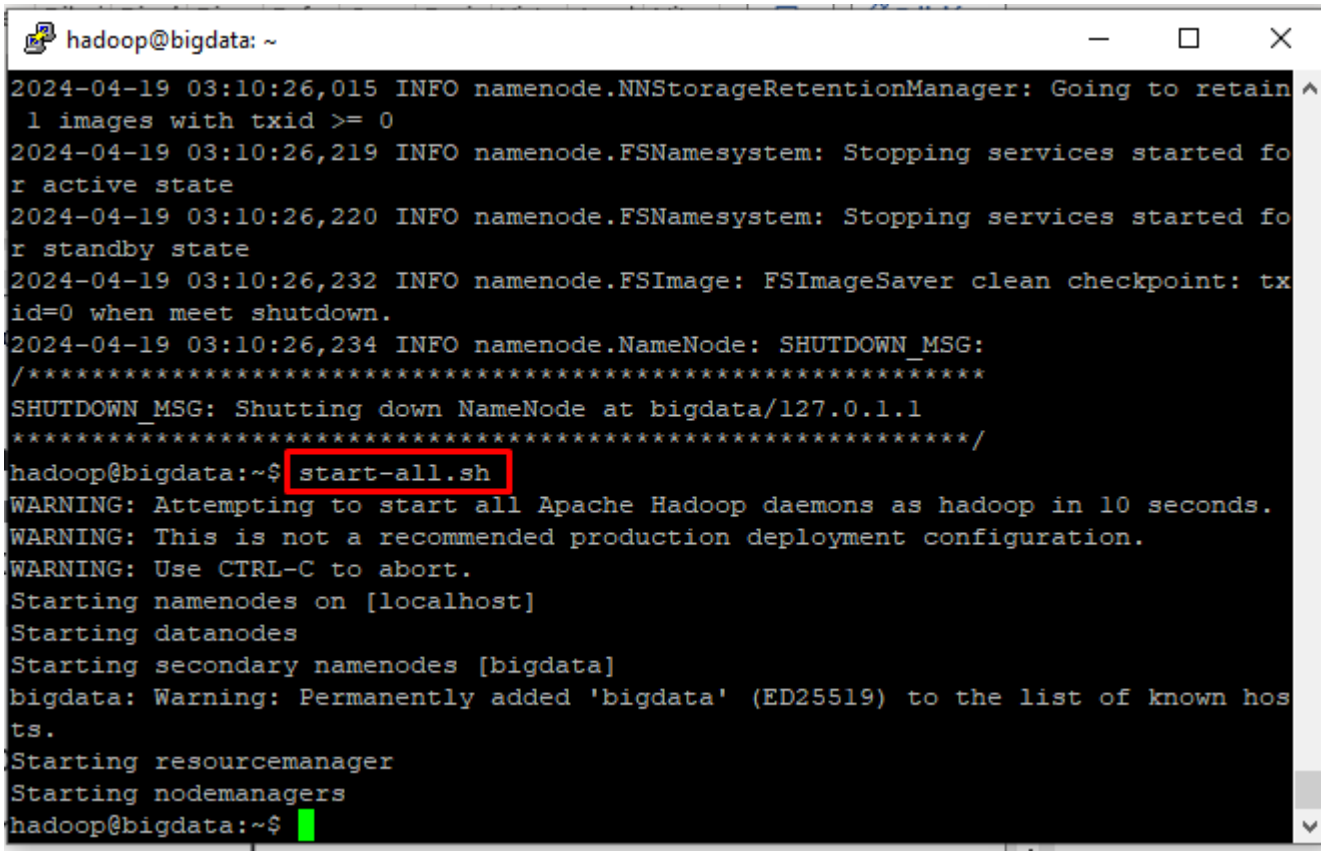
Formateo correctamente del nodo namenode



Nota: Una vez que el directorio namenode se formatee correctamente con el sistema de archivos hdfs, verá el mensaje "El directorio de almacenamiento /home/hadoop/hadoopdata/hdfs/namenode ha sido formateado correctamente".

Figura 69.

Inicio de cluster de hadoop



Nota: A continuación, inicie el clúster de Hadoop con el siguiente comando"start-all.sh"

Una vez iniciados todos los servicios, puede acceder al Hadoop en el navegador de su equipo con la dirección:

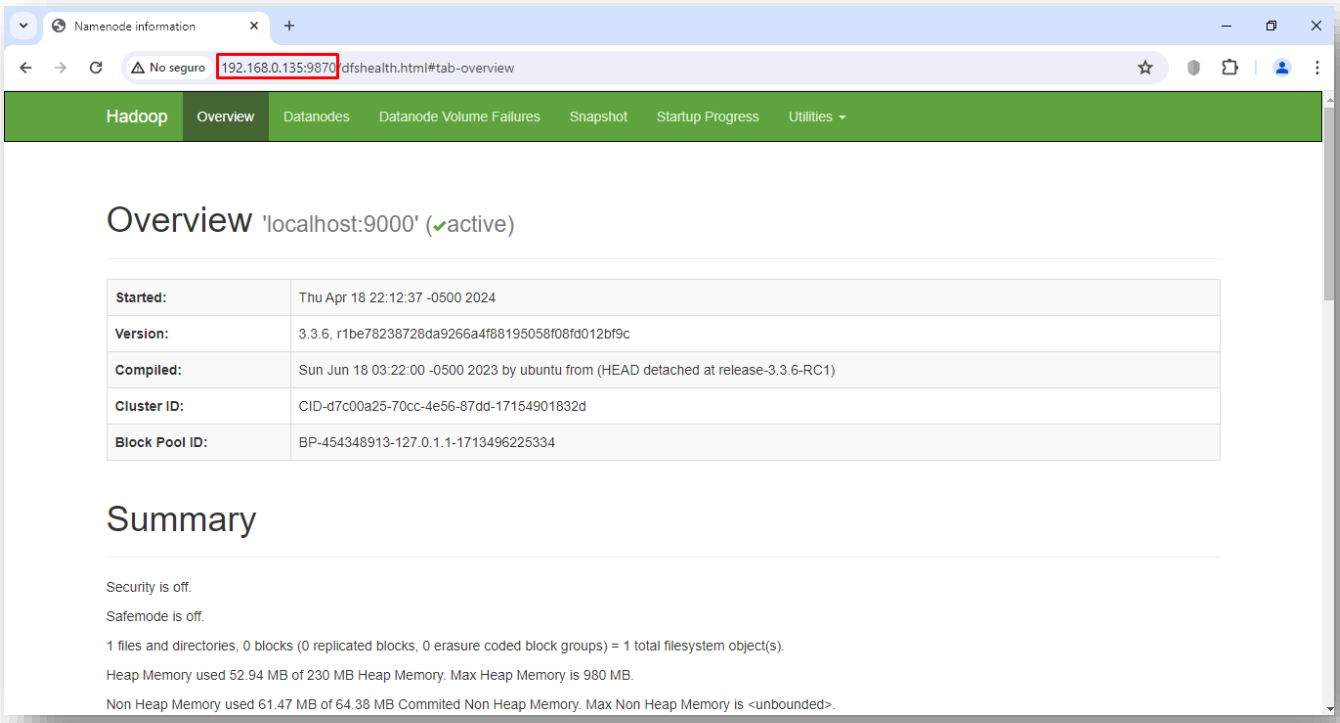
http://IP_MaquinaVirtual:9870

donde IP_MaquinaVirtual corresponde a la IP de su máquina virtual, en el ejemplo desarrollado en este instructivo la IP de la máquina virtual es 192.168.0.135

http://192.168.0.135:9870

Figura 70.

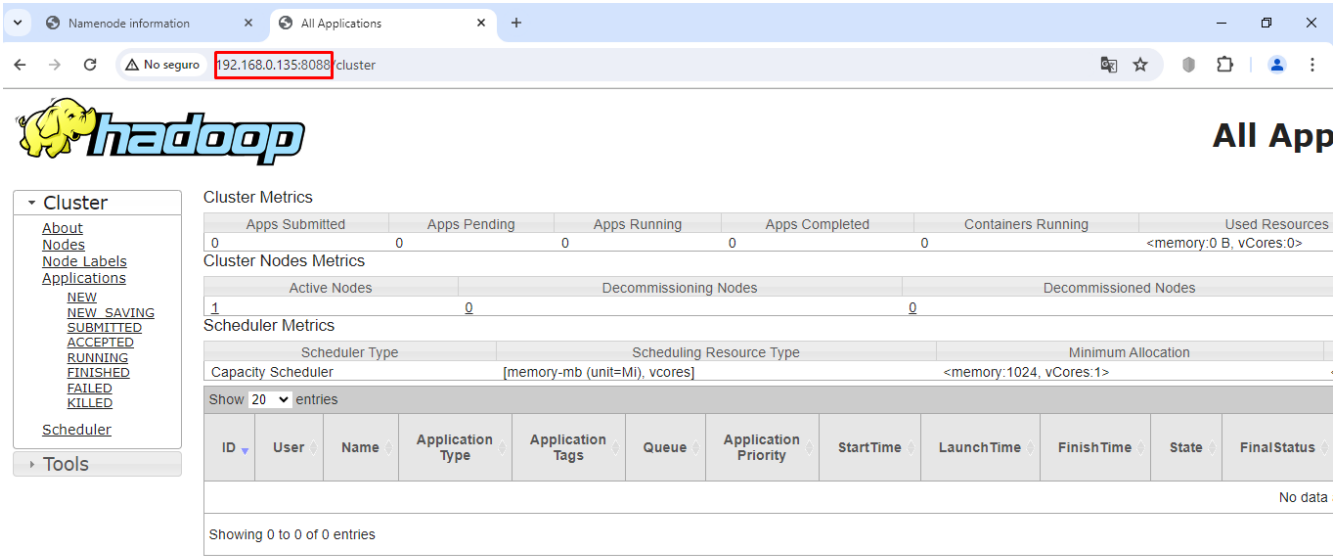
Página Resumen del aplicativo hadoop



Nota: Recuerde reemplaza la IP por la asignada por la maquina virtual. La IP que se muestre en el instructivo es de ejemplo.

Figura 71.

Página principal de hadoop



Nota: La página de la aplicación Hadoop está disponible en http://IP_MaquinaVirtual:8088. donde IP_MaquinaVirtual corresponde a la IP de su máquina virtual, en el ejemplo desarrollado en este instructivo la IP de la máquina virtual es 192.168.0.135. http://192.168.0.135:8088