Universidad Nacional Abierta y a Distancia

Vicerrectoría Académica y de Investigación

Unidad gestora: *Escuela*

Programa: *Ingeniería de Sistemas*

Curso: Big Data

Código: 202016911

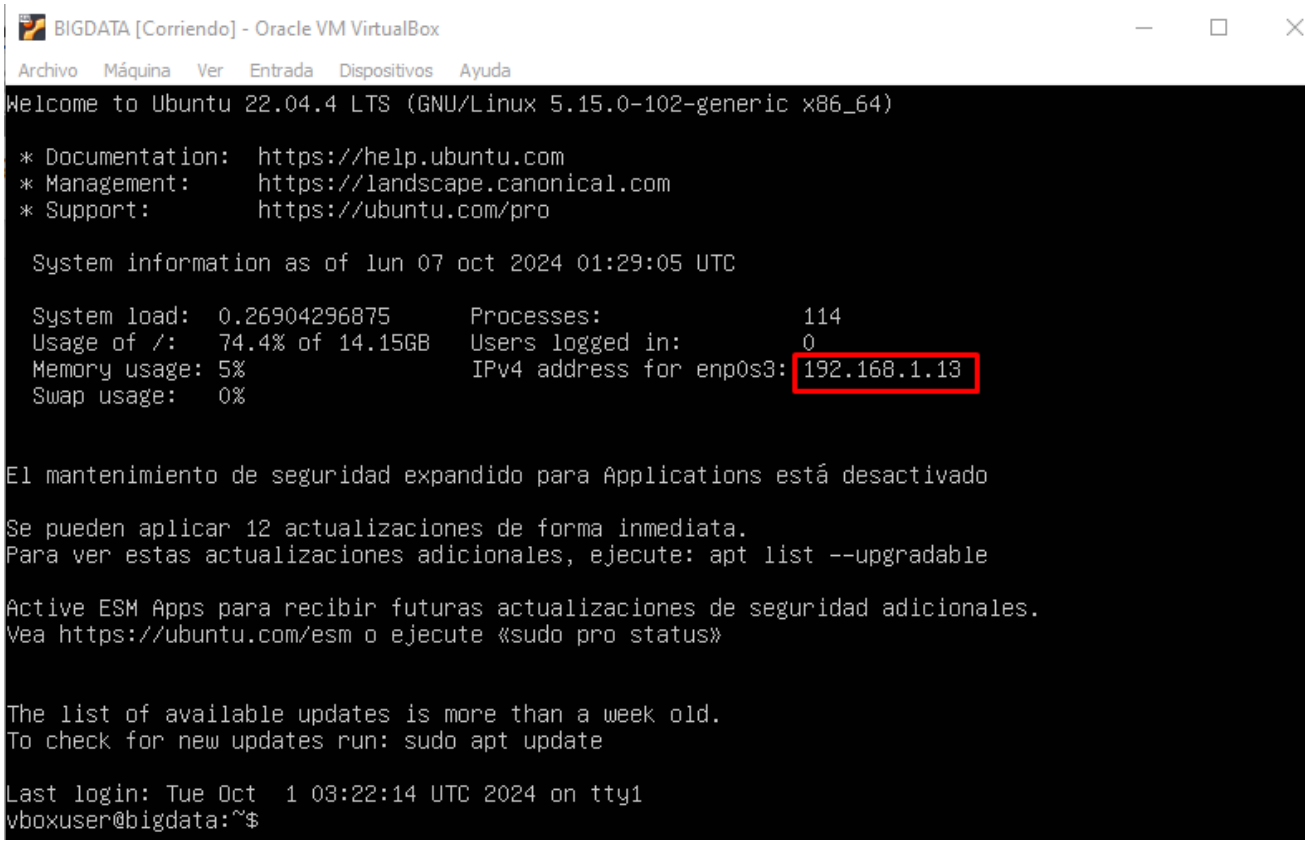
SPARK

Link de referencia:

https://computingforgeeks.com/how-to-install-apache-spark-on-ubuntu-debian/

Figura 1.

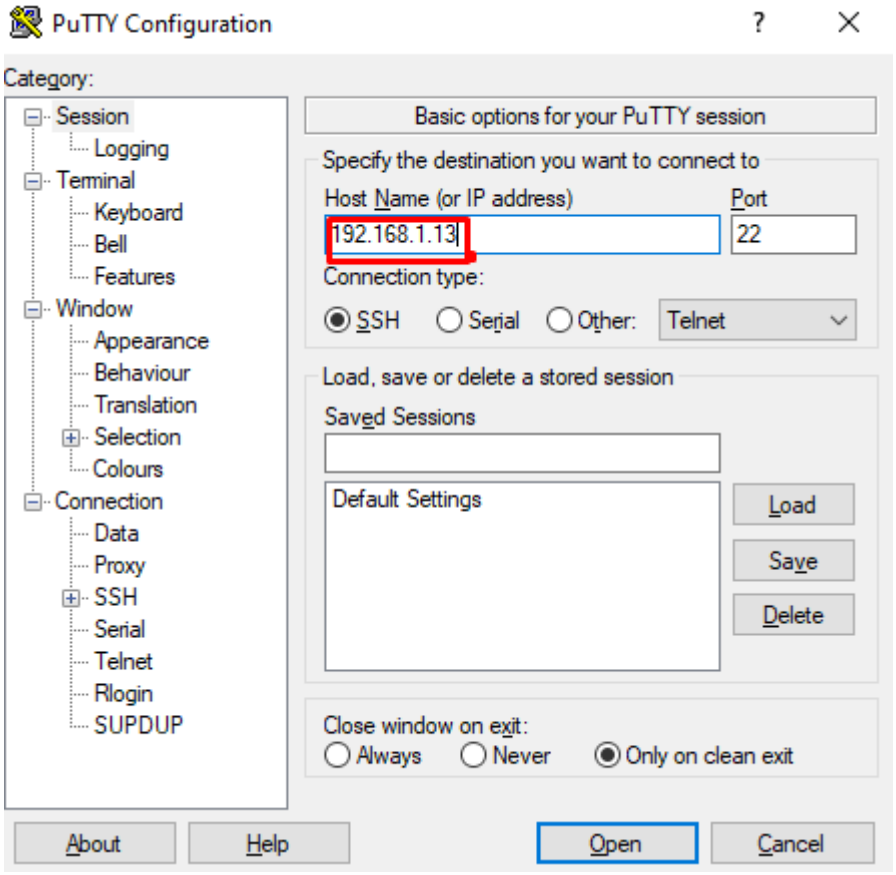
Inicio de sesión en la máquina virtual



Nota: Iniciamos la máquina virtual donde tenemos instalado Hadoop. Usuario “vboxuser” y contraseña “bigdata”. Se debe apuntar la IP asignada por la maquina virtual.

Figura 2.

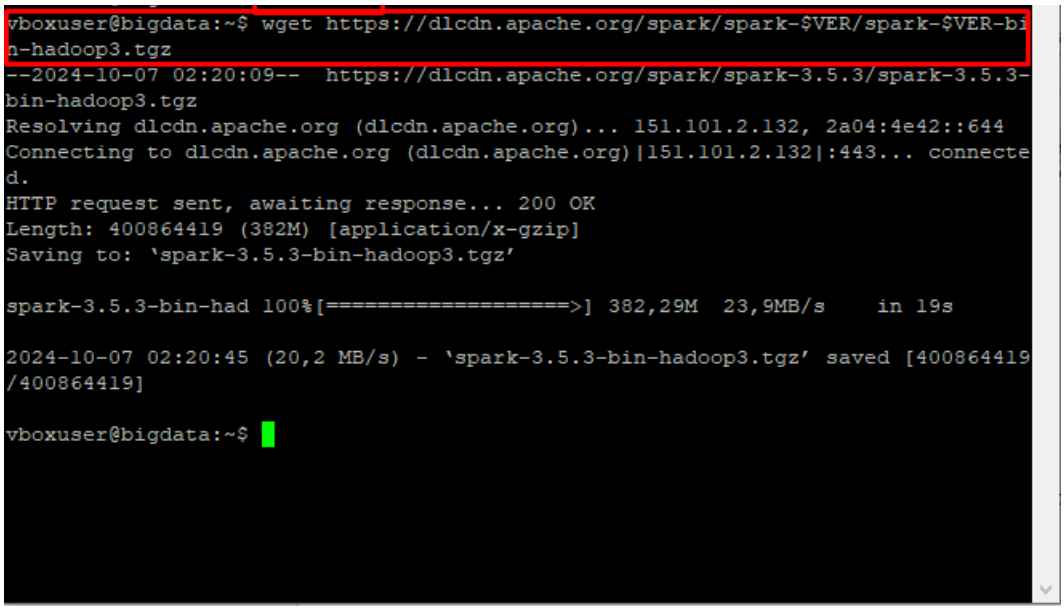
Configuración de Putty



Nota: Ejecutamos Putty para conectarnos por SSH a la máquina virtual utilizando la IP local. En Putty nos iniciamos sesión nuevamente con el usuario “vboxuser” y contraseña “bigdata”

Figura 3.

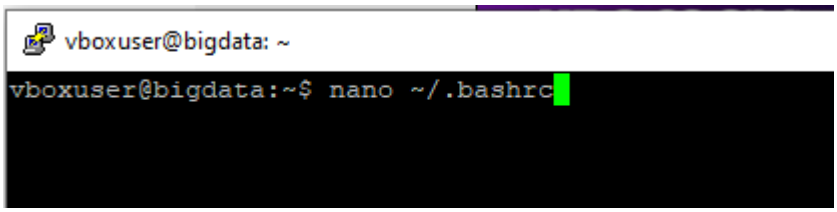
Descarga de apache spark



Nota: Descargue apache spark usando el comando “wget https://dlcdn.apache.org/spark/spark-3.5.8/spark-3.5.8-bin-hadoop3.tgz”, luego descomprima el archivo descargado usando el comando “tar xvf spark-3.5.8-bin-hadoop3.tgz” y mueva de carpeta Apache Spark con el comando “sudo mv spark-3.5.8-bin-hadoop3/ /opt/spark”. Valide usando la url de descarga que la version 3.5.8 de Apache Spark siga disponible en la pagina web o consulte la pagina https://dlcdn.apache.org/spark. Si solicita contraseña recuerde “bigdata”

Figura 4.

Configuración del archivo .bashrc



Nota: Abra el archivo de configuración bashrc usando el comando “nano ~/.bashrc”

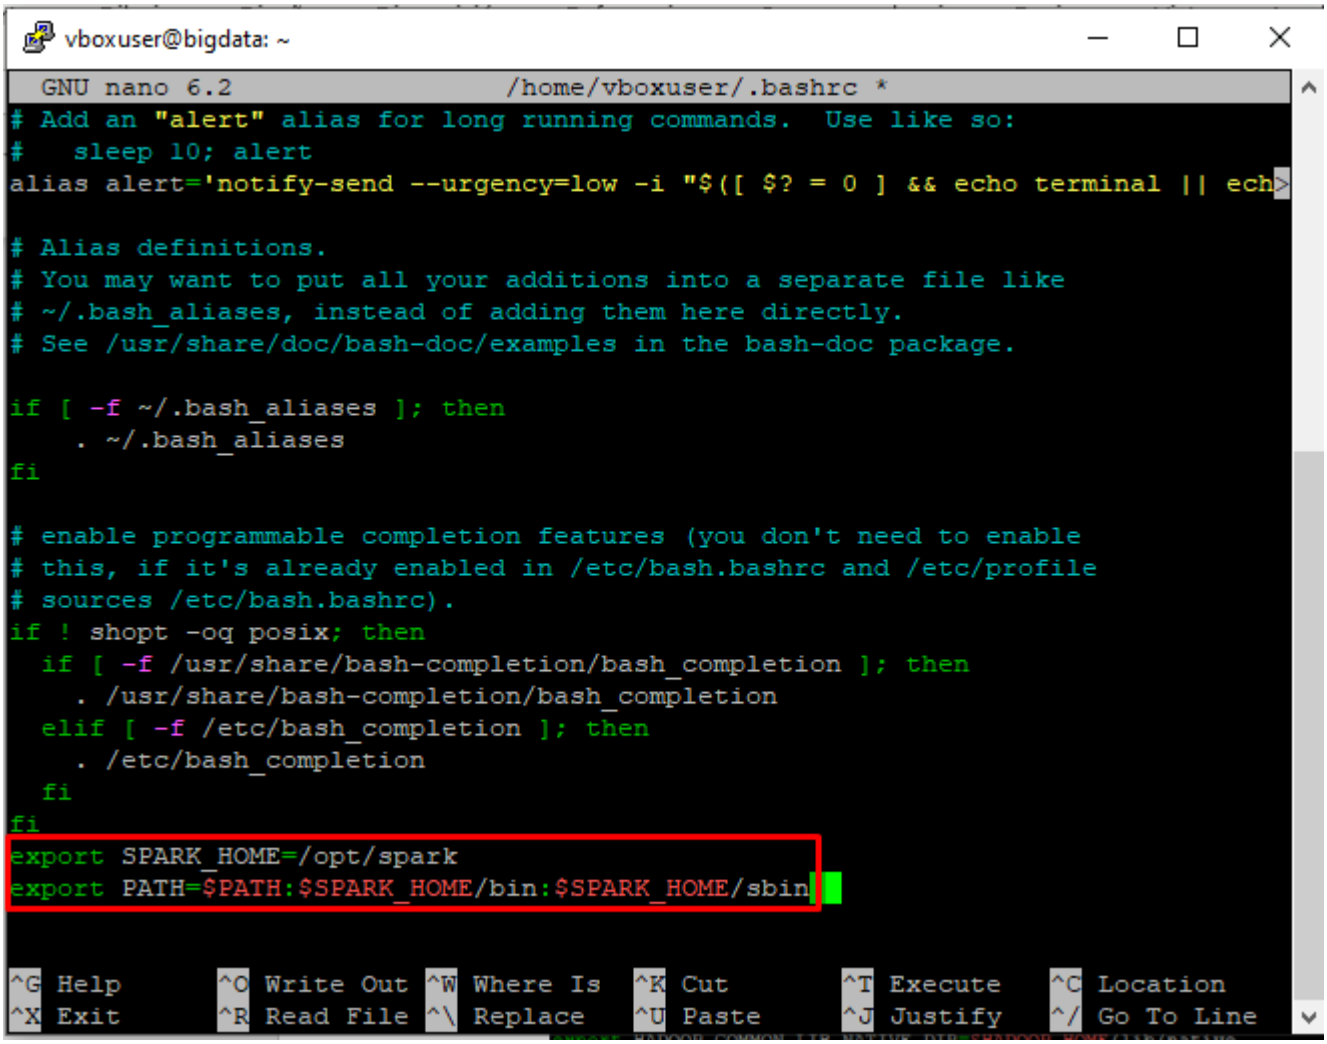
Y debe agregar al final

export SPARK_HOME=/opt/spark

export PATH=$PATH:$SPARK_HOME/bin:$SPARK_HOME/sbin

Figura 5.

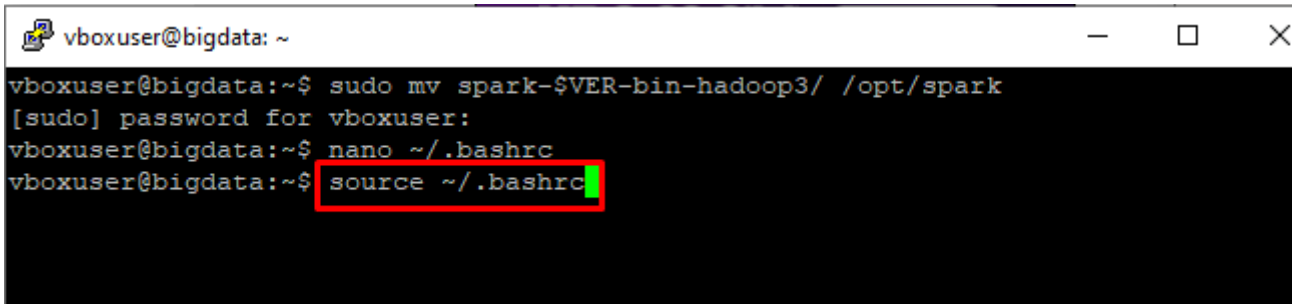
Configuración de variables del archivo .bashrc



Nota: Dar Crtl+O enter y luego Crtl+X para salir

Figura 6.

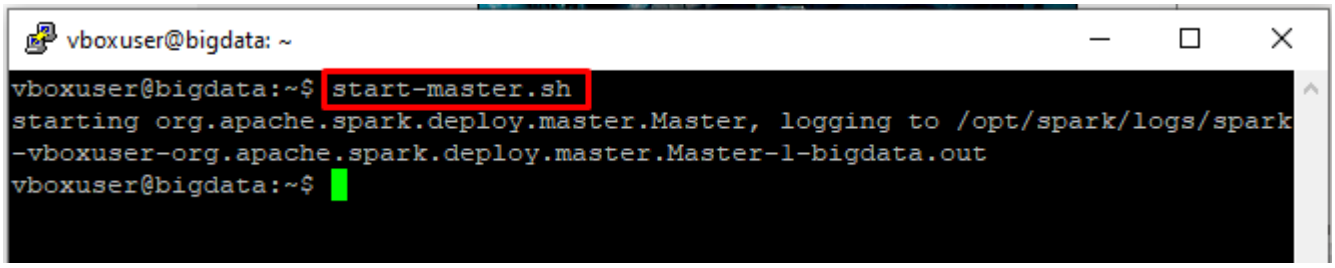
Cargue de cambios del archivo. bashrc



Nota: Active y cargue los cambios usando el comando “source ~/.bashrc”

Figura 7.

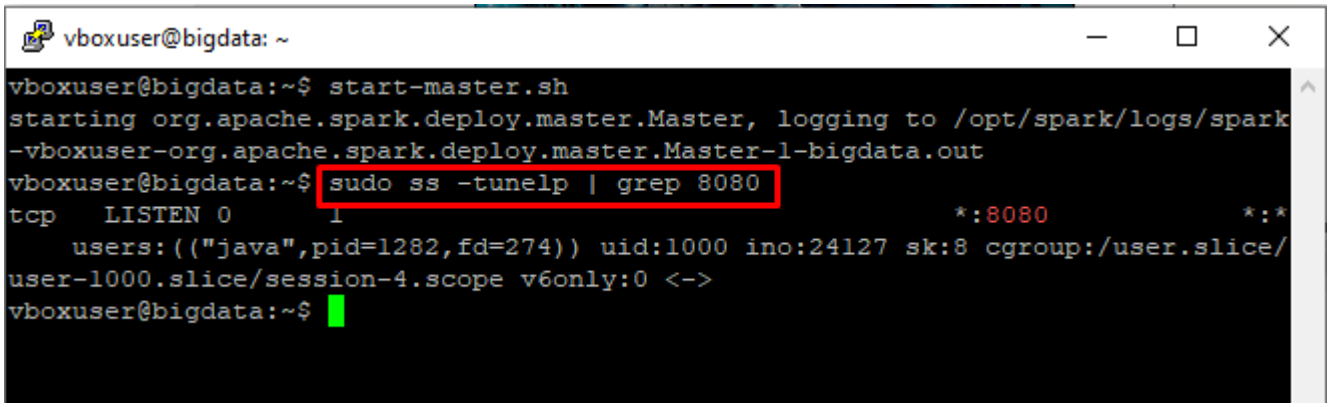
Inicio de servidor de apache spark



Nota: Ahora puede iniciar un servidor maestro independiente mediante el comando ”start-master.sh”

Figura 8.

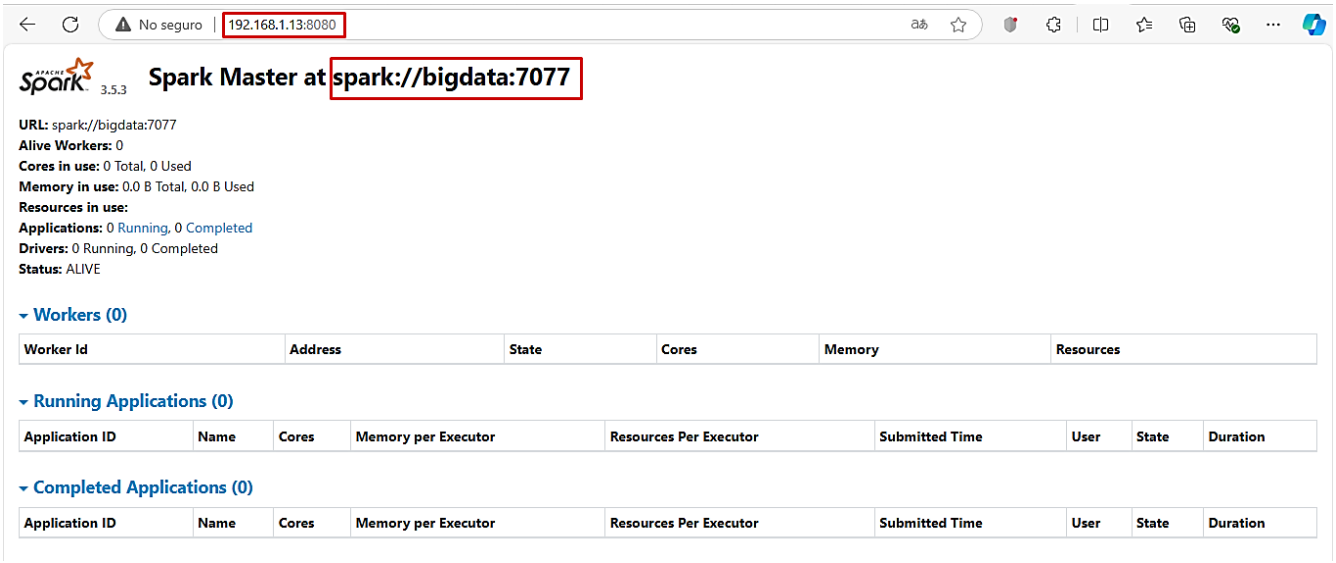
Apertura del puerto TCP 8080



Nota: El proceso se escuchará por medio del puerto TCP 8080 usando el comando "sudo ss -tunelp | grep 8080"

Figura 9.

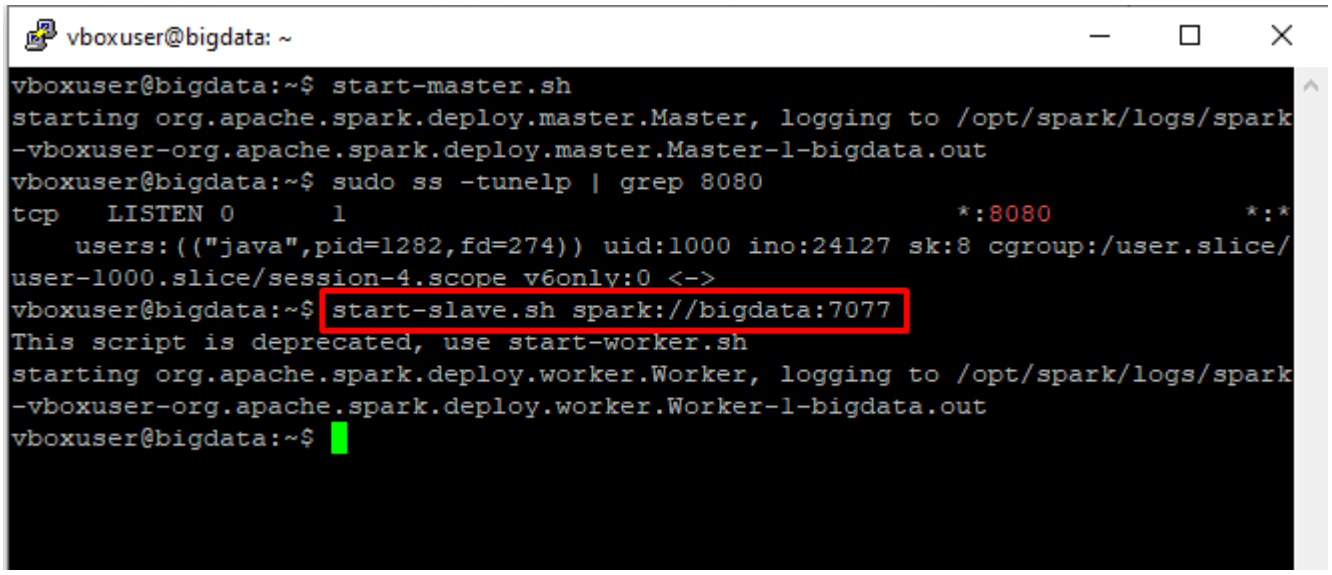
Página principal de apache spark



Nota: Abra el navegador web y accede a la interfaz web de Spark utilizando la URL http://IP_MaquinaVirtual:8080 donde IP_MaquinaVirtual corresponde a la IP de su máquina virtual, en el ejemplo desarrollado en este instructivo la IP de la máquina virtual es 192.168.1.13. http://192.168.1.13:8080

Figura 10.

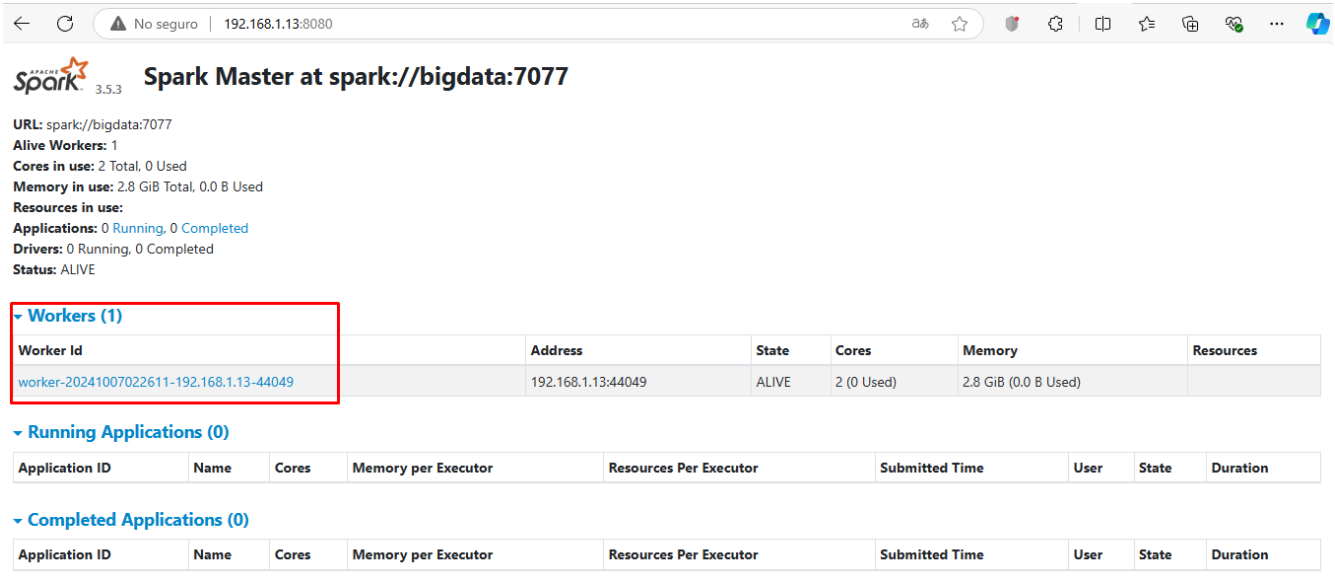
Inicio de proceso de trabajo de apache spark



Nota: Como se puede ver, el servicio maestro de Apache Spark se está ejecutando en spark://bigdata:7077. Así que puede utilizar esta dirección para iniciar el proceso de trabajo de Spark utilizando el comando “start-slave.sh spark://bigdata:7077”.

Figura 11.

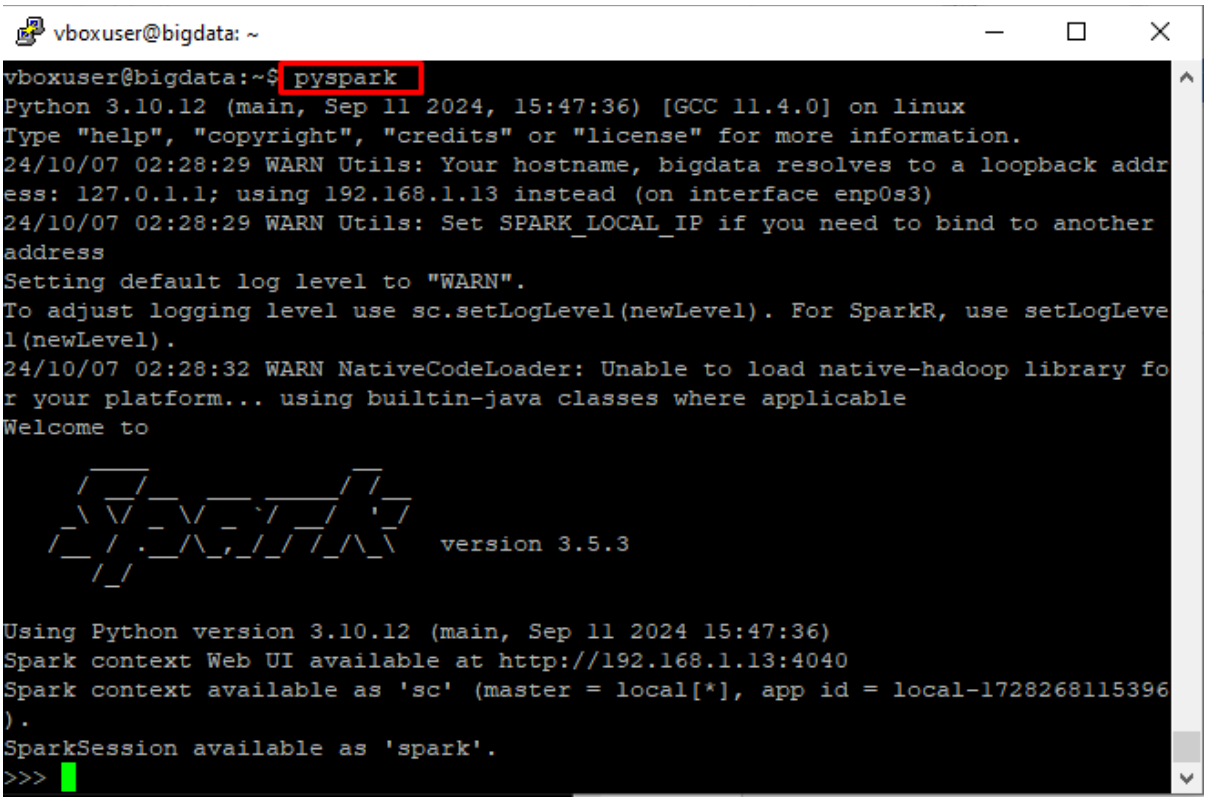
Proceso de apache spark worker



Nota: Ahora, vaya al panel de control de Spark y actualice la pantalla. Debería ver el proceso Spark worker

Figura 12.

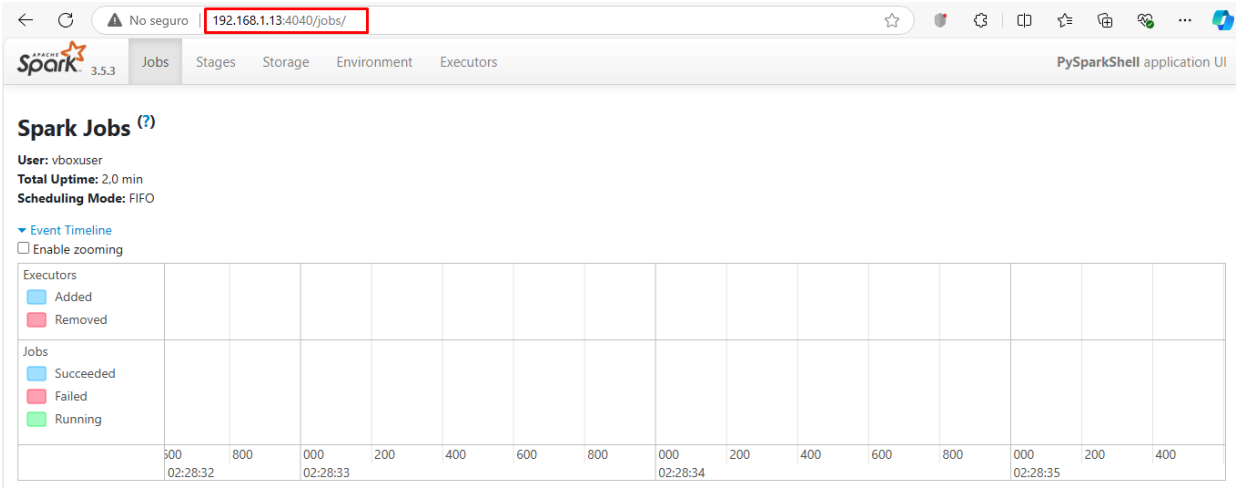
Ingreso al spark context web UI



Nota: Iniciamos una sesión de trabajo (job) para poder ingresar a la interfaz web de Spark context web UI, para esto utilizamos el siguiente comando “pyspark”.

Figura 13.

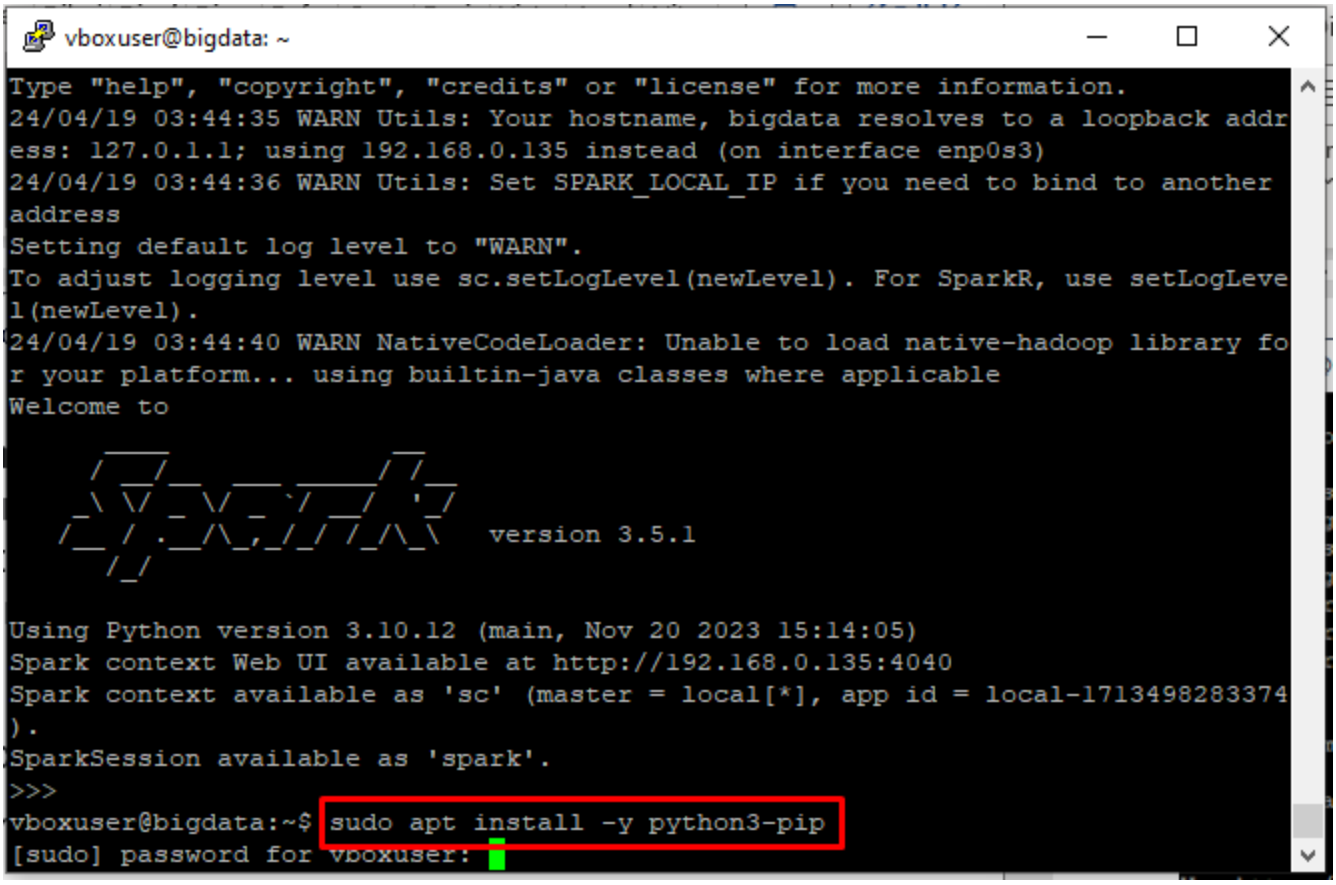
Página principal de Spark Jobs



Nota: Abra el navegador web y accede a la interfaz web de Spark context web UI utilizando la URL http://IP_MaquinaVirtual:4040 donde IP_MaquinaVirtual corresponde a la IP de su máquina virtual, en el ejemplo desarrollado en este instructivo la IP de la máquina virtual es 192.168.1.13. http://192.168.1.13:4040.
Si desea salir de la sesión de Apache Spark lo hacemos mediante el comando de teclado CTRL+D

Figura 14.

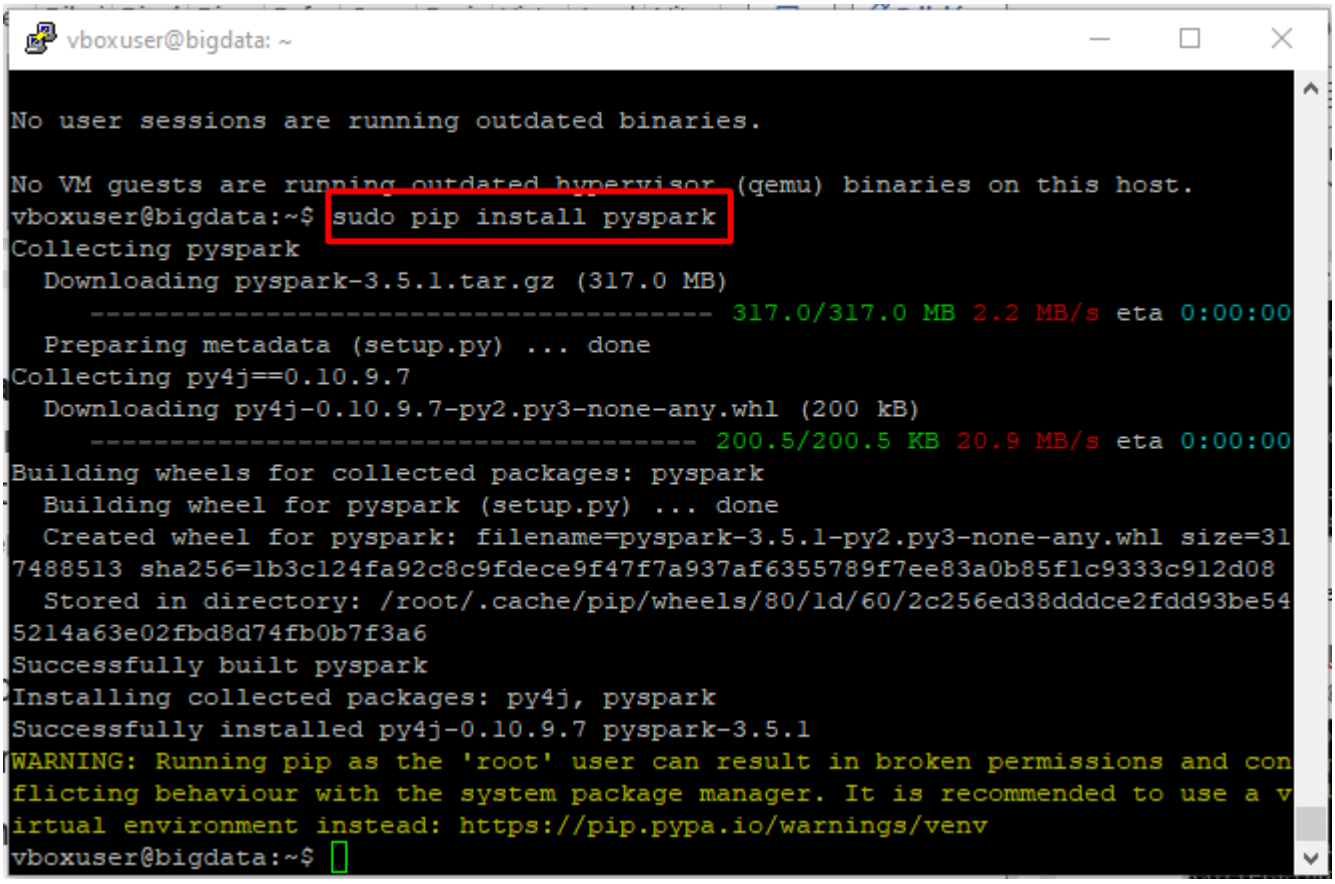
Instalación de herramienta PIP



Nota: Para administrar paquetes de software de Python, instalamos PIP, una herramienta que ayudará a instalar y administrar bibliotecas o módulos mediante el comando “sudo apt install -y python3-pip” y si requiere contraseña “bigdata”

Figura 15.

Instalación de librería Python pyspark



Nota: Instalamos mediante PIP la librería de Python pyspark usando el comando “ sudo pip install pyspark==3.5.1”

Cambiamos al usuario hadoop
su - hadoop
Password: hadoop

Figura 16.
Inicio Sesión usuario hadoop

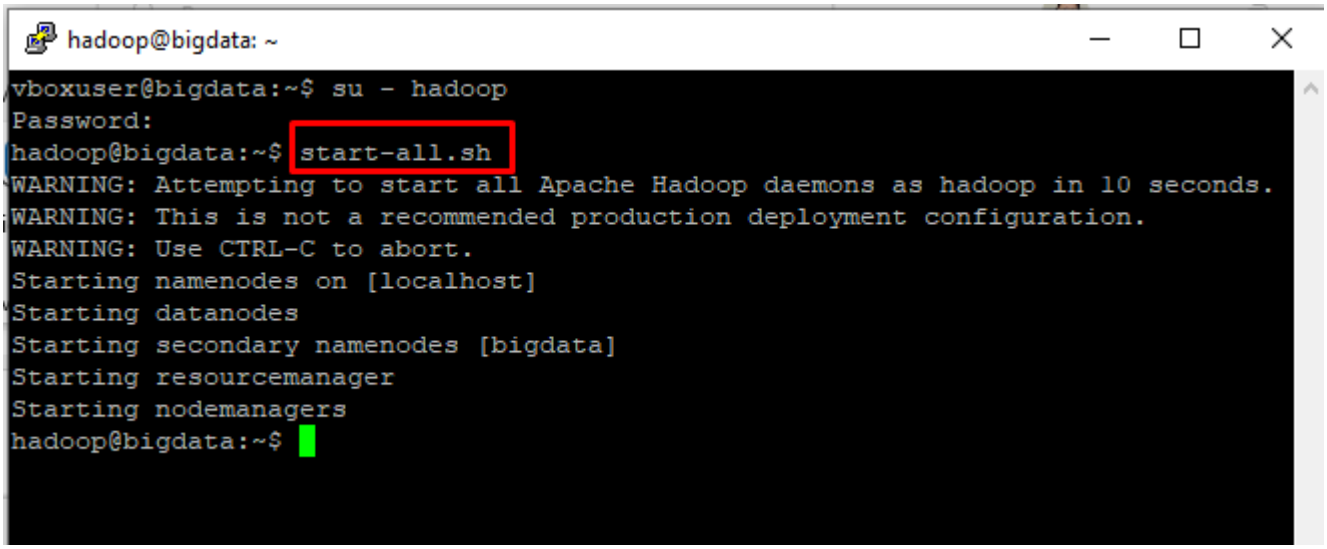


Nota: Cambiamos de usuario a “hadoop” mediante el código “su - hadoop” y contraseña “hadoop”.

A continuación, realizamos la conexión por Putty a nuestra máquina virtual. Recuerda que debe colocar la dirección IP asignada. Una vez conectados exitosamente a la máquina virtual utilizando el software Putty ingresamos con las siguientes credenciales Usuario “hadoop” y contraseña “hadoop”

Figura 17.

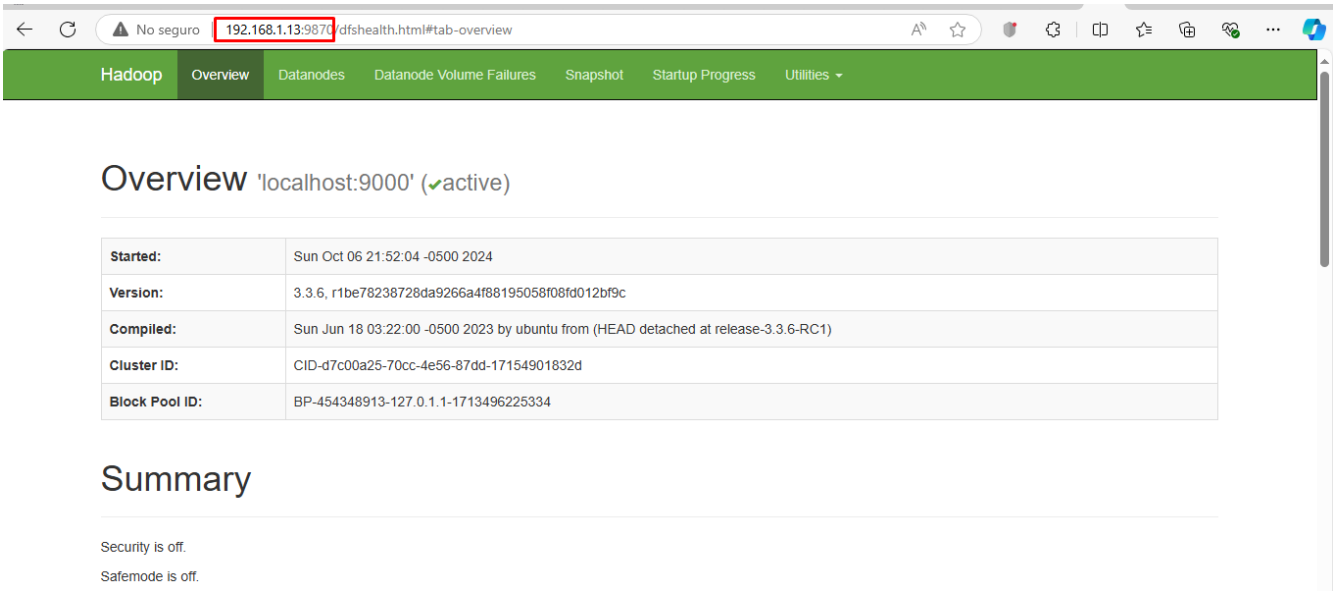
Inicio del cluster hadoop



Nota: Iniciamos el clúster de hadoop con el siguiente comando “start-all.sh”

Figura 18.

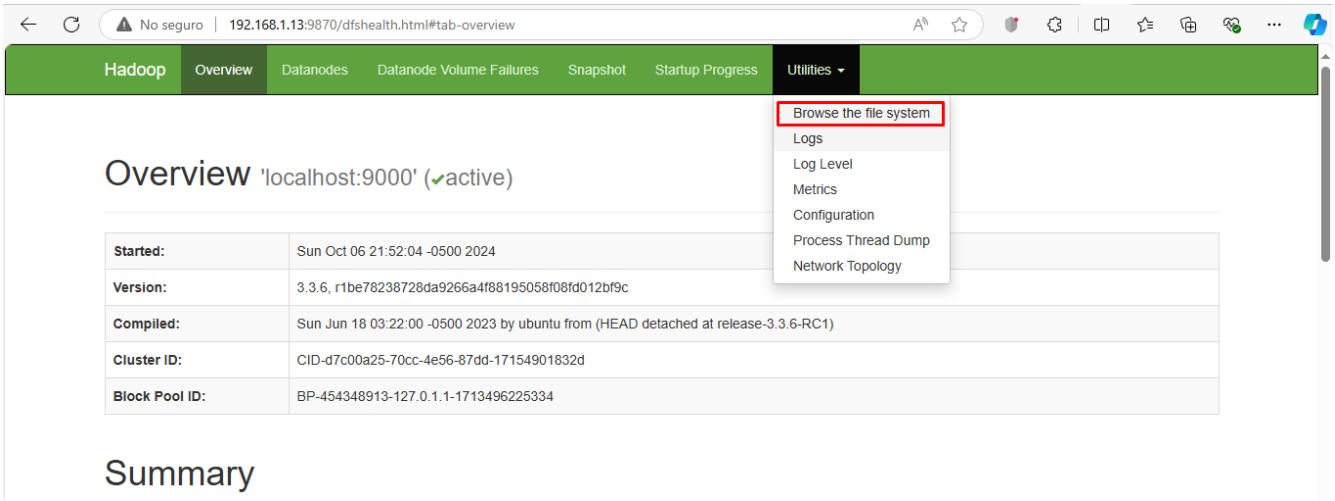
Página principal de resumen de hadoop



Nota: Una vez iniciados todos los servicios, puede acceder a hadoop usando la url http://IP_MaquinaVirtual:9870 y para este caso http://192.168.1.13:9870

Figura 19.

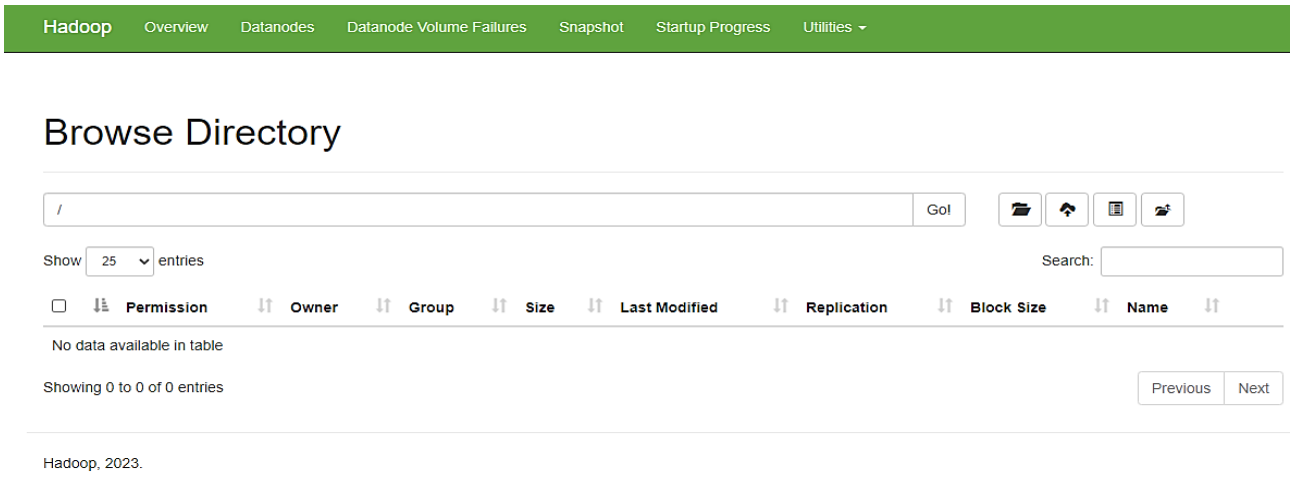
Página principal de hadoop con la opción browse the file system



Nota: Se puede visualizar el sistema de archivos HDFS en la opción Utilities-Browse the file system.

Figura 20.

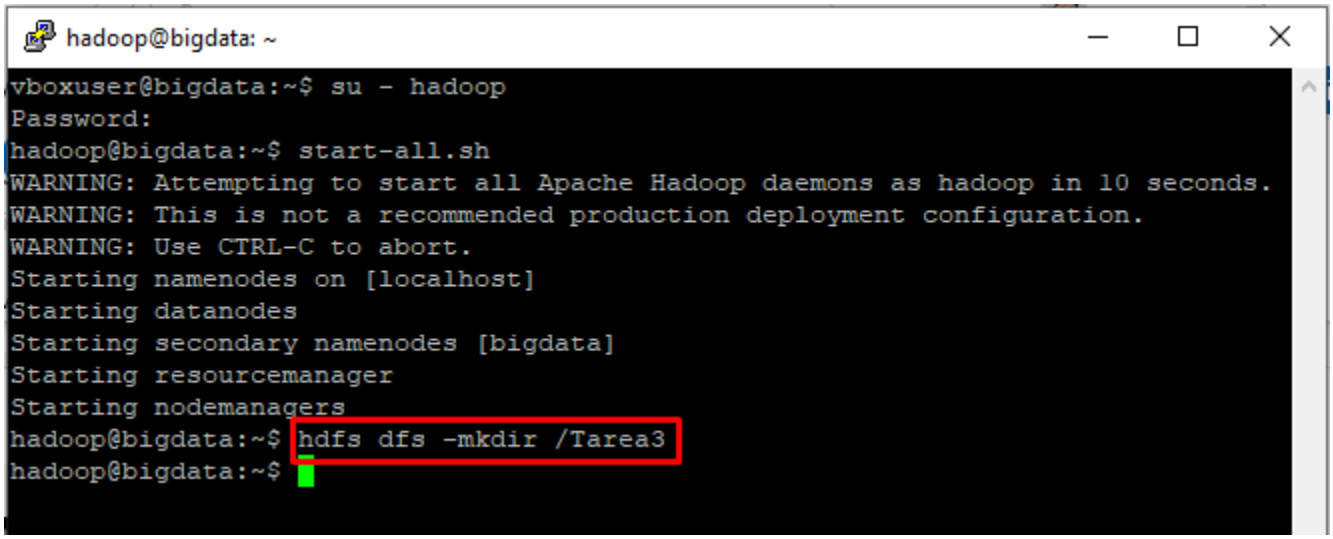
Página de Hadoop opción browser directory



Nota: Hasta el momento no se tiene ninguna carpeta de archivos HDFS.

Figura 21.

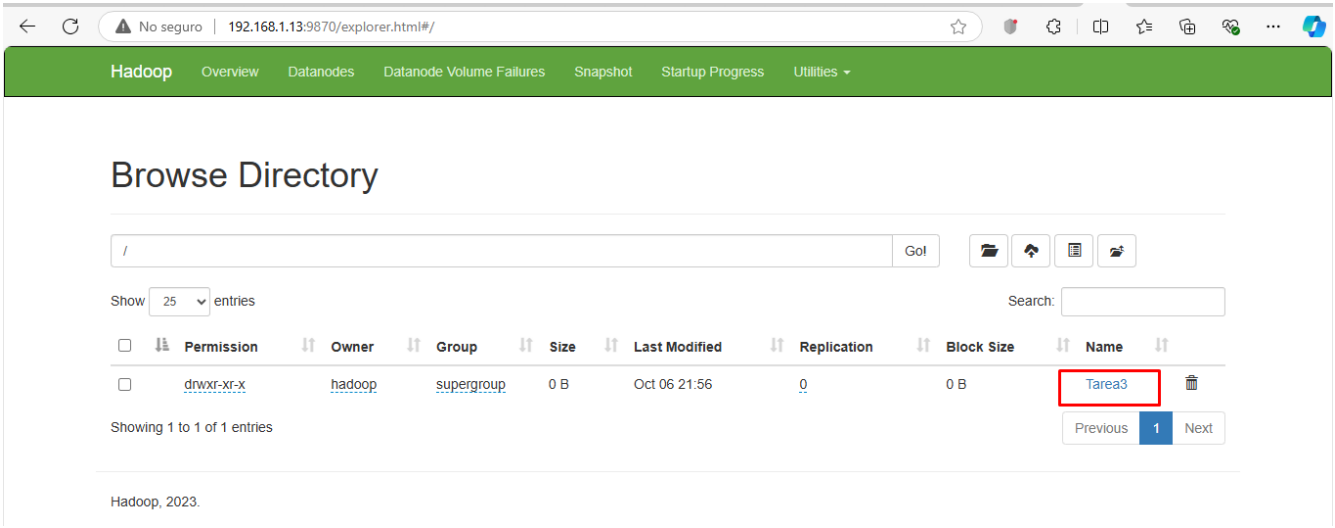
Creación de carpeta en el sistema HDFS



Nota: Se crea una carpeta en el sistema HDFS utilizando el comando “hdfs dfs -mkdir /Tarea3” con esto creamos una carpeta llamada Tarea3 en el sistema HDFS y verificamos en el navegador refrescando la página.

Figura 22.

Validación de la creación de una carpeta en el sistema HDFS



Nota: Se puede observar la creación de la carpeta llamada “Tarea” en el sistema de archivos HDFS.

Figura 23.

Página del dataset tasa de cambio representativa del mercado -histórico

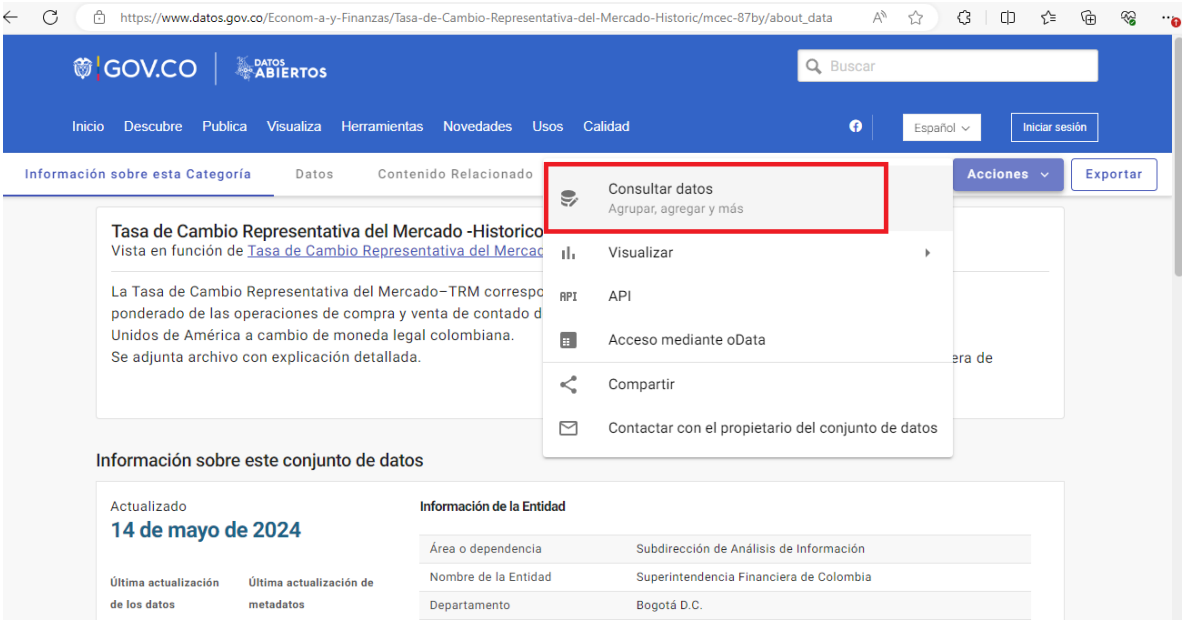


Nota: Ahora, Ingresamos a la url o página https://www.datos.gov.co/browse y buscamos un dataset que cumpla con las condiciones planteadas en la guía de actividades, por ejemplo “Tasa

de Cambio Representativa del Mercado -Histórico".

Figura 24.

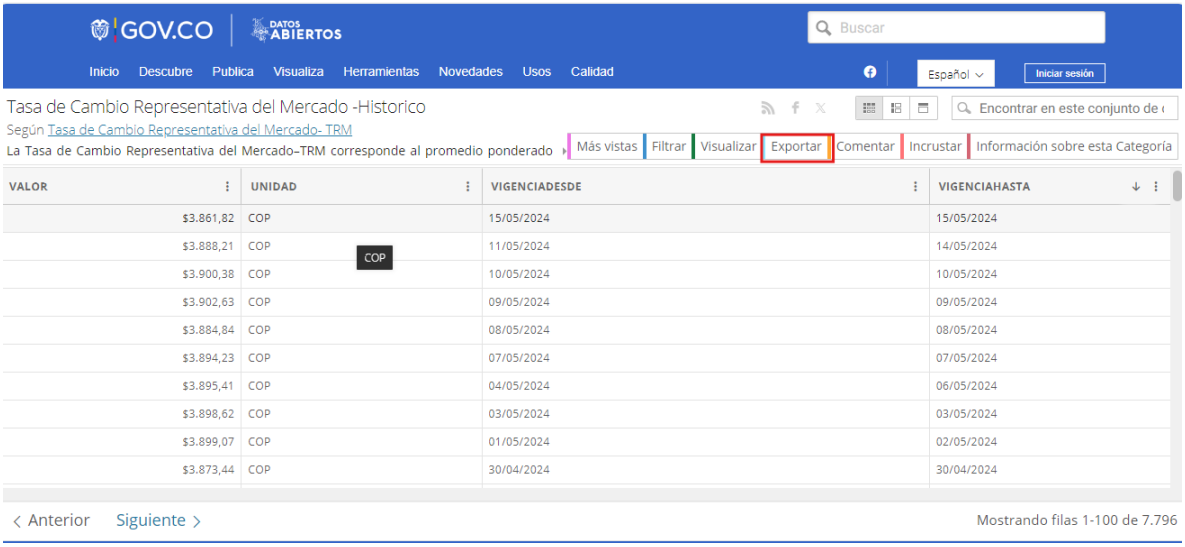
Opción de consultar datos de dataset seleccionado



Nota: Ingresamos al Dataset seleccionado y damos clic en Acciones y luego "consultar datos"

Figura 25.

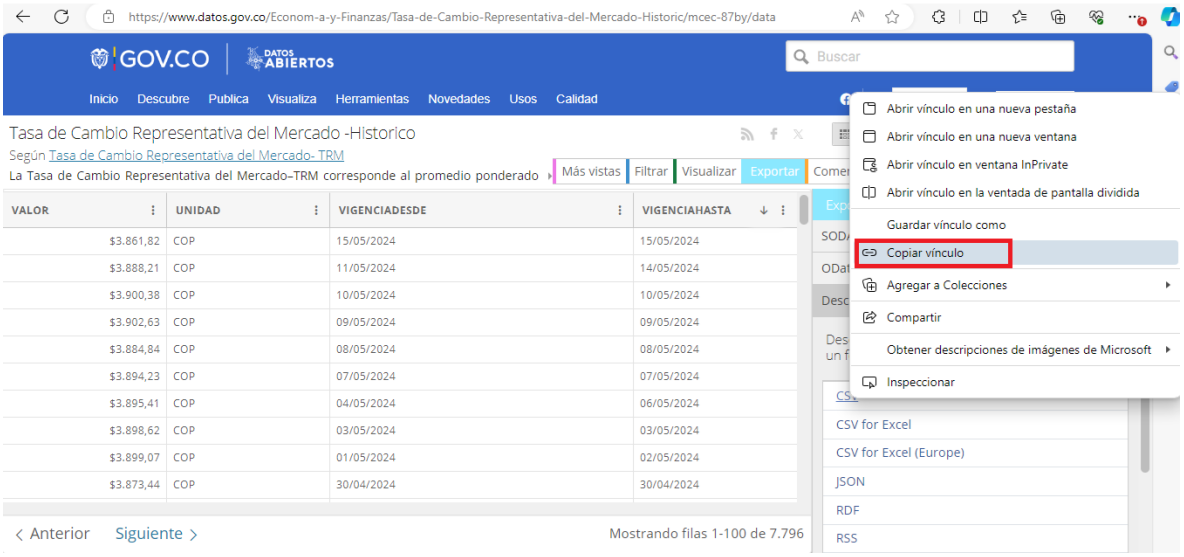
Opción explorar de dataset seleccionado



Nota: Dar click en la opción de exportar

Figura 26.

Opción de copiar vinculo de dataset seleccionado



Nota: Damos clic derecho sobre la opción CSV y luego en copiar vínculo.

Figura 27.

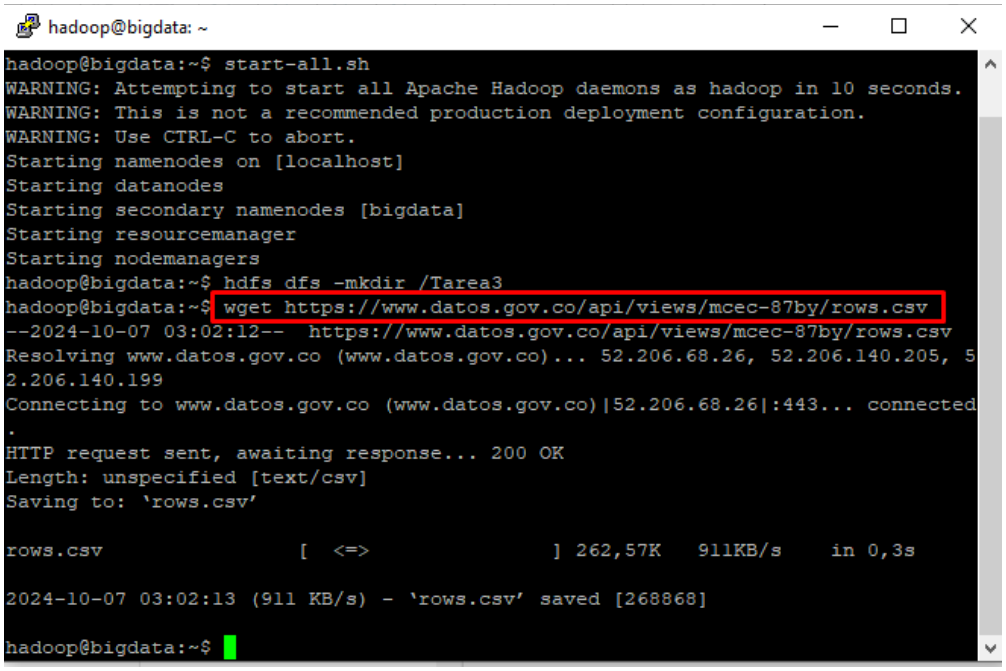
URL obtenida del dataset seleccionado



Nota: Abrimos un bloc de notas y damos “Ctrl + V” o pegar. ¿Eliminamos de la URL ?accessType=DOWNLOAD quedando de la siguiente forma. Esta será la dirección de descarga del dataset https://www.datos.gov.co/api/views/mcec-87by/rows.csv

Figura 28.

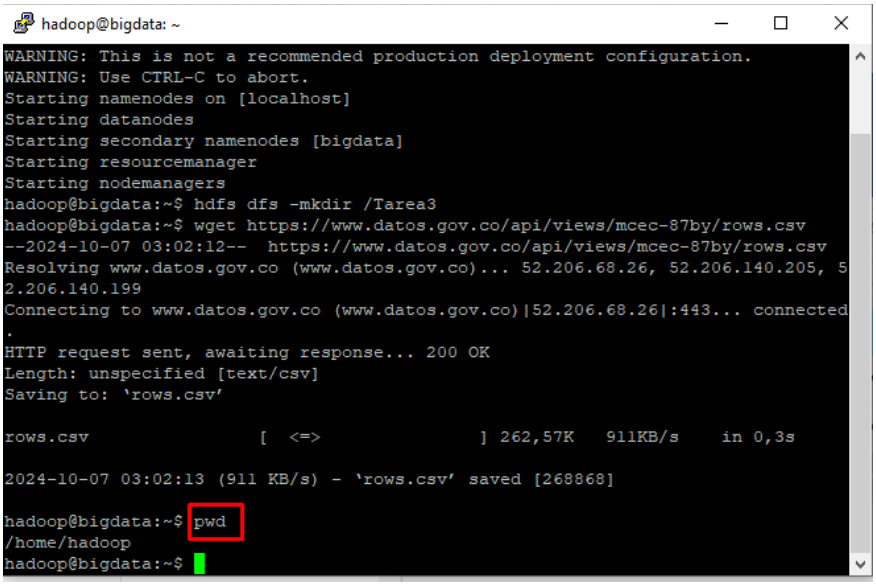
Descargue de dataset seleccionado



Nota: En la máquina virtual descargamos el dataset con la URL obtenida en el anterior paso usando el comando “wget https://www.datos.gov.co/api/views/mcec-87by/rows.csv”.

Figura 29.

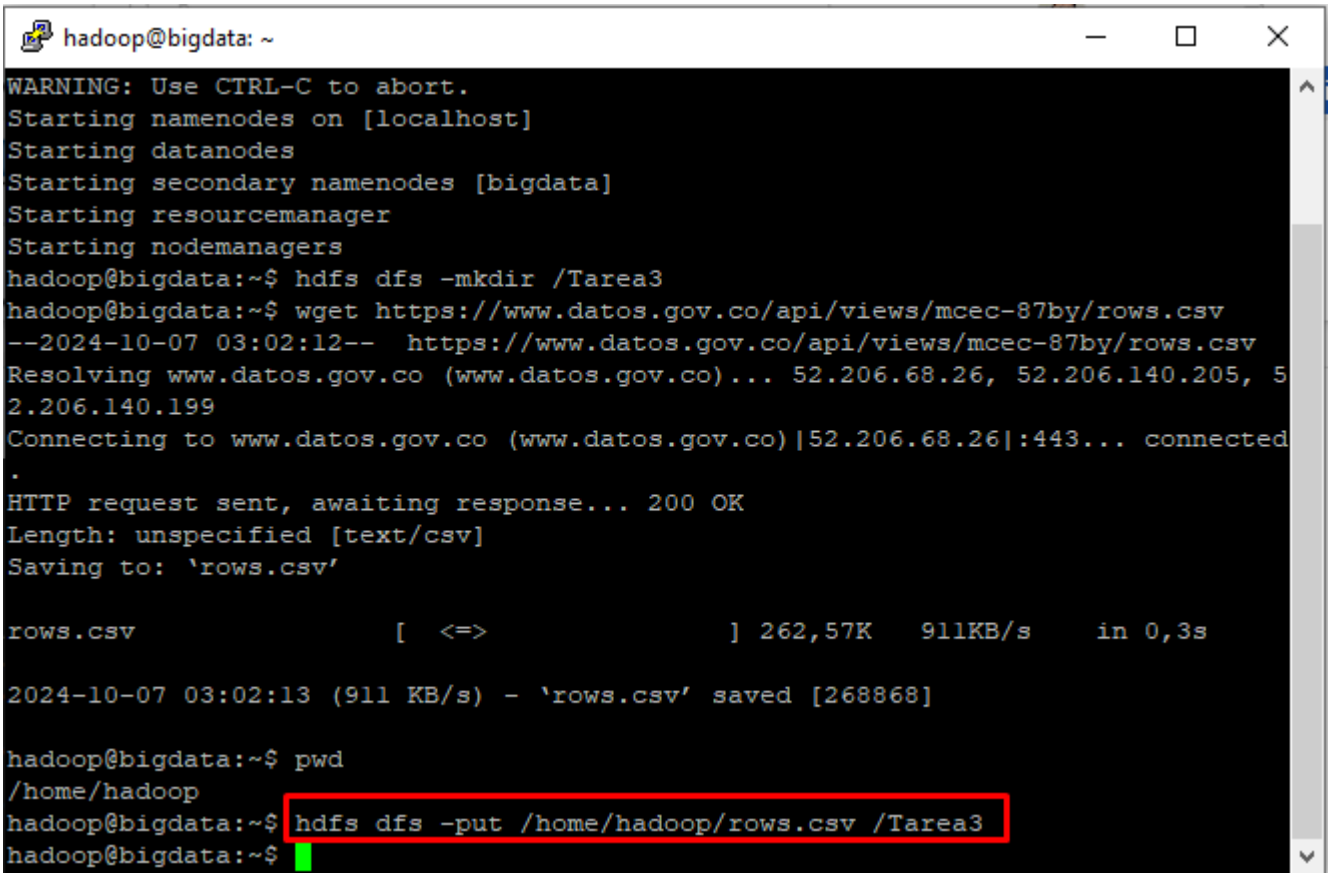
Uso del comando pwd



Nota: Con el comando “pwd” en ubuntu podemos ver la ruta en la que nos encontramos.

Figura 30.

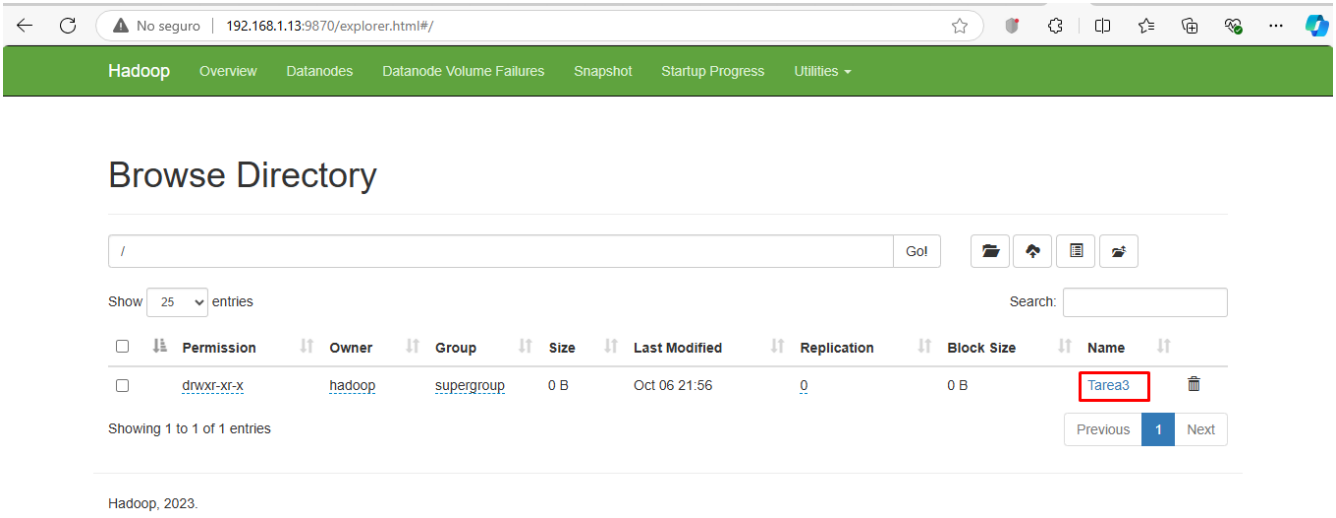
Copia del archivo descargado a la carpeta HDFS



Nota: Ahora copiamos el archivo del Dataset descargado a la carpeta HDFS que creamos usando el comando “hdfs dfs -put /home/hadoop/rows.csv /Tarea3”.

Figura 31.

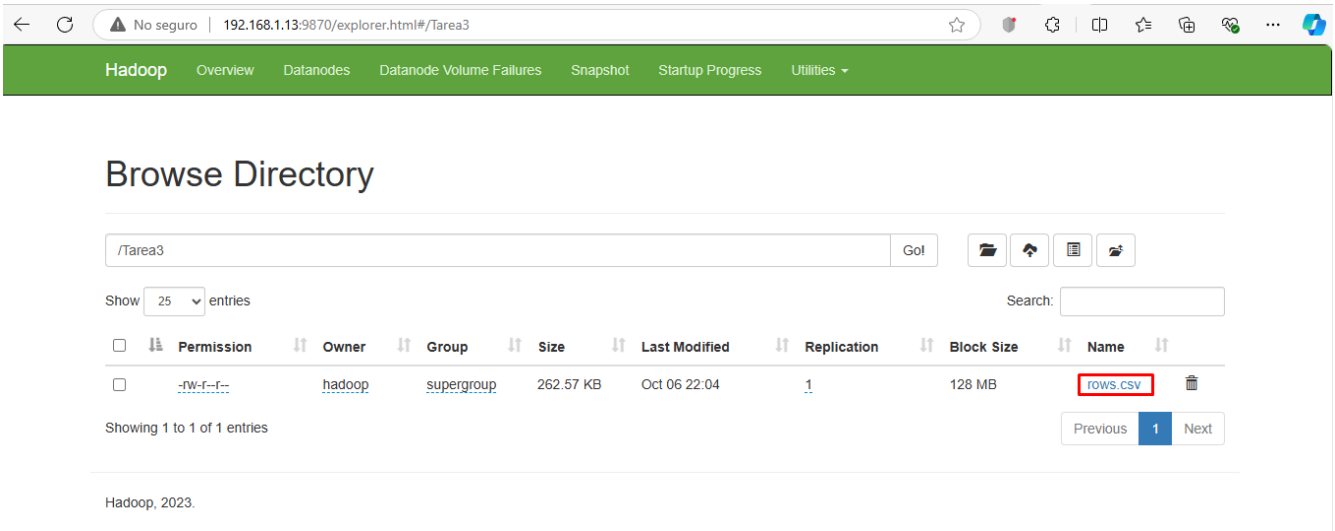
Visualización de la carpeta Tarea3 de archivos HDFS



Nota: Podemos ver que efectivamente se copió el archivo a la carpeta tanto en el navegador como por la línea de comando, ingresando a la carpeta Tarea3

Figura 32.

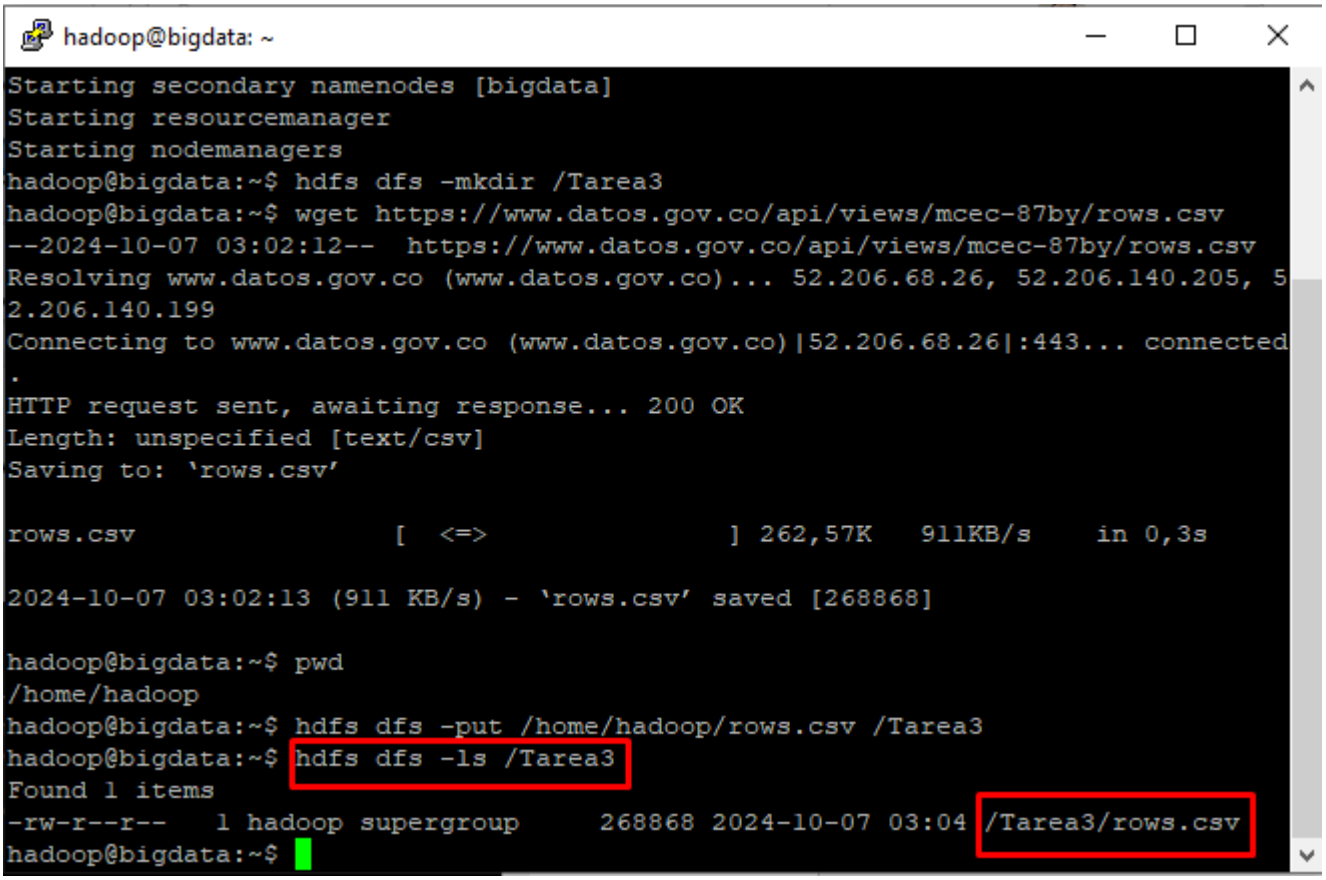
Archivo descargado rows en la carpeta HDFS



Nota: Podemos ver que en la carpeta Tarea3 se encuentra el archivo con el nombre rows.csv que acabamos de cargar a el sistema de archivos HDFS.

Figura 33.

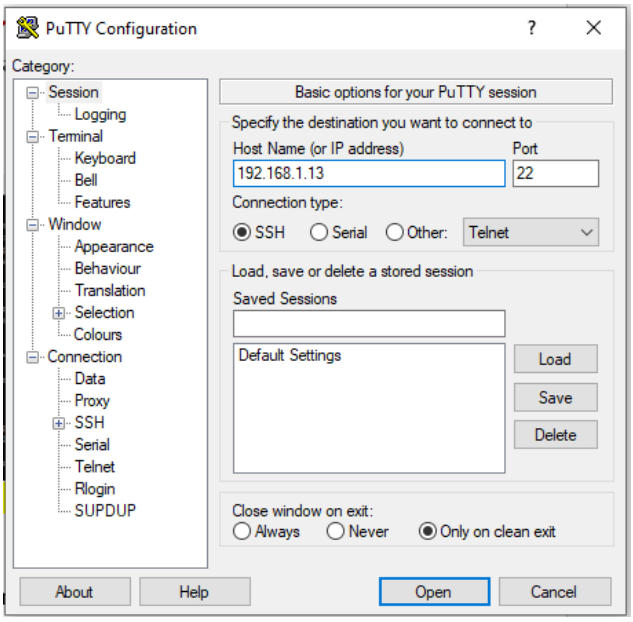
Validación de archivo rows por la línea de comando



Nota: Podemos también por la línea de comando ver el archivo del dataset rows.csv en la carpeta HDFS llamada Tarea3 mediante el comando “hdfs dfs -ls /Tarea3”. En este punto queda cargado el dataset en el sistema de archivos HDFS. Ahora mediante Spark se realizan operaciones básicas.

Figura 34.

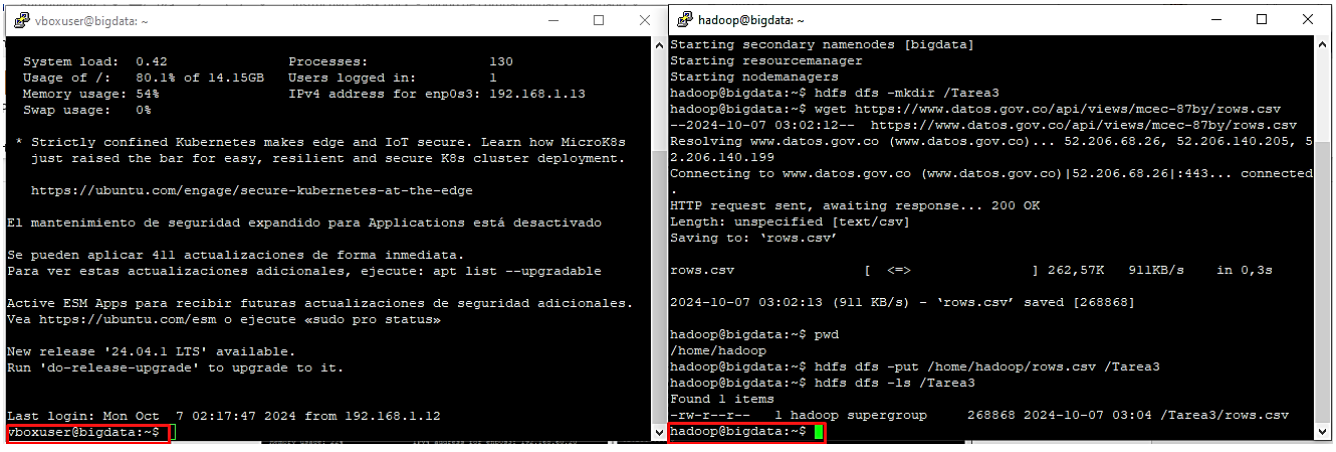
Página principal de configuración de Putty



Nota: Cargamos una nueva sesión por Putty sin cerrar la que ya está establecida

Figura 35.

Inicio de sesión con el usuario vboxuser



Nota: ingresamos con el usuario “vboxuser” y la contraseña “bigdata” y de aquí en adelate se trabajará en la sesión de Putty del usuario vboxuser sin cerrar la sesión del usuario hadoop.

Figura 36.

Creación de archivo tarea3.py



Nota: Se crea un archivo de python con extension .py lo podemos llamar tarea3.py, donde colocaremos el código del programa que se conectará al dataset descargado dentro del sistema HDFS, luego convertiremos estos datos en un dataframe de Spark y sobre este dataframe se realizarán diferentes operaciones y consultas. El archivo se crea mediente el comando “nano tarea3.py”.

Pegamos el siguiente código en el archivo tarea3.py

```
#Importamos librerías necesarias
from pyspark.sql import SparkSession, functions as F

# Inicializa la sesión de Spark
spark = SparkSession.builder.appName('Tarea3').getOrCreate()

# Define la ruta del archivo .csv en HDFS
file_path = 'hdfs://localhost:9000/Tarea3/rows.csv'

# Lee el archivo .csv
df = spark.read.format('csv').option('header','true').option('inferSchema', 'true').load(file_path)

#imprimimos el esquema
df.printSchema()

# Muestra las primeras filas del DataFrame
df.show()

# Estadísticas básicas
df.summary().show()

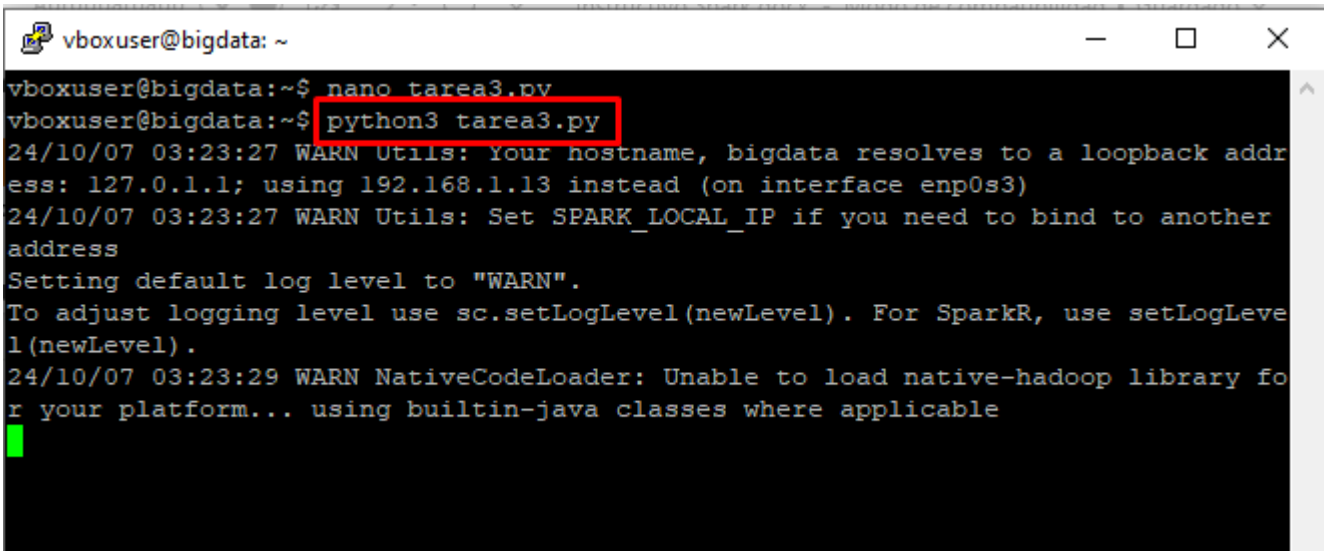
# Consulta: Filtrar por valor y seleccionar columnas
print("Días con valor mayor a 5000\n")
dias = df.filter(F.col('VALOR') > 5000).select('VALOR','VIGENCIADESDE','VIGENCIAHASTA')
dias.show()
```

```
# Ordenar filas por los valores en la columna "VALOR" en orden descendente
print("Valores ordenados de mayor a menor\n")
sorted_df = df.sort(F.col("VALOR").desc())
sorted_df.show()
```

dar Crtl+O enter y luego Crtl+X para salir

Figura 37.

Ejecución del archivo tarea3.py

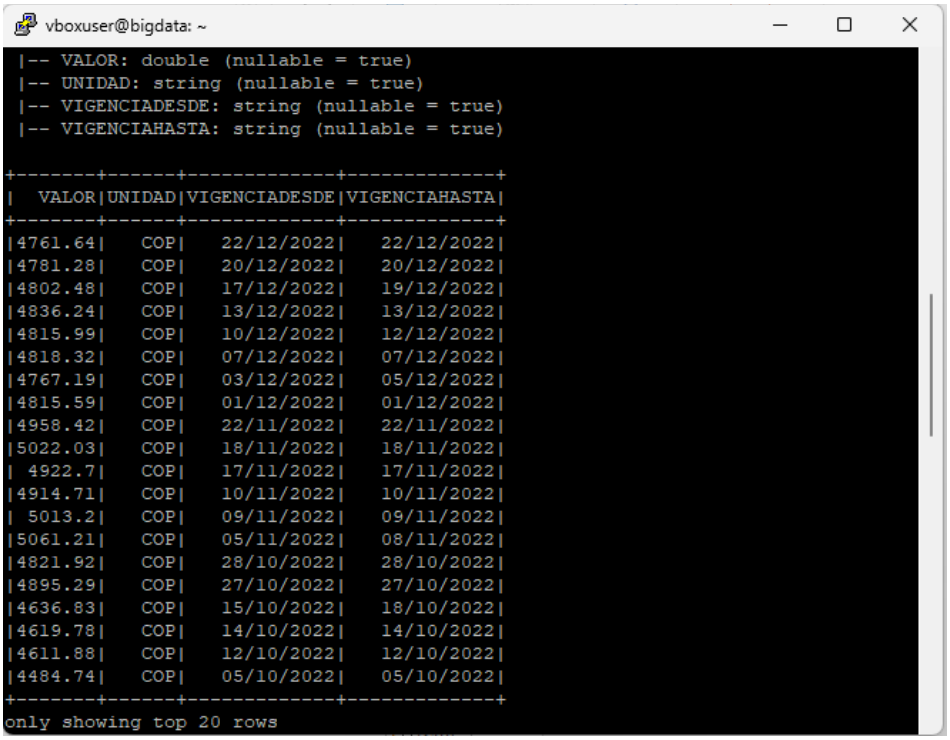


Nota: para ejecutar el archivo se realiza mediante el comando “python3 tarea3.py“

Al terminar la ejecución debemos obtener resultados similares a los siguientes:

Figura 38.

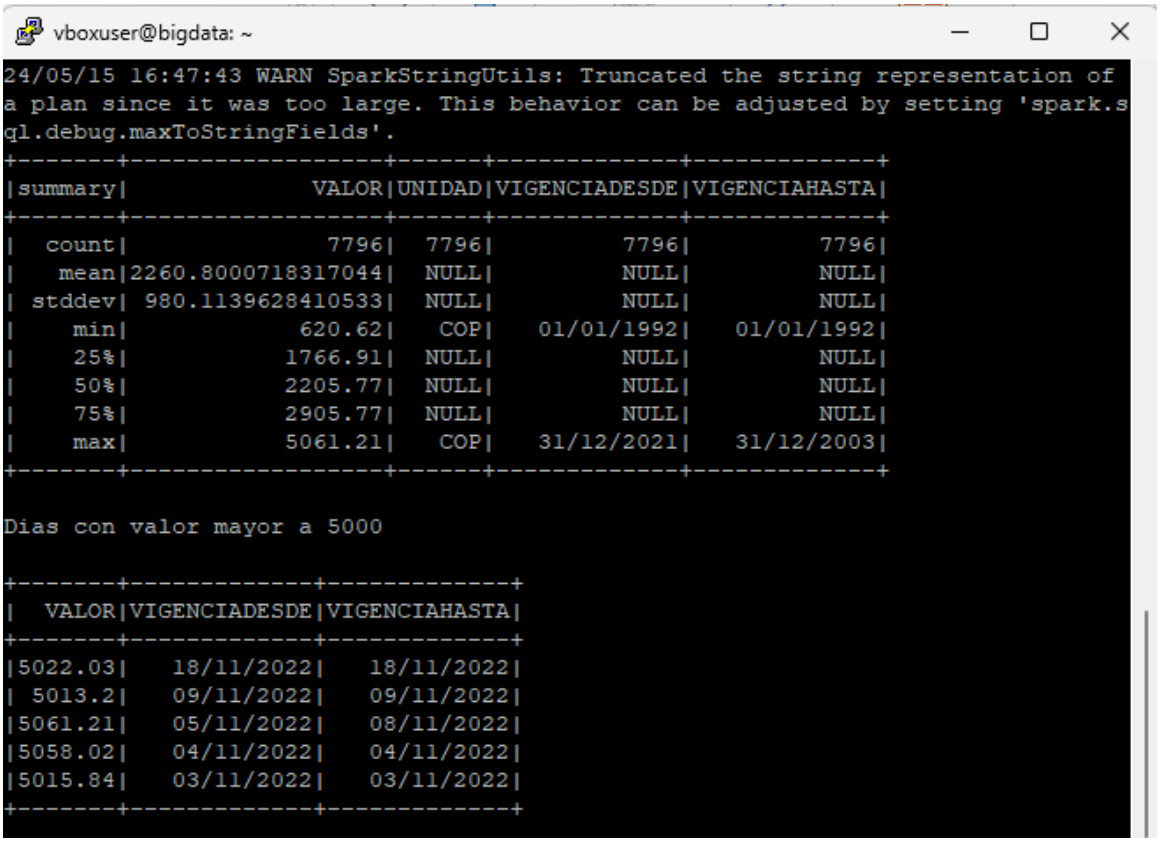
Resultado de los primeros 20 registros del dataset analizado



Nota: En la imagen se puede observar los primeros 20 registros del dataset. Mostrando el valor de la TRM, la unidad en COP, la fecha vigente desde y la fecha vigente hasta.

Figura 39.

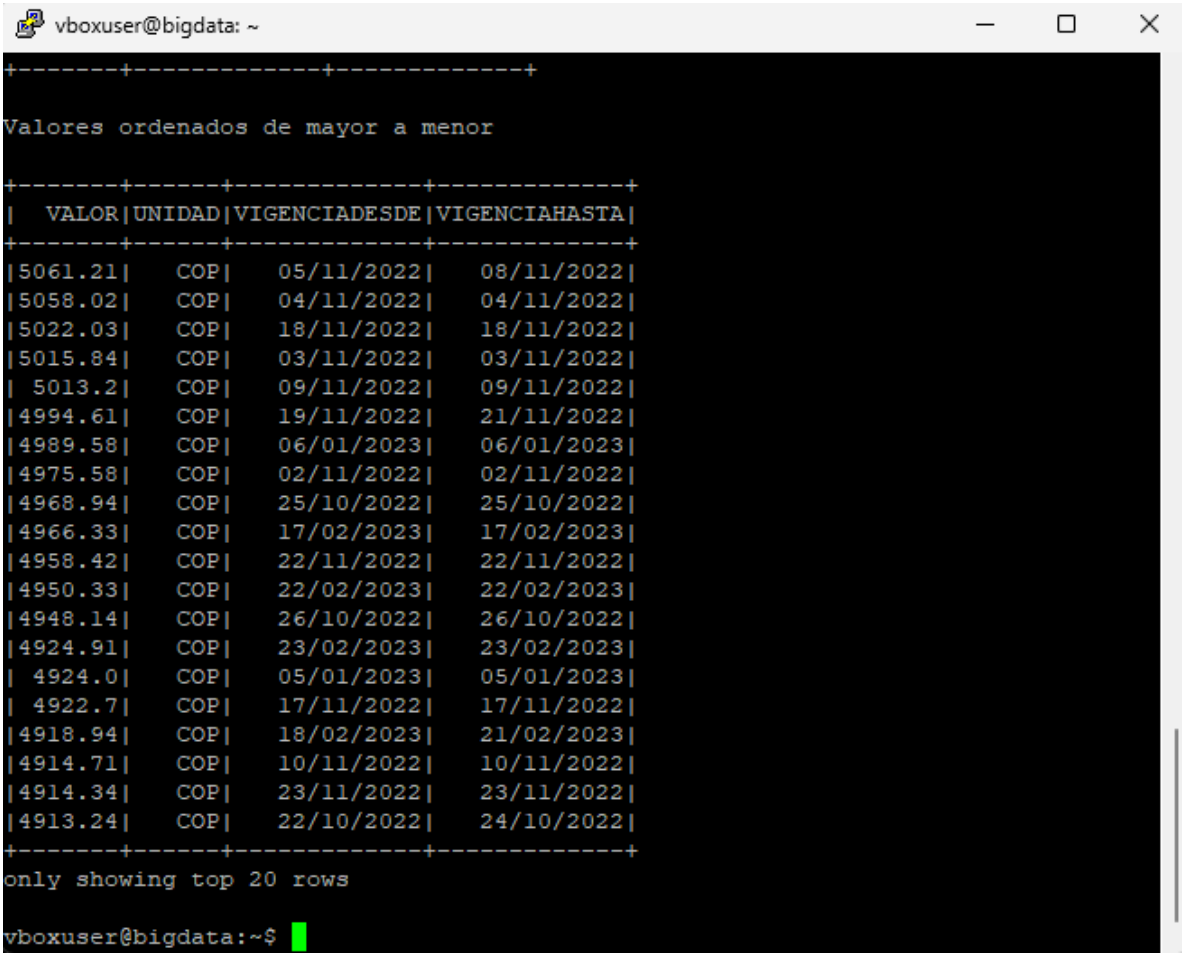
Resumen del dataset seleccionado



Nota: Resumen de dataset seleccionado, mostrando cantidad de valores, media, desviación estándar, mínimo, cuartil del 20%, cuartil del 50%, cuartil del 75% y valor máximo.

Figura 40.

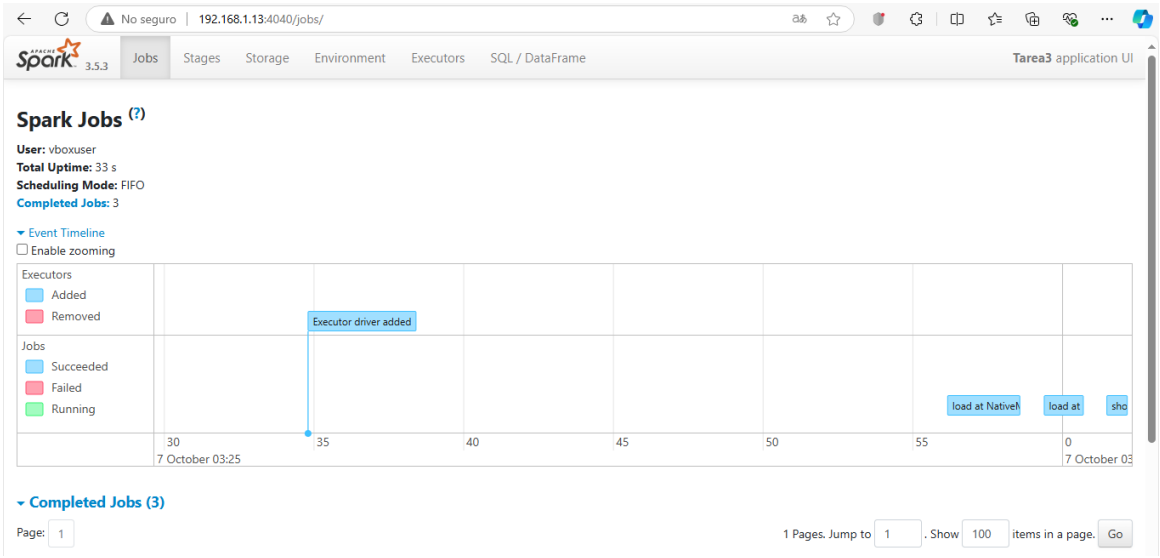
Dataset seleccionado ordenado de mayor a menor por valor



Nota: Imagen que muestra los valores ordenados de mayor a menor del dateset seleccionado.

Figura 41.

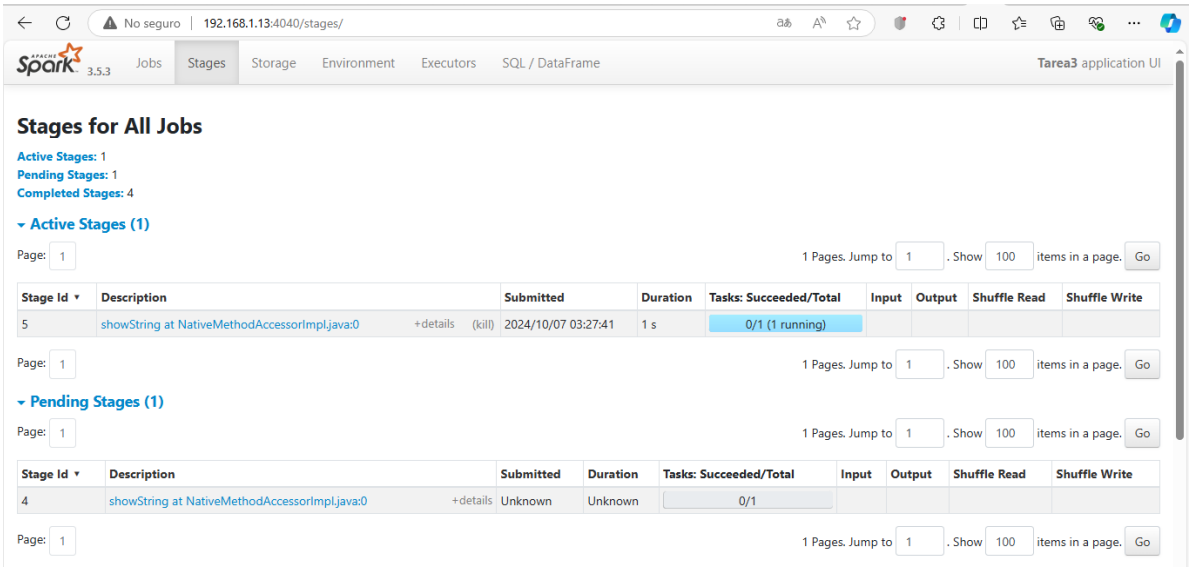
Jobs de Apache Spark



Mientras se encuentre en ejecución el archivo Tarea3.py podemos ver información sobre los Jobs realizados por Spark, para esto ingresamos a la consola web http://your-server-ip:4040 y para este caso http://192.168.1.13:4040

Figura 42.

Stages de Apache Spark



Nota: Mientras se encuentre en ejecución el archivo Tarea3.py podemos ver información sobre los Stages realizados por Spark, para esto ingresamos a la consola web http://your-server-ip:4040 y para este caso http://192.168.1.13:4040